

SD3589CV100 NPU API
开发参考

文档版本 V1.8

发布日期 2024-09-26

版权所有 © 上海云集互联有限公司

版权所有 © 上海云集互联有限公司

概述

本文档主要介绍NPU的推理API的使用。

版本说明

与本文档相对应的产品版本如下。

产品名称	产品版本
SD3589C	V100
SD3589D	V100

用户

本文档主要适用于以下工程师：

- ✧ 技术支持工程师
- ✧ 软件工程师
- ✧ 算法工程师

修订记录

修订记录列出了各文档版本间发生的主要更改。最新版本的文档包含以前所有文档版本的更新内容。

版本	修订日期	修订说明
v1.0	2023.08.17	首个NPU API接口文档
v1.1	2023.10.19	增加1.1版本接口更新
v1.2	2023.11.25	增加1.2版本接口更新
v1.3	2023.12.29	增加性能模式
v1.4	2024.2.5	增加1.4版本接口更新 增加任务优先级调度机制
v1.5	2024.3.26	支持异步推理
v1.6	2024.6.13	变更命名device_ids为core_ids
v1.7	2024.8.5	支持用户设置自定义stride

版权所有 © 上海云集互联有限公司

版权所有 © 上海云集互联有限公司

目录

1 概述 1
1.1 概述 1
1.2 重要概念 1
2 API 参考 2
2.1 ot_avp_npu_init 3
2.2 ot_avp_npu_deinit 3
2.3 ot_avp_npu_load_model 3
2.4 ot_avp_npu_load_model_from_mem 4
2.5 ot_avp_npu_unload_model 4
2.6 ot_avp_npu_bind_model_to_core 5
2.7 ot_avp_npu_execute 5
2.8 ot_avp_npu_trigger 6
2.9 ot_avp_npu_wait 6
2.10 ot_avp_npu_cancel 7
2.11 ot_avp_npu_get_runtime_buffer_size 7
2.12 ot_avp_npu_set_runtime_buffer 8
2.13 ot_avp_npu_get_input_num 8
2.14 ot_avp_npu_get_input_index_by_name 9
2.15 ot_avp_npu_get_input_shape_by_index 9
2.16 ot_avp_npu_get_input_format_by_index 10
2.17 ot_avp_npu_get_input_dtype_by_index 10
2.18 ot_avp_npu_get_output_num 11
2.19 ot_avp_npu_get_output_index_by_name 11
2.20 ot_avp_npu_get_output_name_by_index 12
2.21 ot_avp_npu_get_output_shape_by_index 12
2.22 ot_avp_npu_get_output_format_by_index 13
2.23 ot_avp_npu_get_output_dtype_by_index 13
2.24 ot_avp_npu_create_dataset 14
2.25 ot_avp_npu_add_buffer 14
2.26 ot_avp_npu_set_buffer 15
2.27 ot_avp_npu_destroy_dataset 15
2.28 ot_avp_npu_data_type_size 16
2.29 ot_avp_npu_get_input_default_stride 16
2.30 ot_avp_npu_get_ouput_default_stride 16
2.31 ot_avp_npu_get_input_size_by_index 17
2.32 ot_avp_npu_get_output_size_by_index 17
2.33 ot_avp_npu_malloc 18
2.34 ot_avp_npu_free 18
2.35 ot_avp_npu_set_model_config 18
3 数据类型 20
3.1 ot_avp_npu_config 20
3.2 ot_avp_npu_dataset 20
3.3 ot_avp_npu_shape 21
3.4 ot_avp_npu_dformat 21
3.5 ot_avp_data_type 22

版权所有 © 上海云集互联有限公司

3.6 ot_attr_type....23
3.7 ot_avp_npu_mdl_config....23
3.8 ot_avp_npu_mdl_priority....24
4 错误码....26
5 调试信息....27

版权所有 © 上海云集互联有限公司

1 概述

1.1 概述

NPU是SD3589C平台上做NN模型推理的加速器，本文档主要描述相关的推理接口，可以同时在仿真平台或者板端使用。

1.2 重要概念

- **离线模型(Offline Model)**

  离线模型为使用NPU Toolchain生成的给板端推理使用的模型，此模型只能上板使用；

- **仿真模型(Simulate Model)**

  仿真模型为使用NPU Toolchain生成的给仿真推理使用的模型，不能上板使用；

  生成模型的过程参考《SD3589CV100 NPU工具使用指南》

- **及时刷cache**

  NPU硬件只能从DDR中获取数据。为保证数据在cache和DDR之间的同步，用户申请和释放输入输出的内存，请直接调用提供的接口：ot_avp_npu_malloc/ot_avp_npu_free。

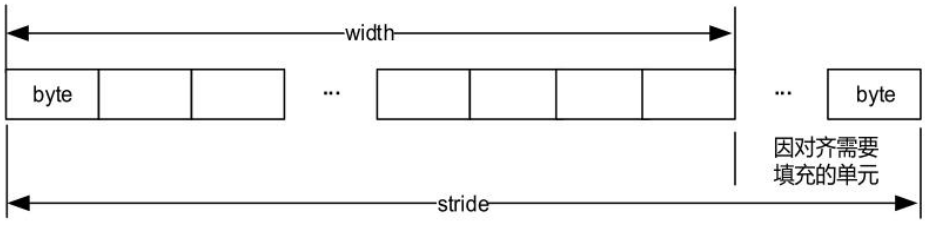
- **跨度(stride)**

  一行的有效数据byte数目 + 为硬件快速跨越到下一行补齐的一些无效byte数目，如图1-1所示。

  不同的数据结构行存储表示的有效元素数目的变量不一样，且其度量跟stride不一定是一样的。

  - shape，行存储方向表示的有效元素数目变量是dim。因对齐需要填充的单元

图1-1 跨度(stride)示意图



版权所有 © 上海云集互联有限公司

2 API 参考

提供以下API：

- ot_avp_npu_init：初始化NPU模块
- ot_avp_npu_deinit：去初始化NPU模块
- ot_avp_npu_load_model：加载模型
- ot_avp_npu_load_model_with_mem：加载模型，使用外部提供的weight/runtime_buf内存空间
- ot_avp_npu_load_model_from_mem：从内存加载模型
- ot_avp_npu_unload_model：卸载模型
- ot_avp_npu_bind_model_to_core: 将模型绑定到某一个或多个核上执行
- ot_avp_npu_execute：模型的同步推理
- ot_avp_npu_trigger：模型的异步推理
- ot_avp_npu_wait：异步推理等待
- ot_avp_npu_cancel：取消异步推理任务
- ot_avp_npu_get_memory_size：获取权重需要的内存大小和runtime_buf需要的内存大小
- ot_avp_npu_get_input_num：获取输入个数
- ot_avp_npu_get_input_index_by_name：通过名称获取输入索引
- ot_avp_npu_get_input_shape_by_index：通过输入索引获取shape
- ot_avp_npu_get_input_format_by_index：通过输入索引获取data_format
- ot_avp_npu_get_input_dtype_by_index：通过输入索引获取data_type
- ot_avp_npu_get_output_num：获取输出个数
- ot_avp_npu_get_output_index_by_name：通过名称获取输出索引
- ot_avp_npu_get_output_name_by_index：通过索引获取输出名称
- ot_avp_npu_get_output_shape_by_index：通过输出索引获取shape
- ot_avp_npu_get_output_format_by_index：通过输出索引获取data_format
- ot_avp_npu_get_output_dtype_by_index：通过输出索引获取data_type
- ot_avp_npu_create_dataset：创建输入输出dataset
- ot_avp_npu_add_buffer：将buffer添加到dataset中
- ot_avp_npu_set_buffer：更新dataset的buffer
- ot_avp_npu_destroy_dataset：删除输入输出dataset
- ot_avp_npu_data_type_size：获取data_type的size
- ot_avp_npu_get_input_default_stride：获取第index个输入的stride
- ot_avp_npu_get_input_size_by_index：获取第index个输入的size
- ot_avp_npu_get_output_default_stride：获取第index个输出的stride
- ot_avp_npu_get_output_size_by_index：获取第index个输出的size
- ot_avp_npu_malloc：申请size大小的内存
- ot_avp_npu_free：释放内存
- ot_avp_npu_set_mdl_config：设置模型需要的配置参数

版权所有 © 上海云集互联有限公司

2.1 ot_avp_npu_init

【功能描述】

初始化NPU资源。

【语法】

【参数描述】

参数名称	描述	输入/输出
config	NPU的初始化配置	输入

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	初始化成功
OT_AVP_NPU_INVALID_PARAM	非法配置参数

【注意事项】需要和ot_avp_npu_deinit配对使用。

【参考代码】无

2.2 ot_avp_npu_deinit

【功能描述】

释放NPU相关资源。

【语法】

【参数描述】

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	释放成功

【注意事项】需要与ot_avp_npu_init配对使用。

【参考代码】无

2.3 ot_avp_npu_load_model

【功能描述】

从文件加载模型。

【语法】

【参数描述】

参数名称	描述	输入/输出
path	模型路径	输入
handle	模型handle，在后续对模型的操作都会用到	输出

【返回值】

版权所有 © 上海云集互联有限公司

返回值	描述
OT_AVP_NPU_SUCCESS	加载成功
OT_AVP_NPU_FAILURE	加载失败
OT_AVP_NPU_INVALID_PARAM	非法参数
OT_AVP_NPU_NOT_SUPPORTED	NPU不支持

【注意事项】模型文件必须可读，并且是合法的离线模型，必须在ot_avp_npu_init之后调用。

【参考代码】无

2.4 ot_avp_npu_load_model_from_mem

【功能描述】

从内存加载模型。

【语法】

【参数描述】

云集互联 YUNJI ECO	描述	输入/输出
model_buf	装载离线模型的内存	输入
model_len	离线模型内存的大小	输入
handle	模型handle	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	加载成功
OT_AVP_NPU_FAILURE	加载失败
OT_AVP_NPU_INVALID_PARAM	非法参数
OT_AVP_NPU_NOT_SUPPORTED	NPU不支持

【注意事项】模型文件必须是合法的离线模型，必须在ot_avp_npu_init之后调用。

【参考代码】无

2.5 ot_avp_npu_unload_model

【功能描述】

模型卸载，模型相关资源回收。

【语法】

【参数描述】

云集互联 YUNJI ECO	描述	输入/输出
handle	模型handle	输入

版权所有 © 上海云集互联有限公司

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	模型卸载成功

【注意事项】无

【参考代码】无

2.6 ot_avp_npu_bind_model_to_core

【功能描述】

将模型绑定到某一个或多个核上执行。（此版本不支持）

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	模型handle	输入
core_ids	绑定的核编号列表，按bit组装	输入

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	模型绑定成功
OT_AVP_NPU_FAILURE	模型绑定失败

【注意事项】必须在模型加载成功后调用。

【参考代码】无

2.7 ot_avp_npu_execute

【功能描述】

模型的同步推理。

【语法】

【参数描述】

云集互联 YUNJI ECO	描述	输入/输出
handle	模型handle	输入
inputs	模型的输入，datasets中的个数需要和模型的输入个数一致	输入
outputs	模型的输出，datasets中的个数需要和模型的输出个数一致	输入

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	模型执行成功
OT_AVP_NPU_FAILURE	模型执行失败

版权所有 © 上海云集互联有限公司

OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.8 ot_avp_npu_trigger

【功能描述】

模型的异步推理。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	模型handle	输入
inputs	模型的输入，datasets中的个数需要和模型的输入个数一致	输入
outputs	模型的输出，datasets中的个数需要和模型的输出个数一致	输入

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	异步任务添加成功
OT_AVP_NPU_FAILURE	异步任务添加失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】

1. 用法1：trigger/wait配套使用，eg.model_0 trigger+wait/model_1 trigger+wait.
2. 用法2：多个模型之间可以实现trigger+trigger+wait的方式，eg.model_0 trigger + model_1 trigger + model_1 wait。其中model_0和model_1的优先级必须一致，则model_1 wait返回，两个模型都执行完成。如果不一致，model_1 wait后，无法保证model_0是否完成。

【参考代码】无

2.9 ot_avp_npu_wait

【功能描述】

等待模型异步推理结束。

【语法】

【参数描述】

云集互联 YUNJI ECO	描述	输入/输出
handle	模型handle	输入
timeout	等待的超时时间，当timeout=-1时永久等待，timeout=0时，立即返回，其它值时，为超时时间，单位为毫秒	输入

版权所有 © 上海云集互联有限公司

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功等到模型执行结束，模型执行成功
OT_AVP_NPU_FAILURE	成功等到模型执行结束，模型执行失败
OT_AVP_NPU_TIMEOUT	等待超时
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.10 ot_avp_npu_cancel

【功能描述】

取消异步推理任务。（此版本不支持）

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	模型handle	输入

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功取消

【注意事项】无

【参考代码】无

2.11 ot_avp_npu_get_runtime_buffer_size

【功能描述】

获取离线模型需要的临时内存的大小。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	模型handle	输入
runtime_buf_size	runtime_buf所需内存大小，单位byte	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功获取到内存大小
OT_AVP_NPU_FAILURE	失败

版权所有 © 上海云集互联有限公司

【注意事项】在load_model之后执行。

【参考代码】无

2.12 ot_avp_npu_set_runtime_buffer

【功能描述】

设置离线模型需要的临时内存，由用户申请。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	模型handle	输入
rumtime_buf	runtime_buf内存地址	输入
runtime_buf_size	runtime_buf所需内存大小，单位byte	输入

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功获取到内存大小
OT_AVP_NPU_FAILURE	失败

【注意事项】无

【参考代码】无

2.13 ot_avp_npu_get_input_num

【功能描述】

获取模型输入个数。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	模型handle	输入
input_num	模型输入节点个数	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	信息获取成功
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

版权所有 © 上海云集互联有限公司

2.14 ot_avp_npu_get_input_index_by_name

【功能描述】

通过输入名称获取输入索引。

【语法】

【参数描述】

云集互联 YUNJI ECO	描述	输入/输出
handle	模型handle	输入
name	输入名称	输入
name_len	输入名称的长度	输入
index	获取输入的索引号	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	信息获取成功
OT_AVP_NPU_FAILURE	信息获取失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】当前版本不支持

【参考代码】无

2.15 ot_avp_npu_get_input_shape_by_index

【功能描述】

通过输入索引获取shape。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	模型handle	输入
index	需要获取输入的索引号	输入
shape	ot_avp_npu_shape信息	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	信息获取成功
OT_AVP_NPU_FAILURE	信息获取失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

版权所有 © 上海云集互联有限公司

【参考代码】无

2.16 ot_avp_npu_get_input_format_by_index

【功能描述】

通过输入索引获取data format

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	模型handle	输入
index	需要获取输入的索引号	输入
format	ot_avp_npu_dformat信息	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	信息获取成功
OT_AVP_NPU_FAILURE	信息获取失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.17 ot_avp_npu_get_input_dtype_by_index

【功能描述】

获取输入data type

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	模型handle	输入
index	需要获取输入的索引号	输入
dtype	ot_avp_npu_dtype信息	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	信息获取成功
OT_AVP_NPU_FAILURE	信息获取失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

版权所有 © 上海云集互联有限公司

【参考代码】无

2.18 ot_avp_npu_get_output_num

【功能描述】

获取模型输出个数。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	模型handle	输入
output_num	模型输出节点个数	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	信息获取成功
OT_AVP_NPU_FAILURE	信息获取失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.19 ot_avp_npu_get_output_index_by_name

【功能描述】

获取输出的索引号。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	模型handle	输入
name	输出的名称	输入
name_len	输出的名称长度	输入
index	获取输出的索引号	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	信息获取成功
OT_AVP_NPU_FAILURE	信息获取失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

版权所有 © 上海云集互联有限公司

【参考代码】无

2.20 ot_avp_npu_get_output_name_by_index

【功能描述】

获取输出的名称。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	模型handle	输入
name	获取输出名称	输出
name_len	输出名称长度	输入
index	输出的索引号	输入

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	信息获取成功
OT_AVP_NPU_FAILURE	信息获取失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.21 ot_avp_npu_get_output_shape_by_index

【功能描述】

获取输出的shape。

【语法】

【参数描述】

云集互联 YUNJI ECO	描述	输入/输出
handle	模型handle	输入
index	需要获取输出的索引号	输入
shape	ot_avp_npu_shape信息	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	信息获取成功
OT_AVP_NPU_FAILURE	信息获取失败
OT_AVP_NPU_INVALID_PARAM	非法参数

版权所有 © 上海云集互联有限公司

【注意事项】无

【参考代码】无

2.22 ot_avp_npu_get_output_format_by_index

【功能描述】

获取输出data format。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	模型handle	输入
index	需要获取输出的索引号	输入
format	ot_avp_npu_dformat信息	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	信息获取成功
OT_AVP_NPU_FAILURE	信息获取失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.23 ot_avp_npu_get_output_dtype_by_index

【功能描述】

获取输出data type。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	模型handle	输入
index	需要获取输出的索引号	输入
dtype	ot_avp_npu_dtype信息	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	信息获取成功
OT_AVP_NPU_FAILURE	信息获取失败
OT_AVP_NPU_INVALID_PARAM	非法参数

版权所有 © 上海云集互联有限公司

【注意事项】无

【参考代码】无

2.24 ot_avp_npu_create_dataset

【功能描述】

创建输入输出内存。

【语法】

【参数描述】

参数名称	描述	输入/输出
无		

【返回值】

返回值	描述
ot_avp_npu_dataset*	创建的输入输出dataset

【注意事项】需要与ot_avp_npu_destroy_dataset配对使用。

【参考代码】无

2.25 ot_avp_npu_add_buffer

【功能描述】

将对应的buffer加入到dataset中来。

【语法】

【参数描述】

参数名称	描述	输入/输出
dataset	输入输出dataset	输入
virt_addr	buffer虚拟地址	输入
phy_addr	buffer物理地址	输入
buffer_len	buffer长度	输入
buffer_stride	buffer跨度，用于逻辑快速跳转到下一行，配置约束16对齐	输入

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	添加成功
OT_AVP_NPU_FAILURE	添加失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

版权所有 © 上海云集互联有限公司

2.26 ot_avp_npu_set_buffer

【功能描述】

更新第index个buffer。

【语法】

【参数描述】

参数名称	描述	输入/输出
dataset	输入输出dataset	输入
index	设置buffer的索引号	输入
virt_addr	buffer虚拟地址	输入
phy_addr	buffer物理地址	输入
buffer_len	buffer长度	输入
buffer_stride	buffer跨度，用于逻辑快速跳转到下一行，配置约束16对齐	输入

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	设置成功
OT_AVP_NPU_FAILURE	设置失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.27 ot_avp_npu_destroy_dataset

【功能描述】

销毁dataset。

【语法】

【参数描述】

参数名称	描述	输入/输出
dataset	输入输出dataset	输入

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功

【注意事项】无

【参考代码】无

版权所有 © 上海云集互联有限公司

2.28 ot_avp_npu_data_type_size

【功能描述】

获取data_type的size。

【语法】

【参数描述】

云集互联 YUNJI ECO	描述	输入/输出
data_type	数据类型	输入

【返回值】

返回值	描述
ot_s32	data_type对应的大小

【注意事项】无

【参考代码】无

2.29 ot_avp_npu_get_input_default_stride

【功能描述】

根据模型描述信息获取模型中指定输入的默认stride。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	模型handle	输入
index	输入index	输入

【返回值】

返回值	描述
ot_u32	第index个输入的默认stride

【注意事项】此接口返回的是默认stride，不一定和使用的stride一致

【参考代码】无

2.30 ot_avp_npu_get_ouput_default_stride

【功能描述】

根据模型描述信息获取模型中指定输出的默认stride。

【语法】

【参数描述】

参数名称	描述	输入/输出

版权所有 © 上海云集互联有限公司

handle	模型handle	输入
index	输出index	输入

【返回值】

返回值	描述
ot_u32	第index个输出的默认stride

【注意事项】此接口返回的是默认stride，不一定和使用的stride一致

【参考代码】无

2.31 ot_avp_npu_get_input_size_by_index

【功能描述】

根据模型描述信息获取指定输入的大小，单位为Byte。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	模型handle	输入
index	输入index	输入

【返回值】

返回值	描述
ot_u32	第index个输入的size

【注意事项】无

【参考代码】无

2.32 ot_avp_npu_get_output_size_by_index

【功能描述】

根据模型描述信息获取指定输出的大小，单位为Byte。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	模型handle	输入
index	输出index	输入

【返回值】

返回值	描述
ot_u32	第index个输出的size

【注意事项】无

版权所有 © 上海云集互联有限公司

【参考代码】无

2.33 ot_avp_npu_malloc

【功能描述】

申请内存。

【语法】

【参数描述】

参数名称	描述	输入/输出
ptr	内存指针	输入
size	需要创建的内存大小	输入

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	申请内存成功
OT_AVP_NPU_FAILURE	申请内存失败

【注意事项】无

【参考代码】无

2.34 ot_avp_npu_free

【功能描述】

释放内存。

【语法】

【参数描述】

云集互联 YUNJI ECO	描述	输入/输出
ptr	内存指针	输入

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	释放内存成功
OT_AVP_NPU_FAILURE	释放内存失败

【注意事项】无

【参考代码】无

2.35 ot_avp_npu_set_model_config

【功能描述】

版权所有 © 上海云集互联有限公司

设置模型需要的配置及参数。（仅支持板端）

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	模型handle	输入
config	模型所需的配置参数	输入

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	设置成功
OT_AVP_NPU_FAILURE	设置失败

【注意事项】无

【参考代码】无

版权所有 © 上海云集互联有限公司

3 数据类型

3.1 ot_avp_npu_config

【说明】

NPU的初始化配置结构体。

【定义】

```
typedef struct {
    ot_u32 core_ids;
    ot_bool dump_layer;
    ot_bool perf_mode;
    ot_u8 log_level;
    ot_u32 thread_num;
} ot_avp_npu_config;
```

【成员】

成员名称	描述
core_ids	需要使用的ID号，如果要同时启动多个核，则ID号按位或运算，例如启动核0和核1，则core_ids=(1<<0)+(1<<1)=3。(当前版本支持绑核处理)
dump_layer	精度dump，true为开启。（当前版本不支持配置）
perf_mode	性能模式，true为开启。 板端模型限制条件： 1. npu graph中node_name长度需小于32. 2. npu graph中node_type长度需小于16. 3. 模型需要包含无权重模型分区.
log_level	日志级别，目前支持输入1: debug、2: info、3: warn、4: error。
thread_num	异步推理，调度线程的数量。 当thread_num =0， 表示只支持同步推理。 当thread_num > 0, 同时支持同步推理和异步推理。

【注意事项】

dump模式和perf模式互斥。

【相关数据类型及接口】

- ot_avp_npu_init
- ot_avp_npu_deinit

3.2 ot_avp_npu_dataset

【说明】

通用输入输出数据的结构体。

版权所有 © 上海云集互联有限公司

【定义】

```
typedef struct ot_avp_npu_dataset ot_avp_npu_dataset;
```

【成员】

成员名称	描述

【注意事项】

【相关数据类型及接口】

- ot_avp_npu_create_dataset
- ot_avp_npu_add_buffer
- ot_avp_npu_set_buffer
- ot_avp_npu_destroy_dataset

3.3 ot_avp_npu_shape

【说明】

描述shape信息。

【定义】

```
typedef struct {
    ot_s32 dims[16];
    ot_u8 dim_size;
} ot_avp_shape;

typedef ot_avp_shape ot_avp_npu_shape;
```

【成员】

成员名称	描述
dims[16]	各维度的大小。
dim_size	维度的个数。

【注意事项】

【相关数据类型及接口】

- ot_avp_npu_get_input_shape_by_index
- ot_avp_npu_get_output_shape_by_index

3.4 ot_avp_npu_dformat

【说明】

描述format信息。

版权所有 © 上海云集互联有限公司

【定义】

```
typedef enum {
    OT_AVP_DF_NCHW,
    OT_AVP_DF_NHWC,
    OT_AVP_DF_ND,
    OT_AVP_DF_BUTT
} ot_avp_npu_dformat;
```

【成员】

成员名称	描述
无	

【注意事项】

【相关数据类型及接口】

- ot_avp_npu_get_input_format_by_index
- ot_avp_npu_get_output_format_by_index

3.5 ot_avp_data_type

【说明】

描述data type信息。

【定义】

```
typedef enum {
    OT_AVP_DTYPE_F32 = 0,
    OT_AVP_DTYPE_F64,
    OT_AVP_DTYPE_INT8,
    OT_AVP_DTYPE_INT16,
    OT_AVP_DTYPE_INT32,
    OT_AVP_DTYPE_INT64,
    OT_AVP_DTYPE_UINT8,
    OT_AVP_DTYPE_UINT16,
    OT_AVP_DTYPE_UINT32,
    OT_AVP_DTYPE_UINT64,
    OT_AVP_DTYPE_F16,
    OT_AVP_DTYPE_INT4,
    OT_AVP_DTYPE_UINT4,
    OT_AVP_DTYPE_BOOL,
    OT_AVP_DTYPE_BUTT
} ot_avp_data_type;
```

【成员】

成员名称	描述
无	

【注意事项】

【相关数据类型及接口】

版权所有 © 上海云集互联有限公司

- ot_avp_npu_get_input_dtype_by_index
- ot_avp_npu_get_input_dtype_by_index

3.6 ot_attr_type

【说明】

描述自定义算子的属性

【定义】

```
typedef enum {
    OT_ATTR_INT = 0,
    OT_ATTR_INTS,
    OT_ATTR_FLOAT,
    OT_ATTR_FLOATS,
    OT_ATTR_STR,
    OT_ATTR_BUTT,
} ot_attr_type;
```

【成员】

成员名称	描述
无	

【注意事项】

【相关数据类型及接口】

3.7 ot_avp_npu_mdl_config

【说明】

NPU的模型配置结构体。（仅支持板端）

【定义】

```
typedef struct {
    ot_avp_npu_mdl_priority priority_level;
    ot_bool priority_preemp;
} ot_avp_npu_mdl_config;
```

【成员】

成员名称	描述
priority_level	模型的优先级，分别为[low, medium, high]
priority_preemp	是否使能可抢占低优先级任务。默认开启。 OT_TRUE: 可抢占且打断当前正在执行的低于该模型优先级的模型任务（OMG转换时，需配置该模型可被抢占）。 OT_FALSE:不能抢占其他任务模型。

【注意事项】

若用户没有显示的调用ot_avp_npu_mdl_config,则该模型的优先级为medium, 默认使能可抢占。

版权所有 © 上海云集互联有限公司

【相关数据类型及接口】

- ot_avp_npu_mdl_priority

3.8 ot_avp_npu_mdl_priority

【说明】

描述模型优先级信息。

【定义】

```
typedef enum {
    OT_AVP_MDL_PRI_LOW,
    OT_AVP_MDL_PRI_MEDIUM,
    OT_AVP_MDL_PRI_HIGH,
} ot_avp_npu_mdl_priority;
```

【成员】

成员名称	描述
无	

【注意事项】

【相关数据类型及接口】

- ot_avp_npu_set_mdl_config

版权所有 © 上海云集互联有限公司

版权所有 © 上海云集互联有限公司

4 错误码

NPU提供的错误码如表4-1所示。

表 4-1 NPU模块错误码

错误代码	宏定义	描述
0x00000000	OT_AVP_NPU_SUCCESS	成功
0xFFFFFFFF	OT_AVP_NPU_FAILURE	失败
0xA0808003	OT_AVP_NPU_INVALID_PARAM	非法参数
0xA0808010	OT_AVP_NPU_RES_NOT_READY	资源未准备好
0xA0808004	OT_AVP_NPU_REINIT	重复初始化
0xA0808008	OT_AVP_NPU_NOT_SUPPORTED	操作不支持
0xA0808024	OT_AVP_NPU_TIMEOUT	超时

版权所有 © 上海云集互联有限公司

5 调试信息

【调试信息】
【调试信息分析】

版权所有 © 上海云集互联有限公司