

SD3589CV100 NPU AVP-QAT-Pytorch API
开发参考

文档版本　1.7.1

发布日期　2024-12-17

版权所有 © 上海云集互联有限公司

版权所有 © 上海云集互联有限公司

概述

本文档主要介绍 AVP 量化感知训练（Quantization Aware Training，QAT），及其主要接口的参考。

版本说明

与本文档相对应的产品版本如下。

产品名称	产品版本
SD3589C	V100
SD3589D	V100

用户

本文档主要适用于以下工程师：

- ✧ 技术支持工程师
- ✧ 软件工程师
- ✧ 算法工程师

修订记录

修订记录列出了各文档版本间发生的主要更改。最新版本的文档包含以前所有文档版本的更新内容。

版本	修订日期	修订说明
v1.0.0	2023.11.27	初始文档
v1.1.0	2023.12.28	新增lsq量化算法
v1.2.0	2024.2.5	支持weight 4bit量化
v1.2.1	2024.2.21	解决resume恢复训错误
V1.3.0	2024.3.27	新增PAT剪枝算法，yolov7量化示例
V1.3.1	2024.4.3	解决保存仅剪枝模型权重并载入
V1.4.0	2024.6.7	支持add/sub/mul/div/concat算子量化
V1.4.1	2024.6.13	解决模型剪枝失败
V1.5.0	2024.8.5	支持qat导出onnx模型转为板端模型

版权所有 © 上海云集互联有限公司

V1.6.0	2024.9.24	优化lsq算法初始化的赋值和耗时问题
V1.7.1	2024.12.17	修复yolov7示例

版权所有 © 上海云集互联有限公司

目录

1. 概述 1
1.1. 概述 1
1.2. 重要概念 1
2. API 参考 2
2.1. initialize 2
2.2. create_quant_model 3
2.3. enable_quantize 4
2.4. disable_quantize 4
2.5. enable_observer 4
2.6. disable_observer 5
2.7. optimize_and_initialize_model 5
2.8. export_onnx 5
2.9. set_lsq_algo_parameter 6
2.10. init_pruner_and_cal_sparsities 6
2.11. execute_pruning 7
2.12. initializing_optimizer_for_pruning 7
2.13. generate_oritek_model 8
2.14. freeze_bn 8
3. 调试信息 9

版权所有 © 上海云集互联有限公司

1. 概述

1.1. 概述

本文档主要介绍AVP中基于PyTorch的QAT的相关的量化接口及其参数信息。

1.2. 重要概念

量化模型：

量化模型指的是对模型进行量化（Quantization）处理之后得到的模型；

离线模型：

离线模型为使用NPU Toolchain生成的给板端推理使用的模型，此模型只能上板使用；

仿真模型：

仿真模型为使用NPU Toolchain生成的给仿真推理使用的模型，不能上板使用；

生成模型的过程参考《SD3589CV100 NPU工具使用指南》

版权所有 © 上海云集互联有限公司

2. API 参考

提供以下API：

- initialize：初始化QAT网络层
- create_quant_model：生成量化模型
- enable_quantize：打开量化器
- disable_quantize：关闭量化器
- enable_observer：打开数据收集器
- disable_observer：关闭数据收集器
- optimize_and_initialize_model：模型优化
- export_onnx：输出onnx模型
- set_lsq_algo_parameter：单独设置lsq量化参数学习率和衰减
- init_pruner_and_cal_sparsities：初始化剪枝器并计算稀疏率
- execute_pruning：执行剪枝
- initializing_optimizer_for_pruning：更新优化器
- generate_oritek_model：生成上板模型
- freeze_bn：冷冻batchNormal2d算子

2.1. initialize

【功能描述】

初始化QAT资源。

【语法】

【参数描述】

参数名称	描述	输入/输出
float_module_list	全精度模型列表	输入
custom_quant_modules	已量化模型列表	输入
parameters	量化配置	输入

【返回值】无

【注意事项】模型文件必须可读，并且是合法的离线模型。

parameters可以不传入，默认配置是fake quantization算法weight 8bit对称量化，input是8比特非对称量化；

Parameters具体参数配置：

params = {“output”:{"num_bits":8, "quant_alg":"lsq", "per_channel":False, "axis":0, "unsigned":False, "symmetric":True},

"weight":{"num_bits":8, "quant_alg":"lsq", "per_channel":True, "axis":0, "unsigned":False, "symmetric":True}}

quant_alg：支持算法，可选项： lsq、fake_quantization ；默认项：fake_quantization

num_bits：量化比特数，可选项4、8；默认项：无，必须填写。weight量化比特数为8或者4；input的量化比特数只能支持8；

per_channel：weight的量化方式，可选项：True、False；默认项：False

版权所有 © 上海云集互联有限公司

axis：perchannel量化维度，默认为0

unsigned：量化数据类型范围，选项：True、False；默认项：False

symmetric：对称量化，选项：True、False；默认项：True

【参考代码】无

默认配置：

quantize_tool.initialize()

fake_quantization算法8bit训练配置

params = {“output”:{"num_bits":8, "quant_alg":"fake_quantization", "per_channel":False, "axis":0, "unsigned":False, "symmetric":False},

"weight":{"num_bits":8, "quant_alg":"fake_quantization", "per_channel":True, "axis":0, "unsigned":False, "symmetric":True}}

lsq算法8bit训 per-tensor练配置

params = {“output”:{"num_bits":8, "quant_alg":"lsq", "per_channel":False, "axis":0, "unsigned":False, "symmetric":True},

"weight":{"num_bits":8, "quant_alg":"lsq", "per_channel":False, "axis":0, "unsigned":False, "symmetric":True}}

lsq算法8bit per-channel训练配置

params = {“output”:{"num_bits":8, "quant_alg":"lsq", "per_channel":False, "axis":0, "unsigned":False, "symmetric":True},

"weight":{"num_bits":8, "quant_alg":"lsq", "per_channel":True, "axis":0, "unsigned":False, "symmetric":True}}

2. 2. create_quant_model

【功能描述】

生成量化模型并初始化量化阈值。

【语法】

【参数描述】

参数名称	描述	输入/输出
origin_model	浮点模型	输入
fuse_bn	是否融合bn算子	输入
concrete_args	指定量化参数具体数值	输入
chip_type	量化平台，可选项SD3589C、SD3589A、SD3589D	输入

【返回值】无

【注意事项】无

【参考代码】

Quant_model = get_quant_model(model, fuse_bn = “True”,chip_type=” SD3589C”)

版权所有 © 上海云集互联有限公司

2.3. enable_quantize

【功能描述】

打开量化器函数，开启量化模型中所有量化算子的数据收集和量化功能。

【语法】

【参数描述】

参数名称	描述	输入/输出
quant_module	待量化的 PyTorch 模型	输入

【返回值】无

【注意事项】参数 quant_module，表示浮点PyTorch模型。

【参考代码】无

2.4. disable_quantize

【功能描述】

关闭量化器函数，开启量化模型中所有量化算子的数据收集和量化功能。

【语法】

【参数描述】

参数名称	描述	输入/输出
quant_module	待量化的 PyTorch 模型	输入

【返回值】无

【注意事项】无

【参考代码】无

2.5. enable_observer

【功能描述】

开启量化算子的数据收集功能，计算量化阈值。

【语法】

【参数描述】

参数名称	描述	输入/输出
quant_module	待量化的 PyTorch 模型	输入

【返回值】无

【注意事项】无

【参考代码】无

版权所有 © 上海云集互联有限公司

2.6. disable_observer

【功能描述】

关闭量化算子的数据收集功能。

【语法】

【参数描述】

参数名称	描述	输入/输出
quant_module	待量化的 PyTorch 模型	输入

【返回值】无

【注意事项】无

【参考代码】无

2.7. optimize_and_initialize_model

【功能描述】

用于初始化 PyTorch 模型的量化系数scale等。

【语法】

【参数描述】

参数名称	描述	输入/输出
quant_module	待优化的 PyTorch 量化模型	输入
data	data用于传递给模型进行前向传播，计算量化阈值	输入

【返回值】无

【注意事项】无

【参考代码】无

2.8. export_onnx

【功能描述】

将给定的量化模型导出为ONNX格式的文件，以便后续用于推理。可以选择是否导出参数、打印详细信息、指定输入输出名称和动态维度等。

【语法】

【参数描述】

参数名称	描述	输入/输出
quant_module	quant_module: torch.nn.Module类型，表示待量化的 PyTorch 模型	输入
args	输入模型进行推理时所需的参数。可以是一个元组或者张量	输入
f	导出的ONNX文件的路径或者文件对象，可以是字符串形式的文件路径或者io.BytesIO对象	输入

版权所有 © 上海云集互联有限公司

export_params	是否导出模型的参数。如果设为False，则只导出模型的结构	输入
verbose	表示是否打印导出过程中的详细信息	输入
input_names	模型的输入名称列表	输入
output_names	模型的输出名称列表	输入
opset_version	导出的ONNX模型所使用的运算集版本号。如果不指定，则使用默认版本号	输入
dynamic_axes	指定哪些维度是动态维度。动态维度在推理时可以改变大小。可以使用字典或者映射来指定每个输入/输出的动态维度	输入
keep_initializers_as_inputs	是否将所有初始设置器（initializers）保留为输入。如果设为False，则初始设置器将导出为常量节点。	输入

【返回值】无

【注意事项】无

【参考代码】无

2.9. set_lsq_algo_parameter

【功能描述】

lsq算法per-cahnnel量化需要单独设置lsq量化参数学习率和衰减。

【语法】

【参数描述】

参数名称	描述	输入/输出
quant_module	待优化的 PyTorch 量化模型	输入
parameters_list	模型参数	输入

【返回值】无

【注意事项】无

【参考代码】无

2.10. init_pruner_and_cal_sparsities

【功能描述】

初始化剪枝器，计算模型每层权重稀疏率和稀疏mask。

【语法】

【参数描述】

参数名称	描述	输入/输出
prune_model	待剪枝模型	输入
sparsity	总体稀疏率	输入

版权所有 © 上海云集互联有限公司

pruner	剪枝器	输入
lamp_type	计算稀疏率方式	输入

【返回值】无

【注意事项】

配置项	描述	选项
sparsity	总体稀疏率	浮点,范围[0,1)
pruner	剪枝器	level_unstructured, level_unstructured_finer ， sparse_model_processer
lamp-type	计算稀疏率方式	None, lamp, l1norm, l2norm, l1norm_local

【参考代码】无

2.11. execute_pruning

【功能描述】

在一次前向传播中执行剪枝。

【语法】

【参数描述】

参数名称	描述	输入/输出
prune_model	待剪枝模型	输入
data	模型输入	输入

【返回值】无

【注意事项】无

【参考代码】无

2.12. initializing_optimizer_for_pruning

【功能描述】

重构优化器权重梯度更新函数step(),确保训练过程中被剪枝的权重梯度与数值都为0。

【语法】

【参数描述】

参数名称	描述	输入/输出
Optimizer	优化器	输入

【返回值】无

【注意事项】无

【参考代码】无

版权所有 © 上海云集互联有限公司

2.13. generate_oritek_model

【功能描述】

将qat重训导出的onnx转换为板端模型。

【语法】

【参数描述】

参数名称	描述	输入/输出
omg	Npu_tool_chain/omg二进制转换文件	输入
model	Qat重训的onnx模型	输入
config	量化配置	输入
output_model	输出模型路径	输入
log_level	输出日志级别	输入
output_model_type	输出模型类型	输入
target	对应平台	输入

【返回值】无

【注意事项】无

【参考代码】无

2.14. freeze_bn

【功能描述】

Qat重训过程中，针对bn融合情况，在训练第五个epoch冷冻bn2d算子

【语法】

【参数描述】

参数名称	描述	输入/输出
quant_module	待优化的 PyTorch 量化模型	输入

【返回值】无

【注意事项】针对mobilenet_v2 4bit训练有效

【参考代码】无

版权所有 © 上海云集互联有限公司

3. 调试信息

【调试信息】

【调试信息分析】

版权所有 © 上海云集互联有限公司