

SD3589CV100 NPU 自定义CPU算子 API
开发参考

文档版本　V1.5

发布日期　2024-6-7

版权所有 © 上海云集互联有限公司

概述

本文档主要介绍自定义CPU算子的API接口使用。

版本说明

与本文档相对应的产品版本如下。

产品名称	产品版本
SD3589C	V100
SD3589D	V100

用户

本文档主要适用于以下工程师：

- 技术支持工程师
- 软件工程师
- 算法工程师

修订记录

修订记录列出了各文档版本间发生的主要更改。最新版本的文档包含以前所有文档版本的更新内容。

版本	修订日期	修订说明
v1.2	2023.11.25	首个自定义CPU算子API接口文档
v1.5	2024.6.7	更新API接口

版权所有 © 上海云集互联有限公司

目录

1 概述 1
1.1 概述 1
1.2 重要概念 1
2 API 参考 2
2.1 ot_avp_custom_get_input_num 2
2.2 ot_avp_custom_get_input_shape_by_index 3
2.3 ot_avp_custom_get_input_dtype_by_index 3
2.4 ot_avp_custom_get_input_format_by_index 4
2.5 ot_avp_custom_get_input_buf_by_index 4
2.6 ot_avp_custom_get_input_buf_len_by_index 5
2.7 ot_avp_custom_get_output_num 5
2.8 ot_avp_custom_get_output_shape_by_index 6
2.9 ot_avp_custom_get_output_dtype_by_index 6
2.10 ot_avp_custom_get_output_format_by_index 7
2.11 ot_avp_custom_get_output_buf_by_index 7
2.12 ot_avp_custom_get_output_buf_len_by_index 8
2.13 ot_avp_custom_set_input_shape_by_index 8
2.14 ot_avp_custom_set_input_dtype_by_index 9
2.15 ot_avp_custom_set_input_format_by_index 9
2.16 ot_avp_custom_set_output_shape_by_index 10
2.17 ot_avp_custom_set_output_dtype_by_index 10
2.18 ot_avp_custom_set_output_format_by_index 11
2.19 ot_avp_custom_get_attr_by_name 11
2.20 ot_avp_custom_get_attr_dtype 12
2.21 ot_avp_custom_get_attr_float 12
2.22 ot_avp_custom_get_attr_floats_size 13
2.23 ot_avp_custom_get_attr_floats_by_index 13
2.24 ot_avp_custom_get_attr_int 14
2.25 ot_avp_custom_get_attr_ints_size 14
2.26 ot_avp_custom_get_attr_ints_by_index 15
2.27 ot_avp_custom_get_attr_string 15
3 数据类型 17
3.1 ot_avp_npu_shape 17
3.2 ot_avp_npu_dformat 17
3.3 ot_avp_data_type 18
3.4 ot_avp_attr_type 18
4 错误码 20
5 调试信息 21

版权所有 © 上海云集互联有限公司

1 概述

1.1 概述

NPU是NN模型推理的加速器。自定义CPU算子是当用户遇到内置算子不满足需求时，自定义CPU算子和函数实现，以满足需求。本文档主要描述在编写CPU算子所需的接口。

1.2 重要概念

离线模型：

离线模型为使用NPU Toolchain生成的给板端推理使用的模型，此模型只能上板使用；

仿真模型：

仿真模型为使用NPU Toolchain生成的给仿真推理使用的模型，不能上板使用；

版权所有 © 上海云集互联有限公司

2 API 参考

提供以下API：

- ot_avp_custom_get_input_num：获取算子的输入个数
- ot_avp_custom_get_input_shape_by_index：通过输入索引获取shape
- ot_avp_custom_get_input_dtype_by_index：通过输入索引获取data_type
- ot_avp_custom_get_input_format_by_index：通过输入索引获取data_format
- ot_avp_custom_get_input_buf_by_index：通过输入索引获取data buffer
- ot_avp_custom_get_input_buf_len_by_index：通过输入索引获取buffer长度
- ot_avp_custom_get_output_num：获取算子的输出个数
- ot_avp_custom_get_output_shape_by_index：通过输出索引获取shape
- ot_avp_custom_get_output_dtype_by_index：通过输出索引获取data_type
- ot_avp_custom_get_output_format_by_index：通过输出索引获取data_format
- ot_avp_custom_get_output_buf_by_index：通过输出索引获取data buffer
- ot_avp_custom_get_output_buf_len_by_index：通过输出索引获取buffer长度
- ot_avp_custom_set_input_shape_by_index：通过输入索引设置shape
- ot_avp_custom_set_input_dtype_by_index：通过输入索引设置data_type
- ot_avp_custom_set_input_format_by_index：通过输入索引设置data_format
- ot_avp_custom_set_output_shape_by_index：通过输出索引设置data shape
- ot_avp_custom_set_output_dtype_by_index：通过输出索引设置data type
- ot_avp_custom_set_output_format_by_index：通过输出索引设置data format
- ot_avp_custom_get_attr_by_name：通过名称获取算子属性
- ot_avp_custom_get_attr_dtype：获取属性的data type
- ot_avp_custom_get_attr_float：获取float属性的值
- ot_avp_custom_get_attr_floats_size：获取floats属性的数组长度
- ot_avp_custom_get_attr_floats_by_index：通过索引获取floats属性数组的值
- ot_avp_custom_get_attr_int：获取int属性的值
- ot_avp_custom_get_attr_ints_size：获取ints属性的数组长度
- ot_avp_custom_get_attr_ints_by_index：通过索引获取ints属性数组的值
- ot_avp_custom_get_attr_string：获取string属性的值

2.1 ot_avp_custom_get_input_num

【功能描述】

获取算子的输入个数。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	算子handle，设置和获取CPU算子信息需要用到	输入
tensor_num	算子的输入个数	输出

版权所有 © 上海云集互联有限公司

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功
OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法配置参数

【注意事项】无

【参考代码】无

2.2 ot_avp_custom_get_input_shape_by_index

【功能描述】

根据输入索引，获取第index个输入的shape信息。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	算子handle	输入
index	需要获取输入的索引号	输入
shape	ot_avp_npu_shape信息	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功
OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法配置参数

【注意事项】无

【参考代码】无

2.3 ot_avp_custom_get_input_dtype_by_index

【功能描述】

根据输入索引，获取第index个输入的dtype信息。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	算子handle	输入
index	需要获取输入的索引号	输入
dtype	ot_avp_npu_dtype信息	输出

版权所有 © 上海云集互联有限公司

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功
OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.4 ot_avp_custom_get_input_format_by_index

【功能描述】

根据输入索引，获取第index个输入的data format。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	算子handle	输入
index	需要获取输入的索引号	输入
format	ot_avp_npu_dformat信息	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功
OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.5 ot_avp_custom_get_input_buf_by_index

【功能描述】

根据输入索引，获取第index个输入的buffer。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	算子handle	输入
index	需要获取输入的索引号	输入

【返回值】

版权所有 © 上海云集互联有限公司

返回值	描述
ot_u8*	第index个输入的data buffer

【注意事项】无

【参考代码】无

2.6 ot_avp_custom_get_input_buf_len_by_index

【功能描述】

根据输入索引，获取第index个输入的buffer长度。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	算子handle	输入
index	需要获取输入的索引号	输入
buf_len	buffer长度	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功
OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.7 ot_avp_custom_get_output_num

【功能描述】

获取算子的输出个数。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	算子handle	输入
tensor_num	算子的输出个数	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功
OT_AVP_NPU_FAILURE	失败

版权所有 © 上海云集互联有限公司

OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.8 ot_avp_custom_get_output_shape_by_index

【功能描述】

根据输出索引，获取第index个输出的shape。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	算子handle	输入
index	需要获取输出的索引号	输入
shape	ot_avp_npu_shape信息	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功
OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.9 ot_avp_custom_get_output_dtype_by_index

【功能描述】

根据输出索引，获取第index个输出的data type。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	算子handle	输入
index	需要获取输出的索引号	输入
dtype	ot_avp_npu_dtype信息	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功

版权所有 © 上海云集互联有限公司

OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.10 ot_avp_custom_get_output_format_by_index

【功能描述】

根据输出索引，获取第index个输出的data format。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	算子handle	输入
index	需要获取输出的索引号	输入
format	ot_avp_npu_dformat信息	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功
OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.11 ot_avp_custom_get_output_buf_by_index

【功能描述】

根据输出索引，获取第index个输出的buffer。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	算子handle	输入
index	需要获取输出的索引号	输入

【返回值】

返回值	描述

版权所有 © 上海云集互联有限公司

ot_u8*	第index个输出的buffer

【注意事项】无

【参考代码】无

2.12 ot_avp_custom_get_output_buf_len_by_index

【功能描述】

根据输出索引，获取第index个buffer的长度。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	算子handle	输入
index	需要获取输出的索引号	输入
buf_len	buffer的长度	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功
OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.13 ot_avp_custom_set_input_shape_by_index

【功能描述】

通过输入索引，设置第index个输入的shape。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	算子handle	输入
index	需要设置输入的索引号	输入
shape	设置shape的信息	输入

【返回值】

返回值	描述

版权所有 © 上海云集互联有限公司

OT_AVP_NPU_SUCCESS	成功
OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.14 ot_avp_custom_set_input_dtype_by_index

【功能描述】

通过输入索引，设置第index个输入的data type。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	算子handle	输入
index	需要设置输入的索引号	输入
dtype	设置ot_avp_data_type信息	输入

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功
OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.15 ot_avp_custom_set_input_format_by_index

【功能描述】

通过输入索引，设置第index个输入的data format。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	算子handle	输入
index	需要设置输入的索引号	输入
format	设置ot_avp_npu_dformat信息	输入

【返回值】

版权所有 © 上海云集互联有限公司

返回值	描述
OT_AVP_NPU_SUCCESS	成功
OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.16 ot_avp_custom_set_output_shape_by_index

【功能描述】

根据输出索引，设置第index个输出的shape。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	算子handle	输入
index	需要设置输出的索引号	输入
shape	ot_avp_npu_shape信息	输入

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功
OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.17 ot_avp_custom_set_output_dtype_by_index

【功能描述】

根据输出索引，设置第index个输出的data type。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	算子handle	输入
index	需要设置输出的索引号	输入
dtype	ot_avp_data_type信息	输入

版权所有 © 上海云集互联有限公司

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功
OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.18 ot_avp_custom_set_output_format_by_index

【功能描述】

根据输出索引，设置第index个输出data format。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	算子handle	输入
index	需要设置输出的索引号	输入
format	ot_avp_npu_dformat信息	输入

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功
OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.19 ot_avp_custom_get_attr_by_name

【功能描述】

根据名称获取算子的属性信息。

【语法】

【参数描述】

参数名称	描述	输入/输出
handle	算子handle	输入

版权所有 © 上海云集互联有限公司

name	算子属性的名称	输入
name_len	名称的长度	输入

【返回值】

返回值	描述
ot_avp_attr*	返回算子属性信息

【注意事项】无

【参考代码】无

2.20 ot_avp_custom_get_attr_dtype

【功能描述】

根据属性信息获取属性data type。

【语法】

【参数描述】

参数名称	描述	输入/输出
attr	属性信息	输入
dtype	属性的data type	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功
OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】无

【参考代码】无

2.21 ot_avp_custom_get_attr_float

【功能描述】

当属性是float类型时，获取float属性的值。

【语法】

【参数描述】

参数名称	描述	输入/输出
attr	属性信息	输入
value	float属性的值	输出

【返回值】

返回值	描述

版权所有 © 上海云集互联有限公司

OT_AVP_NPU_SUCCESS	加成功
OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】只能传入OT_AVP_ATTR_FLOAT的属性。

【参考代码】无

2.22 ot_avp_custom_get_attr_floats_size

【功能描述】

当属性是floats数组时，获取float数组的大小。

【语法】

【参数描述】

参数名称	描述	输入/输出
attr	属性信息	输入
size	float数组的大小	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功
OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】只能传入OT_AVP_ATTR_FLOATS的属性。

【参考代码】无

2.23 ot_avp_custom_get_attr_floats_by_index

【功能描述】

根据索引，获取float数组中第index个数的值。

【语法】

【参数描述】

参数名称	描述	输入/输出
attr	属性信息	输入
index	索引号	输入
value	数组中第index个数的值	输出

【返回值】

返回值	描述

版权所有 © 上海云集互联有限公司

OT_AVP_NPU_SUCCESS	成功
OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】只能传入OT_AVP_ATTR_FLOATS的属性。

【参考代码】无

2.24 ot_avp_custom_get_attr_int

【功能描述】

当属性是int类型时，获取属性的值。

【语法】

【参数描述】

参数名称	描述	输入/输出
attr	属性信息	输入
value	int属性的值	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功
OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】只能传入OT_AVP_ATTR_INT的属性。

【参考代码】无

2.25 ot_avp_custom_get_attr_ints_size

【功能描述】

当属性是int数组类型时，获取数组的大小。

【语法】

【参数描述】

参数名称	描述	输入/输出
attr	属性信息	输入
size	int数组的大小	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功

版权所有 © 上海云集互联有限公司

OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】只能传入OT_AVP_ATTR_INTS的属性。

【参考代码】无

2.26 ot_avp_custom_get_attr_ints_by_index

【功能描述】

根据索引号，获取int数组中第index个值。

【语法】

【参数描述】

参数名称	描述	输入/输出
attr	属性信息	输入
index	输出index	输入

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功
OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】只能传入OT_AVP_ATTR_INTS的属性。

【参考代码】无

2.27 ot_avp_custom_get_attr_string

【功能描述】

当属性是string类型时，获取属性的值。

【语法】

【参数描述】

参数名称	描述	输入/输出
attr	属性信息	输入
array	char数组，用来保存返回的字符串	输出
array_len	字符串的长度	输出

【返回值】

返回值	描述
OT_AVP_NPU_SUCCESS	成功

版权所有 © 上海云集互联有限公司

OT_AVP_NPU_FAILURE	失败
OT_AVP_NPU_INVALID_PARAM	非法参数

【注意事项】只能传入OT_AVP_ATTR_STR的属性。

【参考代码】无

版权所有 © 上海云集互联有限公司

3 数据类型

3.1 ot_avp_npu_shape

【说明】

描述shape信息。

【定义】

```
typedef struct {
    ot_s32 dims[16];
    ot_u8 dim_size;
} ot_avp_npu_shape;
```

【成员】

成员名称	描述
dims[16]	各维度的大小。
dim_size	维度的个数。

【注意事项】

【相关数据类型及接口】

- ot_avp_custom_get_input_shape_by_index
- ot_avp_custom_get_output_shape_by_index

3.2 ot_avp_npu_dformat

【说明】

描述format信息。

【定义】

```
typedef enum {
    OT_AVP_DF_NCHW,
    OT_AVP_DF_NHWC,
    OT_AVP_DF_ND,
    OT_AVP_DF_NCD,
    OT_AVP_DF_ANY,
} ot_avp_npu_dformat;
```

【成员】

成员名称	描述
无	

【注意事项】

【相关数据类型及接口】

版权所有 © 上海云集互联有限公司

- ot_avp_custom_get_input_format_by_index
- ot_avp_custom_get_output_format_by_index

3.3 ot_avp_data_type

【说明】

描述data type信息。

【定义】

```
typedef enum {
    OT_AVP_DTYPE_F32 = 0,
    OT_AVP_DTYPE_F64,
    OT_AVP_DTYPE_INT8,
    OT_AVP_DTYPE_INT16,
    OT_AVP_DTYPE_INT32,
    OT_AVP_DTYPE_INT64,
    OT_AVP_DTYPE_UINT8,
    OT_AVP_DTYPE_UINT16,
    OT_AVP_DTYPE_UINT32,
    OT_AVP_DTYPE_UINT64,
    OT_AVP_DTYPE_F16,
    OT_AVP_DTYPE_INT4,
    OT_AVP_DTYPE_UINT4,
    OT_AVP_DTYPE_BOOL,
    OT_AVP_DTYPE_BUTT
} ot_avp_data_type;
```

【成员】

成员名称	描述
无	

【注意事项】

【相关数据类型及接口】

- ot_avp_custom_get_input_dtype_by_index
- ot_avp_custom_get_output_dtype_by_index

3.4 ot_avp_attr_type

【说明】

描述属性的数据类型

【定义】

版权所有 © 上海云集互联有限公司

```
typedef enum {
    OT_AVP_ATTR_INT = 0,    // INT
    OT_AVP_ATTR_INTS,       // INTS数组
    OT_AVP_ATTR_FLOAT,      // FLOAT
    OT_AVP_ATTR_FLOATS,     // FLOAT数组
    OT_AVP_ATTR_STR,
} ot_avp_attr_type;
```

【成员】

成员名称	描述
无	

【注意事项】

版权所有 © 上海云集互联有限公司

4 错误码

NPU提供的错误码如**表4-1**所示。

表 4-1 NPU模块错误码

错误代码	宏定义	描述
0x00000000	OT_AVP_NPU_SUCCESS	成功
0xFFFFFFFF	OT_AVP_NPU_FAILURE	失败
0xA0808003	OT_AVP_NPU_INVALID_PARAM	非法参数
0xA0808010	OT_AVP_NPU_RES_NOT_READY	资源未准备好
0xA0808004	OT_AVP_NPU_REINIT	重复初始化
0xA0808008	OT_AVP_NPU_NOT_SUPPORTED	操作不支持
0xA0808024	OT_AVP_NPU_TIMEOUT	超时

版权所有 © 上海云集互联有限公司

5 调试信息

【调试信息】
【调试信息分析】

版权所有 © 上海云集互联有限公司