

SD3589CV100 NPU Studio工具使用指南

文档版本　　V1.3.5

发布日期　　2025-02-11

前 言

概述

本文档主要介绍NPU Studio工具的使用方法，目的是帮助NPU Studio工具的使用者更好地使用NPU Studio工具提供的工具能力。

版本说明

与本文档相对应的产品版本如下。

产品名称	产品版本
SD3589C	V100
SD3589D	V100

读者对象

本文档(本指南)主要适用于以下工程师：

技术支持工程师

软件开发工程师

修订记录

修订记录包括每次文档更新的说明，最新版本的文档包含以前所有文档的版本更新内容。

修订日期	版本	修订说明
2023-10-19	V1.0.0	第一次版本发布
2023-11-25	V1.1.0	增添NPU Studio1.1.2版本新增和修改内容的描述
2023-11-29	V1.1.1	更新了对于NPU工具链路径配置的说明

版权所有 © 上海云集互联有限公司

2023-12-27	V1.1.2	更新了对于仿真模拟模块的说明
2024-03-27	V1.1.3	更新了对于性能仿真模块的说明
2024-06-07	V1.2.0	重修订文档适配支持工程管理的工具说明，更新了对于板端性能模块和性能仿真模块的说明
2024-08-01	V1.3.0	重修订文档适配VSCode插件版本的NPU Studio的工具说明
2024-08-14	V1.3.1	调整部分已知问题的说明
2024-09-24	V1.3.2	增加对于代码编译的说明
2024-11-05	V1.3.3	重新修订文档格式
2024-11-28	V1.3.4	增加对于仿真模拟模块多输入的说明
2025-02-11	V1.3.5	增加对于伪量化模块的说明

版权所有 © 上海云集互联有限公司

目 录

前 言 i
目 录 iii
插图目录 iv
1. 工具简介 1
1.1. 简介 1
2. NPU Studio工具使用 1
2.1. 工具环境准备 1
2.2. 工具安装 1
2.3. 工具运行 2
3. 工具界面介绍 2
4. NPU Studio工具功能介绍 3
4.1. 模型转换功能 4
4.2. 伪量化功能 6
4.3. 仿真模拟功能 7
4.4. 精度比对功能 8
4.5. 模型量化功能 10
4.6. 模型可视化功能 11
4.7. 性能仿真功能 12
4.8. 板端性能功能 12
4.9. 代码编译功能 13
5. 常见问题参考(FAQ) 15
5.1. 在内嵌的Netron中打开了模型的情况下，打开其他不同格式的模型，会导致报错 15
5.2. 在使用以//开始的网络地址创建工程或打开工程，保存或打开文件时，会因无法访问网络地址而无法正常工作 15
5.3. 在云桌面或类似环境下运行时，会无法执行模型转换 15
5.4. 在极罕见的情况可能发生NPU Studio的活动栏展开面板不显示内容 15

版权所有 © 上海云集互联有限公司

插图目录

图表 3-1 主界面.....3
图表 3-2 新建项目资源管理器.....3
图表 4-1 输入输出配置.....4
图表 4-2 量化配置1.....5
图表 4-3 量化配置2.....5
图表 4-4 执行转换.....6
图表 4-5 伪量化.....7
图表 4-6 仿真模拟.....8
图表 4-7 精度比对.....8
图表 4-8 精度比对结果.....9
图表 4-9 单项精度比对.....9
图表 4-10 模型量化.....10
图表 4-11 加载与展开.....10
图表 4-12 热力图.....11
图表 4-13 子图.....11
图表 4-14 性能仿真.....12
图表 4-15 板端性能.....13
图表 4-16 生成Makefile.....14
图表 4-17 编译Simulator.....14

版权所有 © 上海云集互联有限公司

1. 工具简介

1.1. 简介

NPU Studio 工具总体是完成ORTM模型转换和性能校验的基本功能和方法，包括模型转换、伪量化、仿真模拟、精度对比、模型量化、模型可视化、性能仿真、板端性能及代码编译。

2. NPU Studio 工具使用

2.1. 工具环境准备

1）本工具运行于Windows 10 (64位)或Windows 11 (64位) 操作系统上；

2）本工具依赖于Visual Studio Code，请确保已安装且版本不低于1.89.0

3）本工具依赖以下：

cmake version 3.29.0-rc1及以上

https://github.com/Kitware/CMake/releases/download/v3.31.0-rc2/cmake-3.31.0-rc2-windows-x86_64.msi

GNU Make 4.4.1及以上

https://github.com/Vuniverse0/mingwInstaller/releases/download/1.2.1/mingwInstaller.exe

2.2. 工具安装

2.2.1工具安装步骤

1.安装步骤：

Windows:

打开Visual Studio Code，在左侧活动栏选择“扩展”，

在扩展面板右上角“视图和更多操作…”中选择“从VSIX安装…”，选择NPU Studio VSIX扩展文件来安装插件。

Linux:

通过VSCode连接至Linux主机后，在已连接的VSCode窗口中选择左侧活动栏中的“扩展”，

在扩展面板中点击“本地-已安装”分栏中找到NPU Studio VSIX，点击下方“在（远程主机名）安装”按钮，将其安装到远程主机。

版权所有 © 上海云集互联有限公司

2.3. 工具运行

安装完成后工具随Visual Studio Code的启动自动运行。

3. 工具界面介绍

打开Visual Studio Code后点击左侧活动栏中的NPU Studio分栏，进入工具主页面。

NPU Studio工程分栏，显示已创建的NPU Studio工程，可以单击打开工程；鼠标悬停在该分栏在分栏标题栏中显示保存工程，打开工程，新建工程按钮。

点击新建工程按钮，将会显示输入框输入工程名称，在输入合法的不包含特殊字符的工程名后，将显示工程目录选择窗口，选择工程目录后，将在选择目录下新建一个以工程名命名的文件夹作为工程文件夹，并在其中生成以npuprj为后缀的工程文件，随后打开该工程。新建工程后，该工程会出现在NPU Studio工程列表中，可供快捷打开。

点击打开工程按钮，将显示工程文件选择窗口，选择要打开的工程的npuprj工程文件后，插件将自动打开一个包含该目录的工作区。

点击保存工程按钮，插件将保存所有打开的功能模块的配置信息，如果在点击保存工程前就关闭了对应的功能模块标签页，则该功能模块的所有修改都会丢失。

功能模块分栏，显示NPU Studio提供的所有功能。点击对应的功能模块选项，能够打开对应功能模块标签页；切换目标平台选项后显示当前工程的目标平台，点击切换目标平台选项，会在上方显示选择框以供选择目标平台。

版权所有 © 上海云集互联有限公司



图表 3-1 主界面



图表 3-2 新建项目资源管理器

4. NPU Studio 工具功能介绍

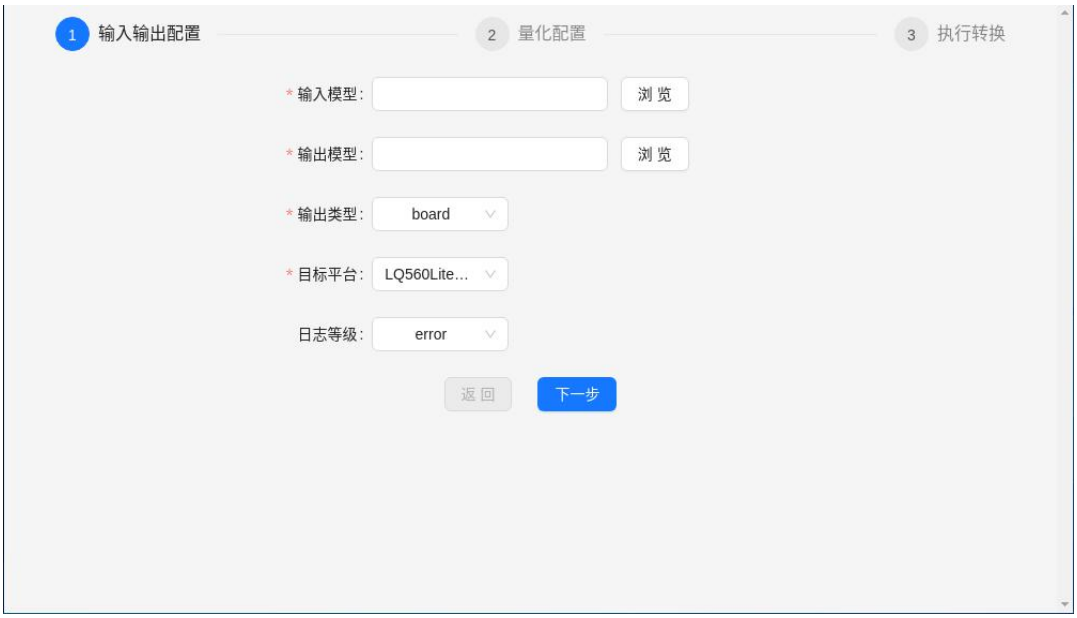
NPU Studio工具由模型转换、伪量化、仿真模拟、精度对比、模型量化、模型可视化、性能仿真、板端性能及代码编译组成。

版权所有 © 上海云集互联有限公司

4.1. 模型转换功能

1）选择模型转换工具后，需要执行三步来将onnx模型转换为ortm模型。

2）在第一步中可以设置作为输入的模型路径和将要输出保存的模型路径，输出类型可以选择输出板端模型（board）或是仿真模型（simulator），如果选择仿真模型则可以在转换完成后后续继续执行仿真模拟，目标平台可以选择要输出的模型所对应的芯片平台，可选选项受到在工具菜单栏中选择的目标平台类型影响，日志等级可以调整在转换时的最低输出等级日志。



图表 4-1 输入输出配置

3）量化配置可以调整作为yaml配置文件输入模型转换工具的量化参数。

在启用enable_dump后会同时输出量化信息到指定的dump_path中。

对于inputs中的shape，preprocess中dtc的mean和std这些参数为数组的配置项，可以点击+号来添加项，点击数组项右上角的-号可以移除该项。

点击从文件导入可以从yaml文件中导入对应配置，点击生成配置文件可以将当前配置保存到指定的路径。

在配置时需要注意calib_path中的文件路径需要为绝对路径。

版权所有 © 上海云集互联有限公司



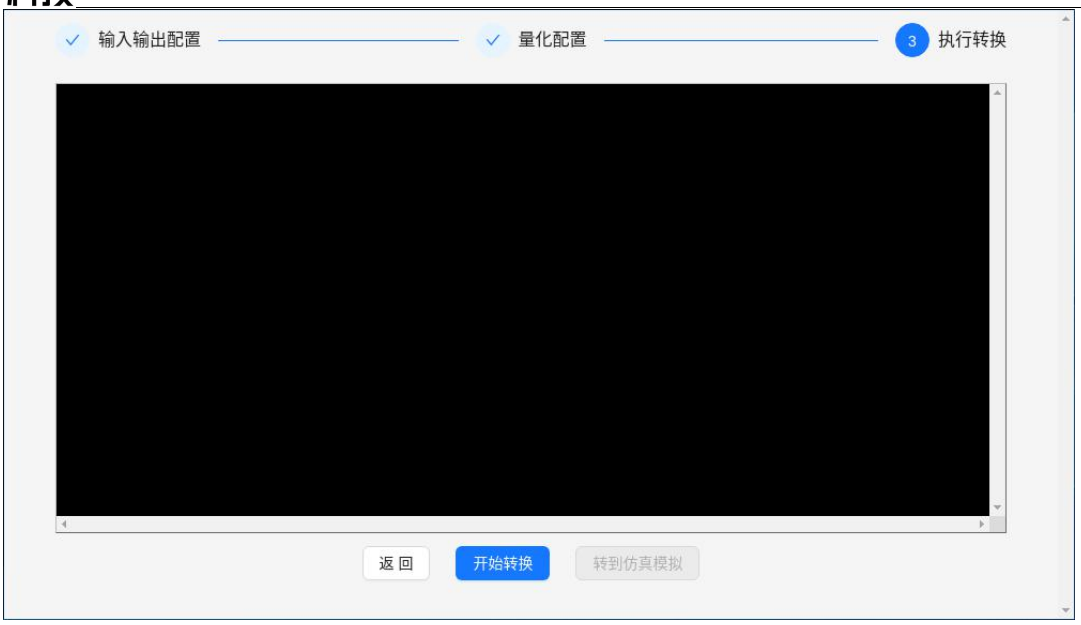
图表 4-2 量化配置1



图表 4-3 量化配置2

4）在第三步点击开始转换按钮执行转换，转换完成后转换时的日志信息会显示在中间的黑色窗口中，此时如果之前选择的输出类型为simulator，则可以点击转到仿真模拟来自动填入部分信息。

版权所有 © 上海云集互联有限公司



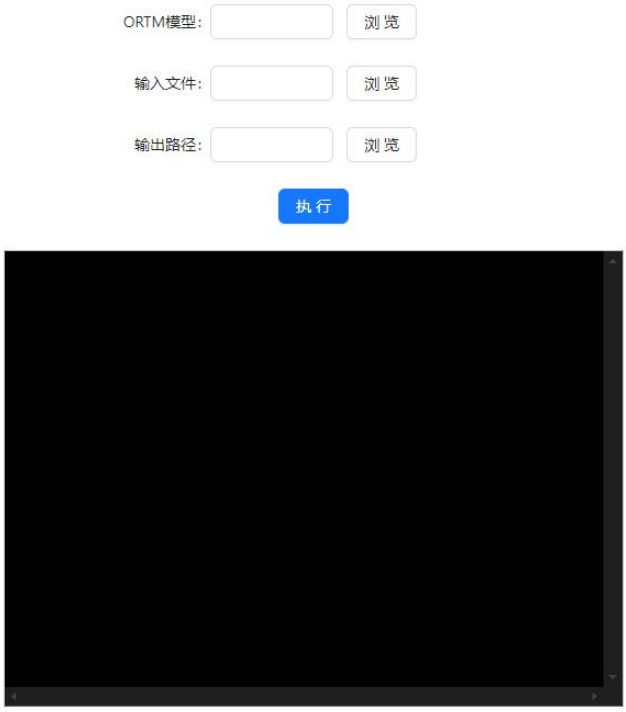
图表 4-4 执行转换

4.2. 伪量化功能

1）选择伪量化工具后，指定从模型转换功能中转换得到的fake_quant模型，选择对应的输入文件，会将结果输出到指定的输出路径中

2）在填入对应文件路径后，点击执行即可开始伪量化，下方的黑色窗口会显示运行过程中的日志，按钮会进入忙碌状态，当运行结束后，按钮就会再次亮起，此时伪量化结果会被输出到指定的输出路径。如果在运行时发生错误，则在日志窗口和右下角弹窗会显示对应错误信息。

版权所有 © 上海云集互联有限公司



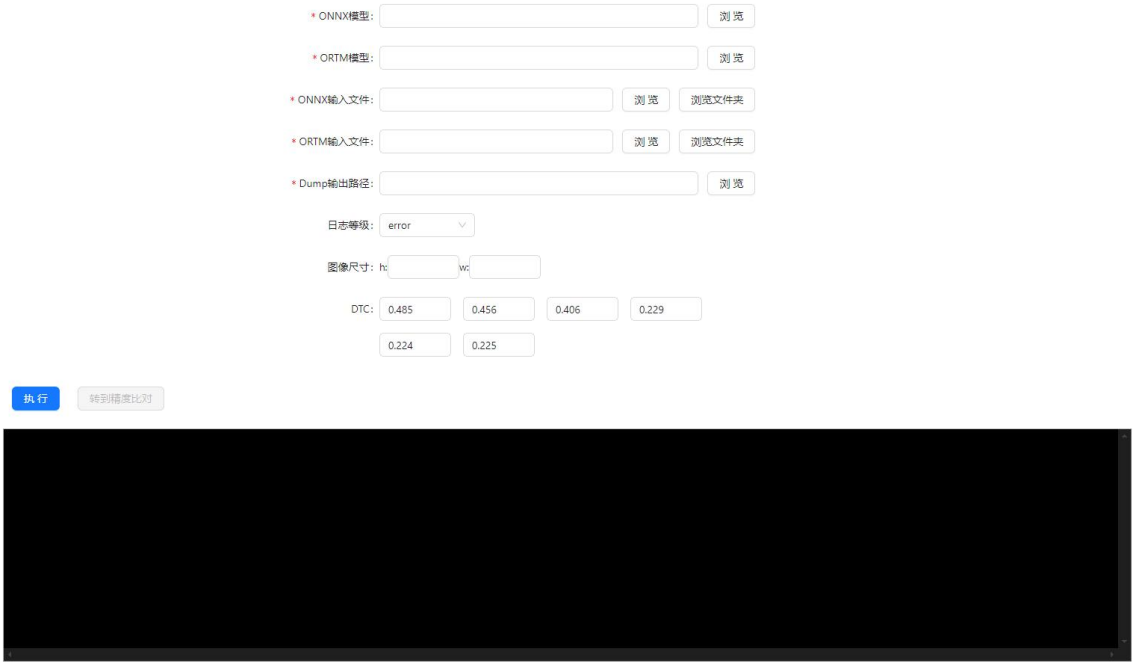
图表 4-5 伪量化

4.3. 仿真模拟功能

1）选择仿真模拟工具后，可以指定onnx模型和转换后后的ortm模型，通过指定各自的输入文件来计算出精度信息以进行比对，比对结果会输出在指定的Dump输出路径。ONNX输入文件和ORTM输入文件可以点击浏览来选择输入文件或者点击浏览文件夹来选择包含多个输入文件的文件夹。图像尺寸参数会在填入ONNX模型后自动填充，DTC参数会在从模型转换跳转时自动填充。

版权所有 © 上海云集互联有限公司

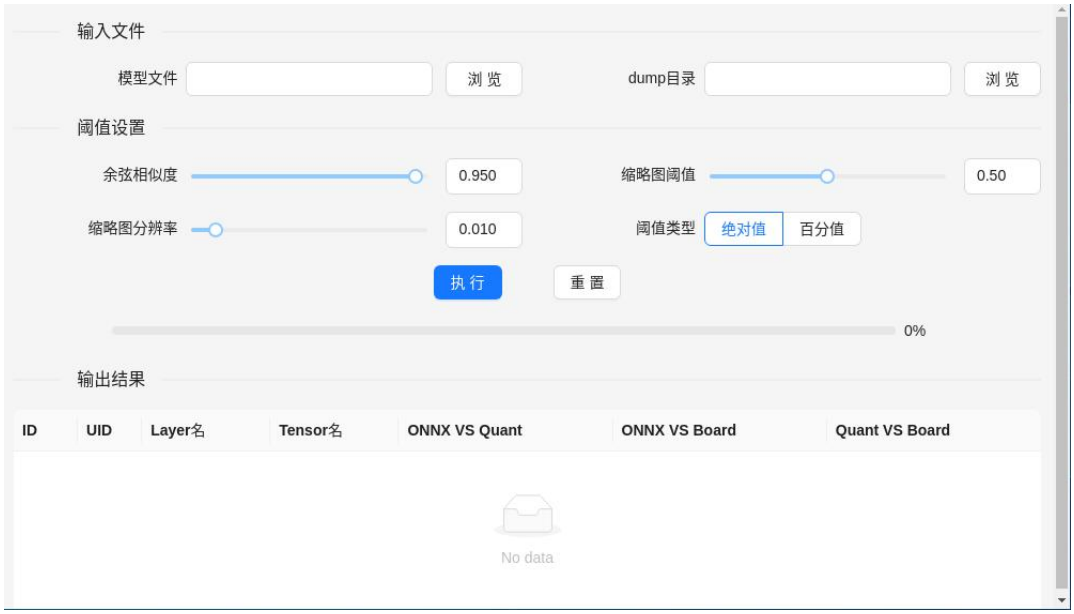
2）在填入对应文件路径后，点击执行即可开始仿真模拟，下方的黑色窗口会显示计算过程的日志，在计算完成后，转到精度比对的按钮就会亮起，点击即可转至精度比对并自动填入相关信息。



图表 4-6 仿真模拟

4.4. 精度比对功能

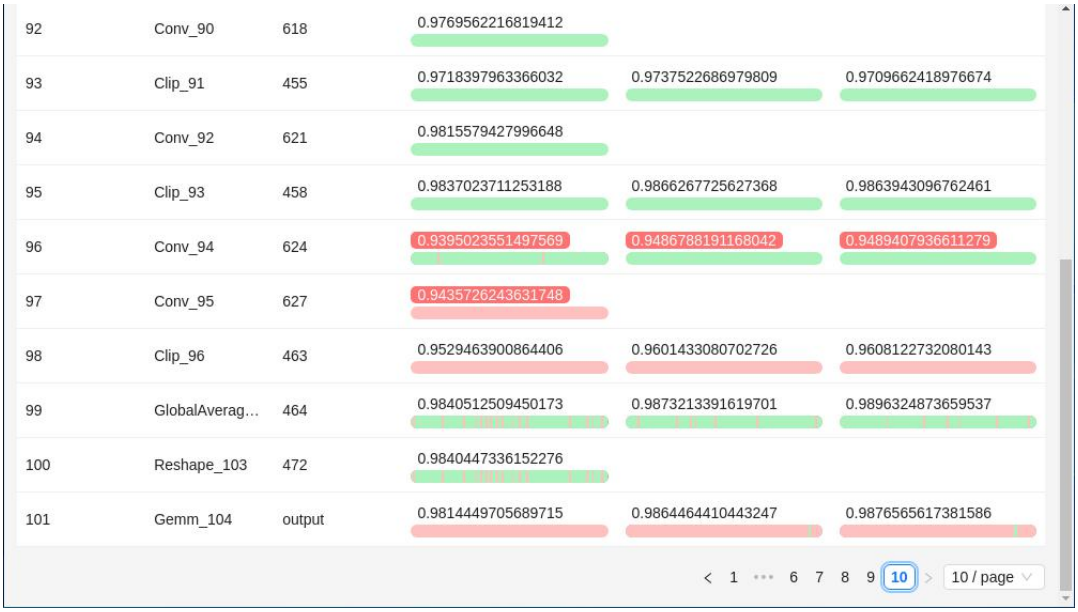
1）选择精度比对工具，可以选择模型文件和dump目录来计算对应的比对结果，余弦相似度可以调整会在输出结果中高亮标记的余弦相似度上限，缩略图阈值和阈值类型可以调整在比对缩略图中高亮标记的最小范围，缩略图分辨率则会影响缩略图中标记的最短长度。



图表 4-7 精度比对

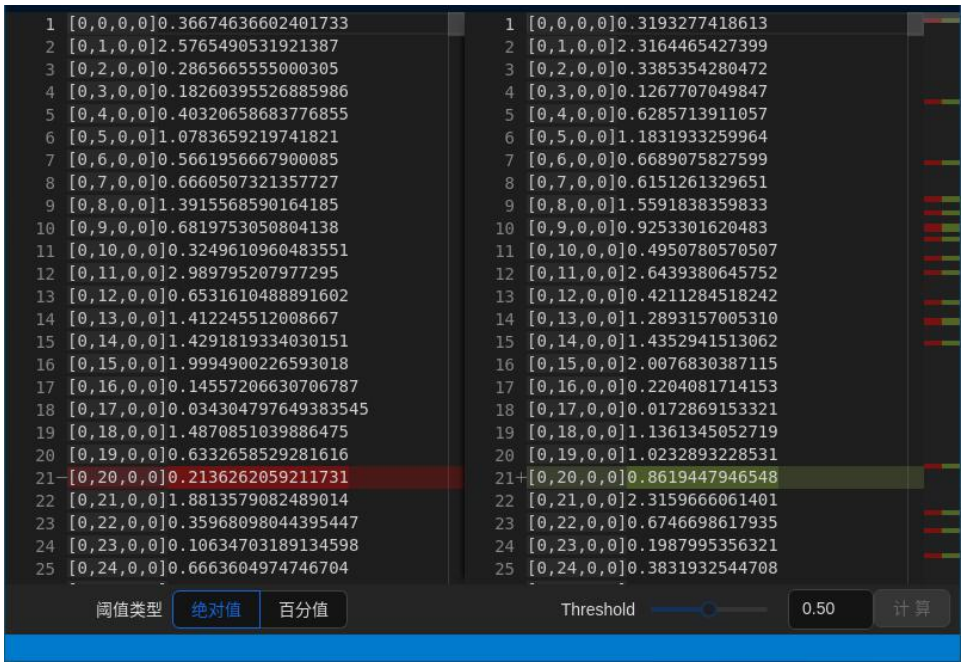
版权所有 © 上海云集互联有限公司

2）在输出结果中，计算出对应的余弦相似度会出现在表格项上方，对应文件中差异超出缩略图阈值的行会在下方缩略图中对应位置标记为红色。



图表 4-8 精度比对结果

3）点击缩略图可以打开文件比对，文件中差异超出阈值的会被高亮标记，在文件大小较小时，每一行行首会显示Shape信息，按下Tab键可以移动到下一处高亮处，按下Shift + Tab键可以移动到上一处高亮处，下方可以调整阈值类型和阈值，点击计算可以重新计算超出阈值的高亮，最下方状态栏显示左右两侧光标处的文档位置和Shape信息。

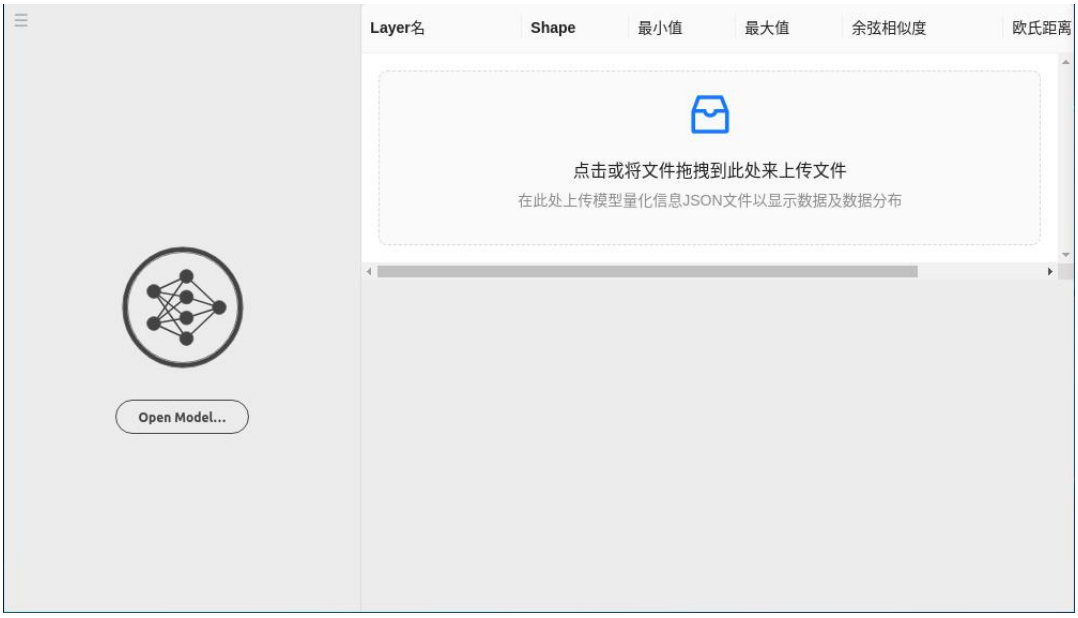


图表 4-9 单项精度比对

版权所有 © 上海云集互联有限公司

4.5. 模型量化功能

1）选择模型量化工具后，左侧显示Netron可视化视图，可以点击按钮打开模型文件，右侧为量化表格，可以点击在文件选择窗口中选择量化JSON文件或拖入量化JSON文件打开。

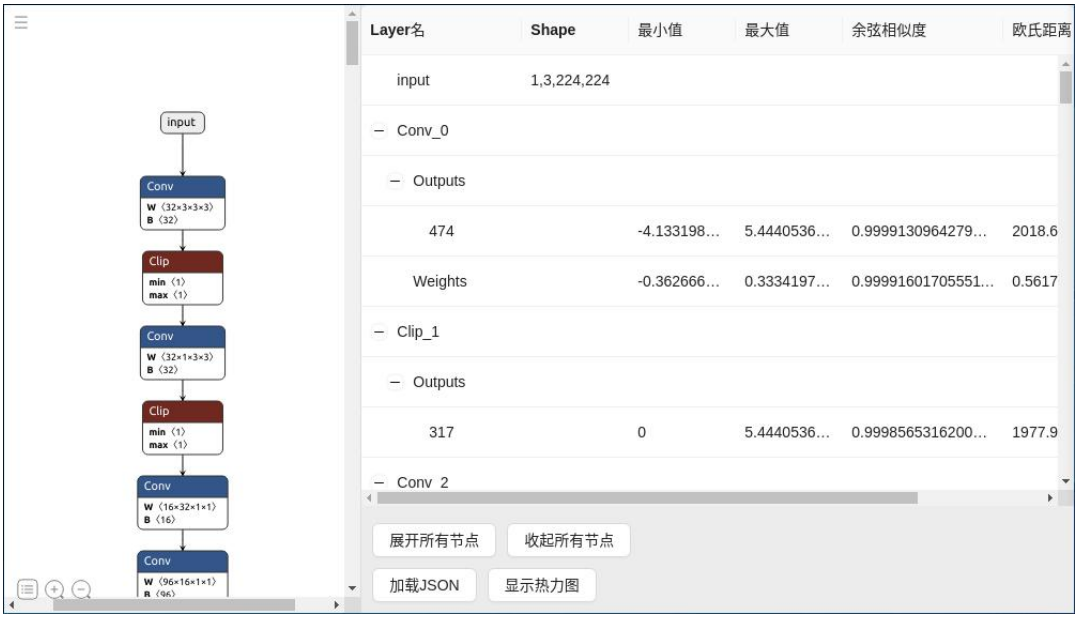


图表 4-10 模型量化

2）打开后量化表格下方出现操作选项，可以展开或收起所有节点。

点击加载JSON可以重新加载其他量化JSON文件。

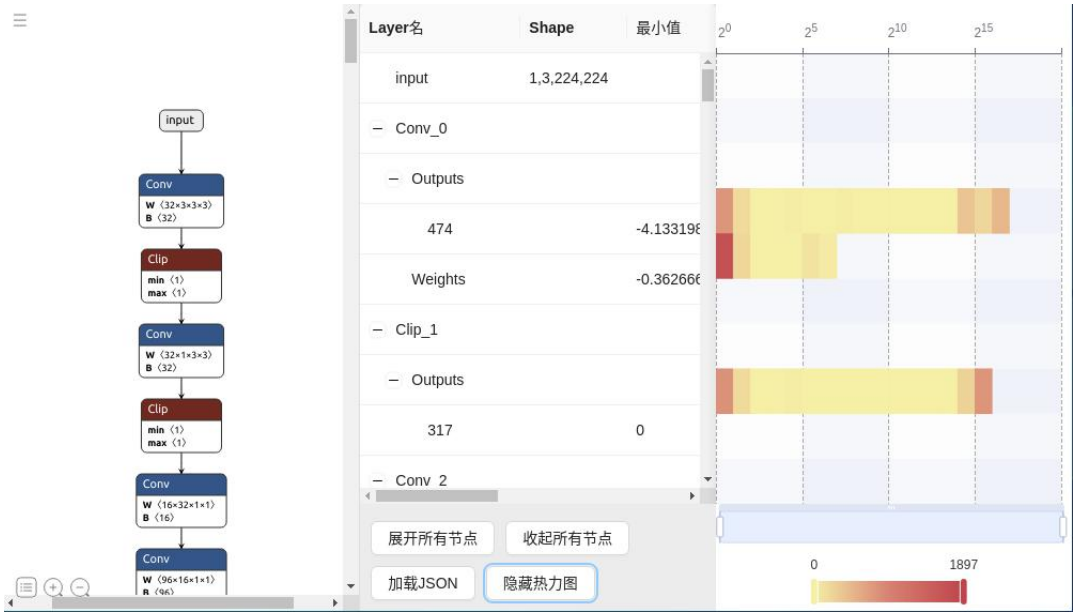
点击表格项可以高亮左侧可视化视图中对应节点，点击可视化视图中对应节点也可以跳转选中对应表格项。



图表 4-11 加载与展开

版权所有 © 上海云集互联有限公司

3）点击显示热力图可以将量化数据以热力图形式在右侧显示与表格行对应。



图表 4-12 热力图

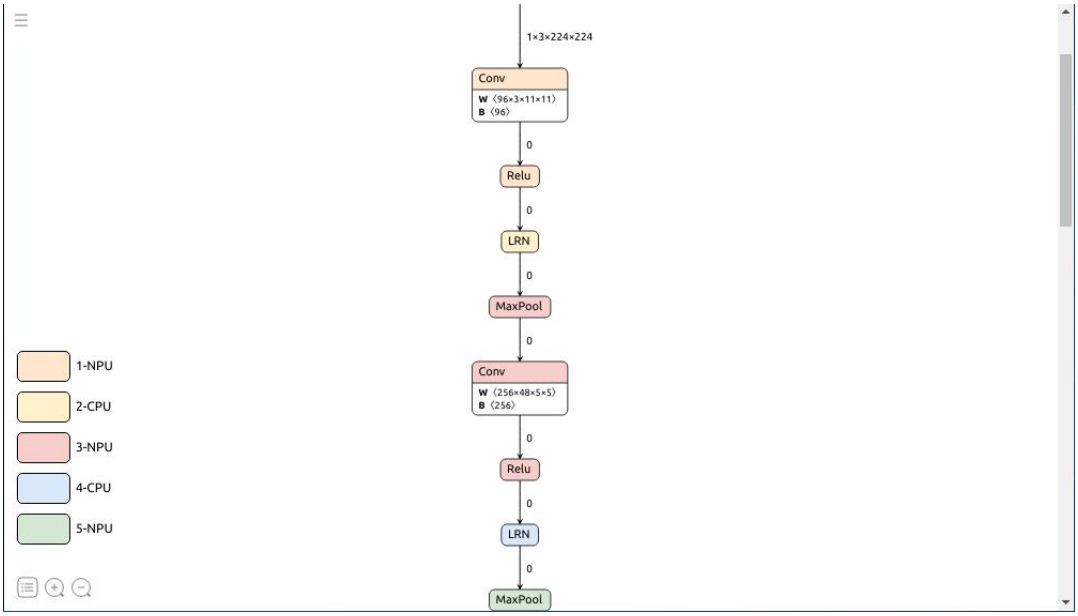
4.6. 模型可视化功能

模型可视化功能与模型量化功能中的模型可视化功能相同，但提供完整窗口来更好展示模型内容。

1）拥有多个子图的模型在导入后左下角会出现相应图例，打开模型后默认展示总图，属于不同子图的节点会被染色成相应子图图例的颜色。

2）点击图例可以切换显示对应子图，在显示某个子图的情况下，其他子图的图例会显示为灰色，以表示目前所选的子图。

3）再次点击该子图图例可以返回总图，点击其他子图可以切换显示对应子图。



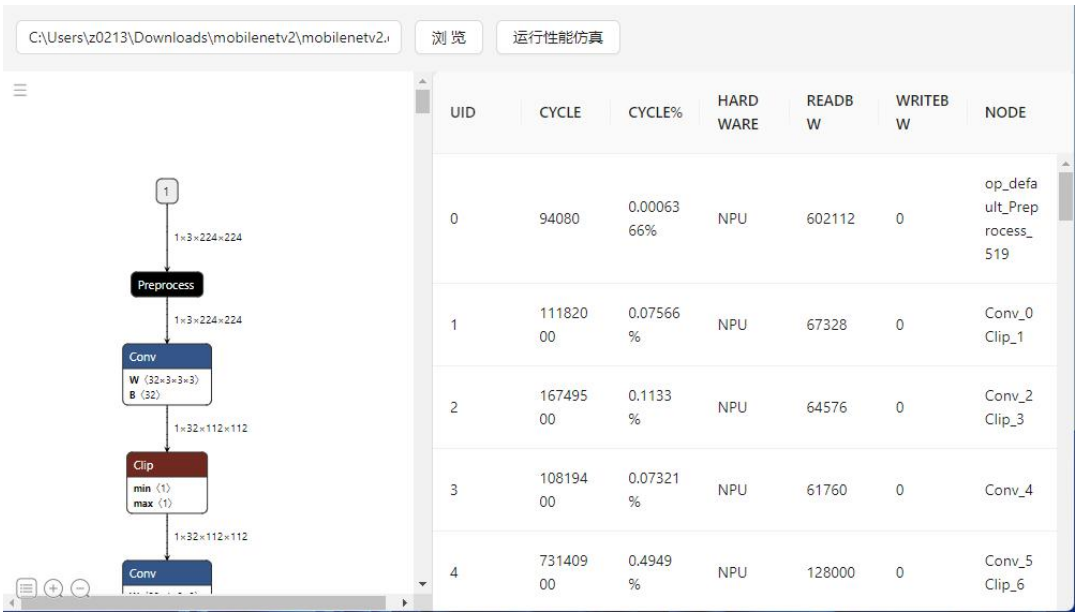
图表 4-13 子图

版权所有 © 上海云集互联有限公司

4.7. 性能仿真功能

1）选择性能仿真工具后，上部显示时间轴，左侧显示Netron可视化视图，右侧显示模型性能数据，在上方输入框中输入或选择浏览按钮选择需要进行性能仿真的ORTM模型路径，之后点击运行性能仿真，等待运行完成，上部显示各个节点在不同处理单元中的运行耗时，左侧会显示模型的结构，右侧显示性能仿真的结果。

2）点击左侧视图中的节点，右侧表格和顶部时间轴对应项会高亮，点击右侧表格项也同样会高亮左侧视图和顶部时间轴中的对应节点。



UID	CYCLE	CYCLE%	HARD WARE	READB W	WRITEB W	NODE
0	94080	0.00063 66%	NPU	602112	0	op_default_Preprocess_519
1	111820 00	0.07566 %	NPU	67328	0	Conv_0 Clip_1
2	167495 00	0.1133 %	NPU	64576	0	Conv_2 Clip_3
3	108194 00	0.07321 %	NPU	61760	0	Conv_4
4	731409 00	0.4949 %	NPU	128000	0	Conv_5 Clip_6

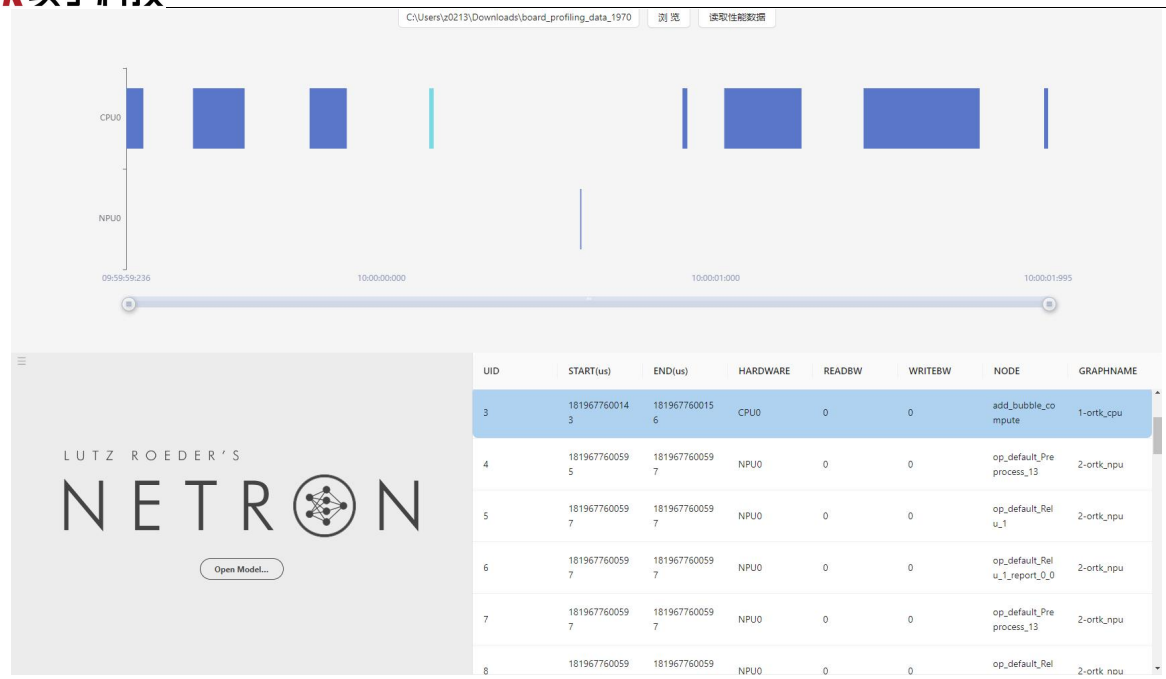
图表 4-14 性能仿真

4.8. 板端性能功能

1）选择板端性能工具后，展示界面与性能仿真基本一致，在上部输入框中输入或选择浏览板端性能文件，之后点击读取性能数据，等待运行完成，上部显示各个节点在不同处理单元中的运行耗时，左侧手动选择对应的模型文件，会显示模型的结构，右侧显示性能仿真的结果。

2）点击左侧视图中的节点，右侧表格和顶部时间轴对应项会高亮，点击右侧表格项也同样会高亮左侧视图和顶部时间轴中的对应节点。

版权所有 © 上海云集互联有限公司



图表 4-15 板端性能

4.9. 代码编译功能

1）创建新工程后，在打开的工程目录下会生成一个simulator文件夹，存放simulator的代码示例。在创建工程后会自动运行cmake来在build文件夹下生成Makefile文件

2）右键CMakeLists.txt在右键菜单中可以选择生成Makefile来在build文件夹下生成Makefile文件。右键Makefile在右键菜单中选择编译Simulator来生成可执行文件。

版权所有 © 上海云集互联有限公司



图表 4-16 生成Makefile



图表 4-17 编译Simulator

版权所有 © 上海云集互联有限公司

5. 常见问题参考(FAQ)

5.1. 在内嵌的 Netron 中打开了模型的情况下，打开其他不同格式的模型，会导致报错

可以通过关闭页面再打开解决。

5.2. 在使用以//开始的网络地址创建工程或打开工程，保存或打开文件时，会因无法访问网络地址而无法正常工作

先将网络地址映射为盘符，然后通过带盘符的路径代替网络地址来进行相同操作。

5.3. 在云桌面或类似环境下运行时，会无法执行模型转换

因环境缺失omg所需特定运行库，推荐在完整的PC环境下使用。

5.4. 在极罕见的情况可能发生 NPU Studio 的活动栏展开面板不显示内容

可以通过重新禁用启用插件或重启VSCode来解决。

版权所有 © 上海云集互联有限公司