

SD3589CV100 NPU工具使用指南

文档版本　V1.10
发布日期　2025-02-15

前 言

概述

本文档主要介绍和说明NPU工具及使用方法等。

版本说明

与本文档相对应的产品版本如下。

产品名称	产品版本
SD3589C	V100
SD3589D	V100

读者对象

本文档主要适用于以下工程师：

- 软件开发工程师、算法工程师
- 技术支持工程师

修订记录

修订记录列出了各文档版本间发生的主要更改。最新版本的文档包含以前所有文档版本的更新内容。

版本	修订日期	修订说明
V1.0	2023-06-15	初始版本
V1.1	2023-10-16	增加V1.1版本新特性说明
V1.2	2023-11-25	增加V1.2版本新特性说明，包含Roialign/InstanceNorm/MatMul/Pow/Erf/HardSigmoid/Max/Min/Mean等新算子及部分cpu算子的支持，对自定义CPU算子的支持，对高精度量化和自动混合量化的支持，对指定某些层是否量化及量化位宽的支持，用QAT工具对量化后模型进行重训的支持等。
V1.3	2023-12-29	增加v1.3版本新特性说明，包含新增CPU算子：

		averagepool,conv,convtranspose,expand,gather, maxpool, globalaveragepool, lrn,matmul,mul, pow prelu reducemax reducemean reducemin relu resize,slice softmax；新增对16bits raw输入输出的支持；新增量化对8a6w的支持；新增支持保存仿真性能文件，更新仿真sample使用方式；新增convert_data.py工具，支持对数据进行预处理。
V1.4	2024-02-05	增加v1.4版本新特性说明：支持配置中间层为模型输出；支持配置输出的顺序；支持模型输入为yuv444;支持模型输入为raw10/12;支持导入4bit模型；支持yolov5后处理硬化；支持多batch模型；新增depth2space，argmax，sum 的cpu算子；CPU/GPU推理加速
V1.5	2024-03-26	增加v1.5版本新特性说明：增加模型防止被篡改；优化samples目录结构，增加模型转换脚本；量化支持PTP/PAT
V1.6	2024-06-07	增加v1.6版本新特性说明：增加reducesum算子；修复yuv输入时预处理引入的精度问题；
V1.7	2024-08-05	增加v1.7版本新特性说明：支持csc转换矩阵配置
V1.8	2024-10-18	支持ReduceSum算子
V1.9	2024-12-17	支持根据模型信息创建输入输出dataset
V1.10	2025-02-10	补充描述GPU nvida最低支持的驱动版本号 新增量化损失评估章节 支持elu算子

目 录

前 言 iii
目 录 i
插图目录 vi
表格目录 vii
1 简介 1
2 OMG工具使用 2
2.1 环境准备 2
2.2 使用示例 3
2.3 参数说明 3
2.3.1 --help 3
2.3.2 --version 3
2.3.3 --model 3
2.3.4 --config 3
2.3.5 --output_model 15
2.3.6 --output_model_type 15
2.3.7 --log_level 15
2.3.8 --target 15
2.3.9 --strip 15
2.3.10 add_postprocess 添加目标检测后处理配置项相关例子介绍 15
云集互联 后处理使用场景说明 17
云集互联 后处理配置项常见问题说明 18
2.4 算子规格明 18
2.4.1 ONNX框架算子规格 19
2.4.1.1 Add 19
2.4.1.2 Abs 19
2.4.1.3 Argmax 20
2.4.1.4 AveragePool 20
2.4.1.5 BatchNormalization 22
2.4.1.6 Clip 22
2.4.1.7 Concat 23
2.4.1.8 Cast 23
2.4.1.9 Constant 23
2.4.1.10 ConstantOfShape 24
2.4.1.11 Conv 24
2.4.1.12 ConvTranspose 26

版权所有 © 上海云集互联有限公司

云集互联 YUNJI ECO Div.....28
云集互联 YUNJI ECO Dropout.....29
2.4.1.15 Elu.....29
2.4.1.16 Exp.....29
2.4.1.17 Erf.....30
2.4.1.18 Expand.....30
2.4.1.19 Flatten.....31
2.4.1.20 Gather.....31
2.4.1.21 Gemm.....32
2.4.1.22 GlobalAveragePool.....32
2.4.1.23 GlobalMaxPool.....32
2.4.1.24 HardSigmoid.....33
2.4.1.25 InstanceNormalization.....33
2.4.1.26 LeakyRelu.....33
2.4.1.27 Log.....34
2.4.1.28 LRN.....34
2.4.1.29 Max.....34
2.4.1.30 MaxPool.....35
2.4.1.31 Mean.....37
2.4.1.32 Min.....37
2.4.1.33 MatMul.....37
2.4.1.34 Mul.....38
2.4.1.35 Pad.....38
2.4.1.36 Pow.....39
2.4.1.37 PRelu.....40
2.4.1.38 ReduceMean.....40
2.4.1.39 ReduceMax.....40
2.4.1.40 ReduceMin.....41
2.4.1.41 ReduceSum.....41
2.4.1.42 Relu.....42
2.4.1.43 Reshape.....42
2.4.1.44 Resize.....43
2.4.1.45 RoiAlign.....45
2.4.1.46 Shape.....46
2.4.1.47 Sigmoid.....46
2.4.1.48 Slice.....46
2.4.1.49 Softmax.....47
2.4.1.50 Split.....47
2.4.1.51 Squeeze.....48
2.4.1.52 Sub.....48
2.4.1.53 Sum.....49
2.4.1.54 Tanh.....50
2.4.1.55 Transpose.....50
2.4.1.56 Unsqueeze.....51

版权所有 © 上海云集互联有限公司

2.4.1.57 Upsample..... 51
2.4.1.58 Mish..... 52
2.4.2 内置CPU算子规格..... 52
2.4.2.1 ArgMin..... 52
2.4.2.2 ArgMax..... 52
2.4.2.3 AveragePool..... 53
2.4.2.4 Cast..... 54
2.4.2.5 Ceil..... 55
2.4.2.6 Conv..... 55
2.4.2.7 ConvTranspose..... 56
2.4.2.8 DepthToSpace..... 58
2.4.2.9 Expand..... 58
2.4.2.10 Floor..... 59
2.4.2.11 Gemm..... 59
2.4.2.12 Gather..... 59
2.4.2.13 GlobalAveragePool..... 60
2.4.2.14 GlobalMaxPool..... 60
2.4.2.15 NonMaxSuppression..... 61
2.4.2.16 MatMul..... 61
2.4.2.17 MaxPool..... 61
2.4.2.18 Mean..... 63
2.4.2.19 Mul..... 63
2.4.2.20 NonZero..... 63
2.4.2.21 Pad..... 64
2.4.2.22 Resize..... 64
2.4.2.23 Pow..... 65
2.4.2.24 PRelu..... 66
2.4.2.25 Range..... 66
2.4.2.26 ReduceMean..... 66
2.4.2.27 ReduceMax..... 67
2.4.2.28 ReduceMin..... 67
2.4.2.29 Relu..... 68
2.4.2.30 Resize..... 68
2.4.2.31 Slice..... 69
2.4.2.32 Softmax..... 70
2.4.2.33 Sqrt..... 70
2.4.2.34 Sum..... 70
2.4.2.35 TopK..... 71
3 仿真工具使用..... 73
3.1 环境准备..... 73
3.2 准备demo工程..... 73
3.2.1 ortm_run_model工程..... 73
3.2.2 mobilenetv2_rgbplanar工程..... 76

版权所有 © 上海云集互联有限公司

3.2.3 tiny-yolov3_yuv420sp工程 76
3.3 配置说明 76
3.4 精度Dump 77
3.5 导出性能数据 77
4 量化损失评估 78
4.1 环境准备 78
4.2 oritek_graph_runner工具参数说明 78
4.3 伪量化精度评估 78
4.3.1 Dump所有中间层数据 79
4.3.2 对比原始onnx结果 79
4.4 量化精度分析 79
4.4.1 导出精度数据 79
4.4.2 精度数据可视化 79
5 板端SDK使用 80
5.1 兼容版本 81
5.2 使用说明 81
5.3 Sample示例 81
5.3.1 通用sample工程 81
5.3.2 sample_api_user_guide工程 82
5.4 配置说明 82
5.5 导出性能数据 82
6 图像预处理工具使用 83
6.1 使用场景 83
6.2 使用说明 83
7 精度对比工具使用 84
7.1 使用场景 84
7.2 环境准备 85
7.3 精度分析 85
7.4 解决方案 87
7.4.1 onnx vs quant余弦相似度较低 87
7.4.1.1 增加量化数据数量 87
7.4.1.2 改变量化算法 87
7.4.1.3 特定算子组合设置配置 87
7.4.1.4 配置混合比特量化 88
7.4.2 onnx vs board余弦相似度较低 89
7.4.2.1 检查层名匹配 89
7.4.2.2 输入为极小值 89
8 高性能算子配置 90
8.1 Conv类算子 90

版权所有 © 上海云集互联有限公司

8.1.1 Conv/Pool/DepthwiseConv 90
8.1.2 ConvTranspose 90
8.2 数据排布 90
9 自定义CPU算子使用 90
9.1 使用场景 91
9.2 环境准备 91
9.3 使用说明 91
9.3.1 算子原语定义 91
9.3.2 算子函数实现 91
9.3.3 算子注册 93
9.3.4 算子库编译和加载 94
9.4 算子定义限制 94
9.5 准备demo工程 94
9.6 板端加载CPU算子库执行 94

版权所有 © 上海云集互联有限公司

插图目录

图 1-1 NPU整体使用流程..... 1
图 2-3 GroupConv转为普通Conv图示..... 10
图 3-1 ot_avp_npu_config相关变量..... 77
图 3-2 模型每层性能数据..... 77
图 3-3 模型总的性能数据..... 78
图 4-1 ot_avp_npu_config相关变量..... 82
图 4-2 模型每层性能数据..... 83
图 4-3 模型总的性能数据..... 83
图 -6-1 精度调试流程..... 85
图 6-2 模型的onnx与量化后、onnx与板端仿真的每一层精度对比..... 86
图 6-3 模型量化后与板端仿真的精度对比..... 86

版权所有 © 上海云集互联有限公司

表格目录

表 2-1 量化配置信息.....6
表 2-2 输入配置信息.....8
表 2.3-6 可配置pass项.....9
表 2-4 Resize NPU规格说明.....44
表2-5 coordinate_transform_mode取值说明.....44
表2-6 mode取值说明.....45
表2-7 nearest_mode源坐标取整方式说明.....45
表 6-1 精度比对参数QuantDump和LayerDump说明.....86

版权所有 © 上海云集互联有限公司

1 简介

NPU的整体使用流程如图1-1。用户基于Pytorch/TensorFlow/Caffe开源框架训练好的模型，先转换为ONNX模型，再使用OMG工具将ONNX模型转换为仿真模型或板端的模型。

问题定位和工具使用：

- 利用仿真工具或者上板工具，可以获取模型的Accuracy（精度）结果和Profiling（性能）结果；
- 当出现精度问题时，可以通过原始精度结果、仿真精度结果、量化后仿真精度结果和上板精度结果对比来定位问题；
- 当出现性能问题时，结合仿真出的Profiling数据及上板出的Profiling数据，通过性能分析工具来优化性能。

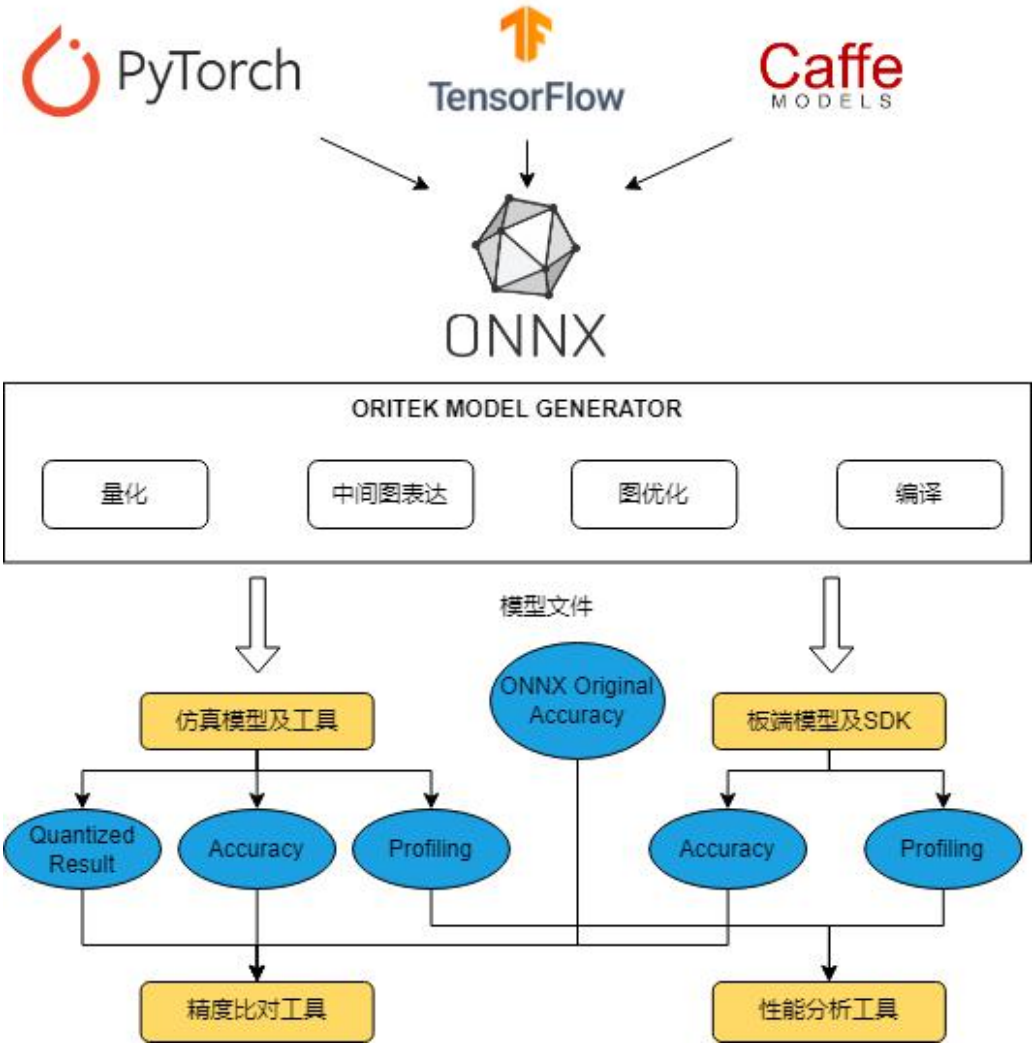


图 1-1 NPU整体使用流程

版权所有 © 上海云集互联有限公司

2 OMG 工具使用

2.1 环境准备

在Ubuntu20.04环境下，从SDK中获取npu_toolchain_v1.x.x.tgz压缩包，解压到当前路径或指定工作路径下，通过tar工具解压得到图2-1所示内容。注意：目前只支持Intel和AMD系列的CPU。

依赖环境	版本
操作系统	Ubuntu 20.04
CPU	只支持 Inter 和 AMD 系列
GPU	只支持 nvidia 系列 最低驱动版本：Driver Version: 525.85.12 (查看方式：nvidia-smi) 最低 CUDA 版本：CUDA Version: 12.0 (查看方式：nvcc -version)

```
tar -zxvf npu_toolchain_v1.x.x.zip
```

npu_toolchain_v1.x.x.tgz解压后目录说明，如图2-1所示。

```
```
├── npu_toolchain
│   ├── Common   # 公共NPU相关工具
│   │   ├── GUI   # 公共的NPUIDE工具
│   │   └── samples   # 转模型和仿真demo示例
│   ├── linux   # Liunx系统的NPU相关工具
│   │   ├── custom_ops # 自定义cpu算子开发示例
│   │   ├── mct   # qat示例
│   │   ├── omg   # 离线模型生成工具、依赖库
│   │   ├── script   #精度比对工具
│   │   └── simulator   # 仿真工具、可引用头文件、依赖库
│   └── windows   # Windows系统的NPU相关工具
            ├── custom_ops # 自定义cpu算子开发示例
│   └── GUI
│   └── simulator
```

图 2- 1 npu_toolchain目录结构说明
```

2.2 使用示例

在npu_toolchain/common/samples/目录下，提供了mobilenetv2和resnet50等ONNX模型离线转换和仿真执行程序。以mobilenetv2为例，进入samples目录下，通过执行oritek_model_gen.sh脚本生成仿真模型（模型的类型参考2.3节参数说明。

```
./oritek_model_gen.sh mobilenetv2_rgbplanar simulator
```

ONNX模型通过omg转换生成仿真模型，参考以下步骤实现：

步骤1 准备ONNX模型文件(*.onnx)和量化配置文件(*.yml)至当前工作路径，用户可指定模型和量化配置文件的所在路径。

步骤2 通过omg可以对onnx模型进行转换，生成适配板端或仿真的离线模型，执行如下命令：

```
./omg --model mobilenetv2-12.onnx \
--config input_config.yml \
--output_model mobilenetv2-12.ortm \
--output_model_type simulator \
--log_level info
```

参数选项的详细配置见2.3 参数说明。

2.3 参数说明

2.3.1 --help

功能说明：可选，查看omg当前支持的可配置参数选项。

示例：

```
./omg --help #  查看支持的参数选项
```

2.3.2 --version

功能说明：可选，查看omg工具当前版本信息。

示例：

```
./omg --verison # 查看版本信息
```

2.3.3 --model

功能说明：必选，输入原始模型的路径与文件名。

示例：

```
--model mobilenet-v2-12.onnx
```

2.3.4 --config

功能说明：量化配置文件的路径。

版权所有 © 上海云集互联有限公司

quant参数说明			
选项			说明
quant	dataset	calib_path	包括dataset.txt所在的路径。data为单输入时不做检查，多输入时要和inputs栏的顺序保持一致。
		calib_data_num	量化时使用的数据量大小。
		weight_auto_bits_calib_num	权重混合精度量化时使用的数据量大小。
		ptp_data_num	PTP剪枝使用的数据量大小。
		quant_batch_size	量化中前向推理的batchsize，calib_type为binary时，该配置无效，按照实际模型所需的input中NCHW的N通道个数作为batch数自动量化。
	ptp_rate	-	配置是否打开PTP剪枝，并指定剪枝率； ptp_rate配置范围[0, 0.5]，配置0代表关闭PTP剪枝，(0,05]代表打开PTP剪枝，并且配置对应的剪枝率；（注：剪枝功能不能和权重混合精度或激活混合精度同时打开）
	skip_quant	-	配置是否跳过量化。true：跳过量化；False：不跳过量化，默认设置为false。
	activation	algorithm	激活层量化支持的算法类型：MSE/KLD/MaxMin/percentile 。当algorithm设置为percentile时，需要配置percent选项。percent的取值范围：percent∈(0,1]，当percent配置为1时与MaxMin算法效果一致，推荐配置0.99999，0.9999，0.999。 示例： activation: algorithm: percentile percent: 0.99999 symmetric: false
		symmetric	false: 使能非对称量化。true: 使能对称量化。
		auto_bits	auto: 自动混合精度量化。auto模式是根据每个activation的量化敏感度来自动筛选，并对筛选到的activation使用16比特量化。 9~15：指定比特数的混合精度量化。activation的混合精度量化是通过对一定比例的activation使用16比特量化，最终达到平均9~15比特量化的效果。参数范围为[9，15]，参数越大，则使用16比特量化的activation比例越高。 （注：activation的auto_bits打开后，weight和activation的quant_type只支持S8，且weight不支

版权所有 © 上海云集互联有限公司

			持auto_bits功能。）
		quant_type	支持的量化数据类型：S8/S16。 （注：activation的S16量化时，weight只支持S8量化）
	weight	algorithm	权重量化支持的算法类型：MaxMin/MSE。
		quant_type	权重量化的数据类型：支持S4/S8。 （注：weight的S4量化时，activation只支持S8量化）
		auto_bits	auto: 自动混合精度量化。auto模式是根据每个weight的量化敏感度来自动筛选，并对筛选得到的weight使用4比特量化。 5~7：指定比特数的混合精度量化。weight的指定比特数混合精度量化是通过对一定比例的weight使用4比特量化，以达到平均5~7比特的量化效果。参数范围为[5，7]，参数越小，则使用4比特量化的weight比例越高。 （注：weight的auto_bits打开后，weigh和activation的quant_type只支持S8，且activation不支持auto_bits功能。）
		per_channel	true: 分通道量化。false: 整个权重一起量化。
	acc_dump	enable_dump	执行量化前后模型的精度误差对比，对比结果保存到dump_path所指定的文件路径中。false: 不对比；true: 对比
		dump_path	精度误差Json文件保存路径。
	quant_tensors	tensor_name	需要单独指定量化配置的tensor名称。
		quant_type	指定tensor量化的数据类型。 支持选项：S4/S8/S16/FP16（大小写不敏感）。 例如要关闭name为resnetv21_relu0和resnetv22_relu0的tensor的量化。则配置方式如下： quant_tensors: - tensor_name: resnetv21_relu0 quant_type: FP16 - tensor_name: resnetv22_relu0 quant_type: FP16
	quant_intervals	start_tensor_name	需要单独指定区间量化配置的区间开始的tensor名称，列表类型的数据。
		end_tensor_name	需要单独指定区间量化配置的区间结束的tensor名称，列表类型的数据。

版权所有 © 上海云集互联有限公司

		quant_type	指定区间量化的数据类型。 支持选项：S8/S16/FP16（大小写不敏感）。 例如要关闭某区间tensor的量化。则配置方式可以如下： quant_intervals: - start_tensor_name: [_st_0] end_tensor_name: [_en_0, _en_1] quant_type: fp16

表 2-1 量化配置信息

inputs参数说明			
选项			说明
inputs	input_name	-	与模型起始的数据输入名保持一致，如data/input。单个输入时不做检查。
	calib_type	-	量化时校准集的格式。支持的选项：Image/Binary。 注：1.若设置为Image，必须配置preprocess参数栏中的dtc参数栏。2.目前Image输入只支持输入格式为RGB的模型，如果模型需要BGR作为输入，可以使用Binary。
	input_type	-	仿真模型和离线模型输入的数据格式。支持的选项：Image/Binary。 注：1. 若设置为Image，则必须配置preprocess参数栏中的preprocess_input_type, preprocess_output_type, dtc。2. Binary数据类型默认为float，是经过DTC处理后的结果。
	data_type	-	指定输入的数据类型。支持的选项：U8/S8/U16/S16/FP16/FP32。
	reverse_rgb_order	-	是否需要反转输入的rgb顺序。false: 为rgb次序，true: 为bgr次序。不支持配置。默认为false。
	data_layout	-	当前版本仅支持NCHW数据排布格式。
	shape	-	模型输入数据的shape，如[1, 3, 224, 224]。
	preprocess	preprocess_input_type	模型预处理输入格式，input_type设置为Image时生效。支持的选项： RGBPlanar/YUV420SP/YVU420SP/YUV422SP/YUV400/RAW_RGGB/RAW_BGGR/RAW_GBRG/RAW_GRBG。当图片类型为RAW_RGGB/RAW_BGGR/RAW_GBRG/RAW_GRBG时，需要指定data_type参数（U10/U12/U16），raw格式输入只支持配置1个。
		preprocess_output_type	模型预处理输出格式，input_type为Image时生效。支持的选项：RGBPlanar/Gray/YUV444Planar/ BGGRPlanar/GBRGPlanar/GRBGPlanar/RGGBPlanar。 配置预处理示例：（1）RGBPlanar预处理输入，input_type: RGBPlanar, output_type: RGBPlanar；（2）YUV420SP预处理输入，

			input_type: YUV420SP, output_type: RGBPlanar；（3）YUV420SP预处理输入，YUV444预处理输出（模型按YUV444格式训练）：input_type: YUV420SP, output_type: YUV444Planar。
		resize	letter_box: false letter_box按照height / img_h、width / img_w中较小的比例进行resize，空出来的size使用灰度值填充。 height: 256 width: 256
		crop	method: absolute 支持 ratio（比例） 和 absolute（以图像中心裁剪）两种模式。 height: 224 width: 224
		dtc	embeded_to_model: true 要将dtc处理添加到离线模型。 mean: [0.485, 0.456, 0.406] std: [0.229, 0.224, 0.225] 对RGB图像数据：data = (img / 255 - mean) / std 对灰度图等单通道数据：data = (img / 255 - mean[0]) / std[0]
		csc_matrix	当使用preprocess_input_type为YUV或者YVU的输入数据类型，并且preprocess_output_type为RGBPlanar时，所需的转换矩阵。如果不配置，则使用默认的转换矩阵。转换公式为: $$\begin{vmatrix} R \\ G \\ B \end{vmatrix} = \left(\begin{vmatrix} m_{00} & m_{01} & m_{02} \\ m_{10} & m_{11} & m_{12} \\ m_{20} & m_{21} & m_{22} \end{vmatrix} \begin{vmatrix} Y - B_0 \\ U - B_1 \\ V - B_2 \end{vmatrix} \right) \gg 10 + \begin{matrix} b_0 \\ b_1 \\ b_2 \end{matrix}$$ coef: - 1024 - 0 - 1436 - 1024 - -352 - -731 - 1024 - 1815 - 0 in_dc: - 0 - 128 - 128 out_dc: - 0 - 0 - 0

版权所有 © 上海云集互联有限公司

		注：只有dtc可以在仿真和离线模型中执行。resize、crop参数栏给量化配置使用，仿真和离线模型执行时需要在外部做。

表 2-2 输入配置信息

outputs参数说明			
选项			说明
outputs	output_name	-	与模型数据输出名保持一致，如data/output。支持指定中间tensor为模型输出，不支持指定常量折叠的中间tensor为输出。
	output_type	-	仿真模型和离线模型输入的数据格式。支持的选项：Image/Binary。若设置为Image，则必须配置postprocess参数。
	data_type	-	指定输出层的数据类型，默认值为FP32。支持的选项：U8/S8/U16/S16/FP16/FP32.
	postprocess	postprocess_output	RAW_RGGB/RAW_BGGR/RAW_GBRG/RAW_GRBG/YUV400/UVSP/VUSP。当图片类型为RAW_RGGB/RAW_BGGR/RAW_GBRG/RAW_GRBG时，需要指定data_type（U10/U12/U16）。YUV400的输入通道必须是1，UVSP和VUSP的输入通道必须是2。

表 2.3-3 输出配置信息

executor参数说明			
选项			说明
executor	enable_gpu		当为true时表示启用GPU，当为false时，表示禁用GPU
	cpu_settings	thread_num	thread_num表示启用CPU线程数量
	gpu_settings	dev_id	dev_id表示要启用的GPU的设备ID

表 2.3-4 执行器信息

model参数说明			
选项			说明
model	output_order	-	指定输出顺序。例如，如果要交换output1,和output2的顺序，可以配置为： model: output_order: - "output2" - "output1"
	enable_preemption	-	模型优先级抢占使能开关。开启后，模型可被抢占。
	decrease_interrupt_v100	-	减少中断次数使能开关，当为true时表示开启，在使用异步接口的情况下生效。开启后，生成的板端模型不支持profile。

表 2.3-5 模型配置信息

add_postprocess参数说明

选项			说明
add_postprocess	postprocess_type	-	后处理的类型。支持的选项：detection。
	image_h	-	模型输入的数据的高
	image_w	-	模型输入的数据的宽
	model_type		后处理的模型计算类型。支持的选项：yolov5
	nms_threshold		非极大值抑制的阈值。0~1
	low_score_threshold		最终框的置信度的分数。0~1
	detection_head	head_input_name	检测头的输入的张量名字。该张量名字需要与模型中的张量名字一一对应
		topK	检测头的框的最大个数。
		num_classes	检测头需要分类的数量,必须大于0.
		anchor_size	检测头所需锚框的尺寸

表 2.3-6 后处理配置信息

passes参数说明			
选项			说明
passes	pass_name	-	要启用或者禁用Pass的名称，支持列表见表2.3-8。
	enable	-	当为true时，表示 启动此Pass，当为false时，表明禁用此Pass

表 2.3-7 passes参数说明

Pass名称	功能描述	默认是否启用
GroupConvDiagonalizePass	将非Depthwise的Group卷积转换为普通卷积，通过浪费计算量，来减少由于Group拆分带来的多个任务频繁切换额外耗时，见图2-3。此Pass针对计算量小且group切分较多的场景下有正向收益，需要客户根据自己模型的情况来做调整。	false

表 2.3-8 可配置pass项

版权所有 © 上海云集互联有限公司

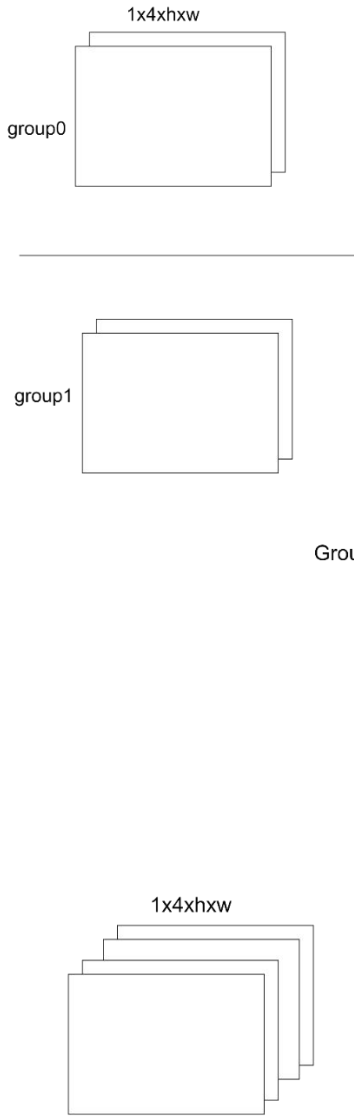


图 2- 3 GroupConv转为普通Conv图示

配置文件示例：

```
quant:
  acc_dump:
    enable_dump: true
    dump_path: ./result.json
  dataset:
    calib_path: /xxx/dataset.txt
  activation:
    algorithm: MaxMin
    symmetric: false
```


版权所有 © 上海云集互联有限公司

```
    quant_type: "S8"
  weight:
    algorithm: MaxMin
    quant_type: "S8"
    per_channel: false
inputs:
  - input_name: data
    calib_type: Image
    input_type: Binary
    reverse_rgb_order: false
    data_layout: NCHW
    shape: [1, 3, 224, 224]
    preprocess:
      resize:
        letter_box: false
        height: 256
        width: 256
      crop:
        method: absolute
        height: 224
        width: 224
      dtc:
        mean: [0.485, 0.456, 0.406]
        std: [0.229, 0.224, 0.225]
      csc_matrix:
        coef:
        - 1024
        - 0
        - 1436
        - 1024
        - -352
        - -731
        - 1024
        - 1815
        - 0
        in_dc:
        - 0
        - 128
        - 128
        out_dc:
        - 0
        - 0
        - 0

executor:
  enable_gpu: false
  cpu_settings:
    thread_num: 4
```


版权所有 © 上海云集互联有限公司

```
 gpu_settings:
    dev_id: 0
add_postprocess:
 - postprocess_type: detection
   image_h: 640
   image_w: 640
   model_type: yolov5
   nms_threshold: 0.6
   low_score_threshold: 0.6
   detection_head:
      -head_input_name:[/tensor1,/tensor2,/tensor3]
      topK: 300
      num_classes: 80
      anchor_size: [[30,61,62,45,59,119],[10,13,16,30,33,23],[116,90,156,198,373,326]]
```

图 2-2 配置文件样例

量化时参考图片（支持.jpeg/.jpg格式）的路径保存在dataset.txt文件，每一行是一次输入，如果存在多个图片输入的情况，输入路径用空格隔开，图片依次输入顺序与模型输入保持一致。

dataset.txt文件内容如下：

```
/xxx/xxx_1.jpeg /xxx/xxx_2.jpg
```

一般量化后的模型需要做精度比对，参考第5章节说明。若出现量化精度问题可参考以下几点重新量化：

- 增加量化参考时的图片数量；
- 直接修改为预处理后数据文件，此时preprocess不需要配置，对应文件修改内容如下：

```
inputs:
  - input_name: data
    calib_type: Binary        # 输入是经过预处理的二进制文件
    input_type: Binary
    reverse_rgb_order: false
    data_layout: NCHW
    shape: [1, 3, 224, 224]
    # preprocess:             # 则该选项不用配置
```

- 修改activation参数栏的量化算法类型，当前支持可配置的量化算法有：MSE/KLD/MaxMin/percentile。

配置项中设置acc_dump，会执行量化后模型与原模型的权重与激活值的精度误差对比，计算余弦相似度、欧氏距离与MSE等指标值；网络结构（每个网络节点的输入输出）、每层输出数据和权重的分布直方图、以及每一层的精度误差以JSON文件格式保存在用户指定路径，用户若未指定保存路径，则保存在默认目录./result.json。结果文件可以导入到可视化工具中，便于直观对比量化效果。

- 预处理参数设置

预处理支持的输入输出参数设置如下：

preprocess_input_type	preprocess_output_type
RGBPlanar	RGBPlanar
YUV400	Gray

版权所有 © 上海云集互联有限公司

YUV420SP	RGBPlanar
	YUV444Planar
YVU420SP	RGBPlanar
	YUV444Planar
YUV422SP	RGBPlanar
	YUV444Planar
YVU422SP	RGBPlanar
	YUV444Planar
RAW_BGGR	BGGRPlanar
RAW_GBRG	GBRGPlanar
RAW_GRBG	GRBGPlanar
RAW_RGGB	RGGBPlanar

表 2-7 支持的预处理配置项

对于模型不同的输入类型，config配置预处理示例：

-配置Binary输入

```
inputs:
  - input_name: input
    calib_type: Image
    input_type: Binary  # 模型输入的数据格式 Image/Binary
    reverse_rgb_order: false
    data_layout: NCHW
    shape: [1, 3, 224, 224]
…
```

-配置RGBPlanar预处理

```
inputs:
  - input_name: input
    calib_type: Image
    input_type: Image   # 模型输入的数据格式 Image/Binary
    reverse_rgb_order: false
    data_layout: NCHW
    shape: [1, 3, 224, 224]
    preprocess:
      preprocess_input_type: RGBPlanar
      preprocess_output_type: RGBPlanar
      resize:
        letter_box: false
        height: 256
        width: 256
      crop:
        method: absolute
```


版权所有 © 上海云集互联有限公司

```
    height: 224
    width: 224
  dtc:
    mean: [0.485, 0.456, 0.406]
    std: [0.229, 0.224, 0.225]
```

-配置YUV420SP预处理

```
inputs:
 - input_name: input
   calib_type: Image
   input_type: Image   # 模型输入的数据格式 Image/Binary
   reverse_rgb_order: false
   data_layout: NCHW
   shape: [1, 3, 224, 224]
   preprocess:
     preprocess_input_type: YUV420SP
     preprocess_output_type: RGBPlanar
     resize:
       letter_box: false
       height: 256
       width: 256
     crop:
       method: absolute
       height: 224
       width: 224
     dtc:
       mean: [0.485, 0.456, 0.406]
       std: [0.229, 0.224, 0.225]
```

-配置raw16 RGGB预处理

```
inputs:
- input_name: onnx::Concat_0
  calib_type: Binary
  input_type: Image
  data_type: u16
  reverse_rgb_order: false
  data_layout: NCHW
  shape: [1, 4, 776, 968]
  preprocess:
    preprocess_input_type : RAW_RGGB
    preprocess_output_type : RGGBPlanar
    dtc:
      mean: [0.0, 0.0, 0.0, 0.0]
      std: [1.0, 1.0, 1.0, 1.0]
```

其他说明：必选参数。

版权所有 © 上海云集互联有限公司

2.3.5 --output_model

功能说明：必选，输出模型的保存路径与文件名。如果output_model_type参数为simulator，则会同步生成一个伪量化模型，用于评价量化损失。

参数取值：存放转换后的离线模型路径及文件名

示例：

```
--output_model ./xxx.ortm # 在当前路径下生成后缀名为.ortm文件。如果是仿真模型，则会同步生成一个xxx_fake_quant.ortm的伪量化模型。
```

2.3.6 --output_model_type

功能说明：必选，输出的模型类别。

参数取值：板端: board，仿真: simulator。

示例：

```
--output_model_type board # 生成板端可部署模型
```

2.3.7 --log_level

功能说明：可选，omg的日志级别。

参数取值：[debug/info/warn/error]

输出等级依次为debug->info->warn->error，级别越低，打印信息越多，高级别会屏蔽低级别日志信息。

示例：

```
--log_level debug # 则 info、warn、error 信息都将显示
--log_level error # 则仅显示 error 信息
```

2.3.8 --target

功能说明：可选，指定模型转换后的运行目标平台。

参数取值：需配置具体芯片型号。

示例：

```
--target SD3589C # 在该芯片目标平台上推理
```

2.3.9 --strip

功能说明：可选，是否删除模型结构信息。

参数取值：不开启。

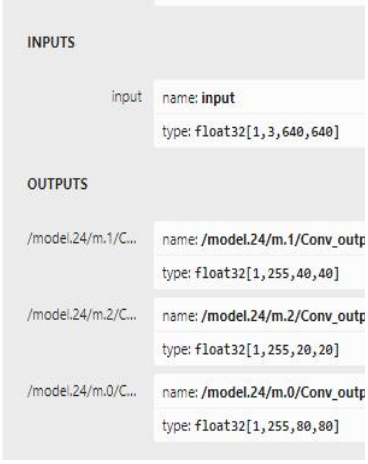
示例：

```
--strip # 模型离线转换后删除模型结构信息
```

云集互联 YUNJI ECO add_postprocess 添加目标检测后处理配置项相关例子介绍

示例说明： 以yolov5作为添加后处理的原模型，展示相关内容以及配置示例：

版权所有 © 上海云集互联有限公司

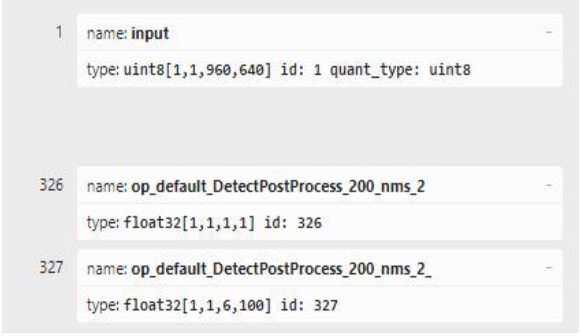


原模型为一个输入,三个输出。输入名字为input, 输出的三个名字分别为/model.24/m.1/Conv_output_0 , /model.24/m.2/Conv_output_0, /model.24/m.0/Conv_output_0.

add_postprocess后处理配置项，对应文件修改内容如下：

```
add_postprocess:
  - postprocess_type: detection
    image_h: 640
    image_w: 640
    model_type: yolov5
    nms_threshold: 0.4
    low_score_threshold: 0.4
    detection_head:
      -head_input_name:[/model.24/m.1/Conv_output_0,/model.24/m.0/Conv_output_0,
      /model.24/m.2/Conv_output_0]
        topK: 100
        num_classes: 80
        anchor_size: [[30,61,62,45,59,119],[10,13,16,30,33,23],[116,90,156,198,373,326]]
```

需要设置后处理的类型为detection. image_h image_w为输入数据的宽高。model_type为解析框大小与位置的计算策略.nms_threshold为计算非极大值抑制时的过滤值。low_score_threshold为过滤解析框时的分数过滤值，该值为框的分类类别最大的置信度乘以是否为物体的置信度的最终结果。detection_head:包含其检测头的内容. head_input_name 为一个检测头里所需的解析数据的名字。以yolov5为例，则有一个检测头，需要解析的名字分别为/model.24/m.1/Conv_output_0,/model.24/m.0/Conv_output_0,/model.24/m.2/Conv_output_0。topK 为最终输出框的最大个数，num_classes则为解析数据时所需的类别数。Anchor_size为每个解析数据时对应的解析框的锚框的wh， 以第一个/model.24/m.1/Conv_output_0，其形状为[1,255,40,40]，并且其num_classes为80时，其数据分布排布为[1, 锚框个数*(coords+score+num_classes), 40,40]，coords表示为预测框的x，y，w，h。score表示是否是背景的分数。于是锚框个数为3， 则anchor_size中该tensor对应的anchor的数量长度则为6.，于是添加完后处理的转换模型为：



版权所有 © 上海云集互联有限公司

模型的第一个输出为最终输出框的个数，模型的第二个输出为 最终解析框的数据[1,1,6,100], 6表示为框的Xmin,Ymin,Xmax,Ymax,Score,ClassId。100为topk的值。当最终解析出的真实框的个数小于topk时，则其余位置会填充0数据。如果需要添加检测头时，则添加一组项head_input_name至anchor_size的配置。

model_type为yolov5时，解析框时所采用的公式为：

$$b_x = 2 * sigmoid(t_x) - 0.5 + C_x$$
$$b_y = 2 * sigmoid(t_y) - 0.5 + C_y$$
$$b_w = p_w * (2 * sigmoid(t_w))^2$$
$$b_h = p_h * (2 * sigmoid(t_h))^2$$

$t_x t_y t_w t_h$分别为预测的左上角坐标横轴坐标，预测的左上角坐标纵轴坐标，预测的物体的宽，预测的物体的高，$C_x C_y$分别为锚框的距离左上角的横轴，锚框的距离左上角的纵轴，$p_w p_h$分别为锚框的锚框的宽高。$b_x b_y b_w b_h$为最终解析的左上角横轴坐标，最终解析的左上角纵轴坐标，最终解析的物体的宽，最终解析的物体的高。

目标检测后处理流程为：1.解析预测框的最终宽高以及左上角坐标点，2.过滤小于low_score_threshold的框的置信度，3 根据框的置信度排序框，4 利用非极大值抑制过滤重叠的框，5 输出置信度最大前topk的框的最终结果。

2.3.10.1 后处理使用场景说明

场景1: 需要为每一个检测头配一个目标检测后处理，并且限制的输出框的个数不一样

则add_postprocess后处理配置项，对应文件修改内容如下：

```
add_postprocess:
 - postprocess_type: detection
   image_h: 640
   image_w: 640
   model_type: yolov5
   nms_threshold: 0.4
   low_score_threshold: 0.4
   detection_head:
    -head_input_name:[/model.24/m.1/Conv_output_0]
     topK: 100
     num_classes: 80
     anchor_size: [[30,61,62,45,59,119]]
    -head_input_name:[ /model.24/m.0/Conv_output_0]
     topK: 50
     num_classes: 80
     anchor_size: [ [10,13,16,30,33,23]]
    -head_input_name:[/model.24/m.2/Conv_output_0]
     topK: 60
     num_classes: 80
     anchor_size: [ [116,90,156,198,373,326]]

```

场景2: 每个检测头有不同的分类类别个数

则add_postprocess后处理配置项，对应文件修改内容如下：

```
add_postprocess:
```

```
 - postprocess_type: detection
   image_h: 640
   image_w: 640
   model_type: yolov5
   nms_threshold: 0.4
   low_score_threshold: 0.4
   detection_head:
    -head_input_name:[/model.24/m.1/Conv_output_0]
     topK: 100
     num_classes: 5
     anchor_size: [[30,61,62,45,59,119]]
    -head_input_name:[ /model.24/m.0/Conv_output_0]
     topK: 50
     num_classes: 3
     anchor_size: [ [10,13,16,30,33,23]]
    -head_input_name:[/model.24/m.2/Conv_output_0]
     topK: 60
     num_classes: 2
     anchor_size: [ [116,90,156,198,373,326]]
```

2.3.10.2 后处理配置项常见问题说明

1. 当出现输出数据不对时，先检测输入的数据排布方式是否为[1, 锚框个数*(coords+score+num_classes), h,w],其次检测num_classes是否配置对.检查anchor_size中锚框是否设置正确.输入的image_h, image_w是否配置正确.原网络所采用的解析方式是否为yolov5策略.
2. 当出现预测框重叠过多时，降低nms_threshold的阈值
3. 当出现有许多检测框时，增加low_score_threshold的阈值

2.4 算子规格明

当前版本离线模型生成、推理基于ONNX框架，故其他开源框架，如Pytorch/Tensorflow/Caffe训练出的模型需先转换为ONNX模型。

当前仅支持处理的输入数据格式为NCHW，分别代表batch_size, channels, height, width四个维度。当前的输入输出的张量与常量的字符串的长度的最长为127。

当前平台中在使用ONNX模型转为离线模型中暂不支持模型里有修改batch的操作。

版权所有 © 上海云集互联有限公司

2.4.1 ONNX框架算子规格

2.4.1.1 Add

功能描述：将两个输入张量的元素逐个相加。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线data输入
A	input	float/int32	输入张量	两个输入张量形状不同时，会触发numpy-style的广播机制。4D shape都是在线输入，双向广播时转为CPU算子，4D shape双向广播时，在线输入第一个维度必须为1. 3D shape双向广播，转为CPU算子。不支持除以0。离线输入不允许为多batch。所有在线输入的batch维度需保持一致。在线输入从低维度广播成多维度时，只支持batch为1的时候。例如从2维广播成3维时。	是
B	input	float/int32	输入张量		
C	output	float/int32	输出张量		

2.4.1.2 Abs

功能描述：取输入张量的绝对值。

版权所有 © 上海云集互联有限公司

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线data输入
x	input	float	输入张量		否
y	output	float	输出张量		

2.4.1.3 Argmax

功能描述：返回输入最大值的索引。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线data输入
x	input	float	输入张量		否
y	output	float	输出张量		
axis	attribute	int	计算最大值的维度	多batch场景下，axis不能为0。	

2.4.1.4 AveragePool

功能描述：对输入张量在kernel size指定的空间维度进行下采样，采样方法就是取区域中的平均值。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线data输入
X	input	float	输入张量	部分超出图像分析引擎规格的用CPU 图像分析引擎 规格: 1 <= kernel <=255; 1 <= stride <=255； 0<=pad; strides <= input_size; pad left < kernel width; pad right < kernelwidth; pad up < kernel height; pad down < kernelheight; 当前shape已支持(N,C,H,W； pad左右	是

				填充值与上下填充值必须相等。pad左右填充值之和与上下填充值之和不能均不能大于5。 dilations不支持配置为非1	
auto_pad	attribute	AutoPad Mode	pad自动填充模式，详见表2.4.1.11-1 AutoPadMode取值说明。		
ceil_mode	attribute	int	输出形状取整处理。 1:向上取整； 0: 向下取整	默认为false，不可配置	
dilations	attribute	list of units	可选，池化窗口膨胀系数。 dilations[0]为height方向系数 dilations[1]为width方向系数 默认dilations[0]=dilations[1]=1	暂不支持，设置不生效	
kernel_shape	attribute	list of units	池化窗口大小。 kernel_shape[0]为窗口height kernel_shape[1]为窗口width		
pads	attribute	list of ints	边缘像素补位填充值，默认补0 pads[0]为顶部填充值 pads[1]为左侧填充值 pads[2]为底部填充值 pads[3]为右侧填		

版权所有 © 上海云集互联有限公司

			充值		
strides	attribute	list of ints	步长，窗口每次移动的像素数。默认strides[0]=strides[1]=1 stride[0]为height方向步长 stride[1]为width方向步长		
count_include_pad	attribute	int	可选，控制计算均值时是否包含padding的数，默认为0		
Y	output	float	输出张量		

2.4.1.5 BatchNormalization

功能描述：对输入数据归一化处理，输出数据在0到1之间，定义如下：

$$y = \frac{x - mean}{\sqrt{var + epsilon}} * scale + B$$

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线data输入
X	input	float	输入张量	2≤维度≤4	否
scale	input	float	缩放系数	仅支持离线值，一维向量，默认按通道(C0,C1,...,Cn)取值。	
B	input	float	偏置		
mean	input	float	训练后均值		
var	input	float	训练后方差		
epsilon	attribute	float	防止被零除造成溢出，默认值为1e-5f。	支持配置	
y	output	float	输出张量		

2.4.1.6 Clip

功能描述：将输入数据限定在指定的上下限值范围内并输出。

版权所有 © 上海云集互联有限公司

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量		否
min	input	float	下限值。	仅支持离线值	
max	input	float	上限值。		
Y	output	float	输出张量		

2.4.1.7 Concat

功能描述：将张量列表沿着指定的轴方向连接为单个张量。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
inputs	list of input	float/int32/int64/int8/uint8	输入张量	最大支持32路在线输入。	是
axis	attribute	int32	沿着的轴方向。	设r为输入inputs的维度个数，$axis \in [-r, r-1]$。必须配置。不支持离线输入为多batch。多batch情况输入时，axis不能设置为0.	
output	output	float/int32/int64/int8/uint8	输出张量		

2.4.1.8 Cast

功能描述：输入张量类型转换

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
cast_inputs	input	float	输入张量		否
to	attribute	int16/int8/uint8	转换类型		
y	output	int16/int8/uint8	输出张量		

2.4.1.9 Constant

功能描述：此算子会生成一个常数张量。

版权所有 © 上海云集互联有限公司

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
value	attribute	tensor	生成输出Tensor的数据来源	当前仅支持value来配置数据，不支持sparse_value/value_float/value_floats/value_int/value_ints/value_string/value_strings	是
Y	output	float	输出张量		

当前支持constant输入的算子：Relu、Clip、Conv、Add、Sub、Div、Mul、Sum、Exp、 LRN、Softmax、Concat、Reshape、 Log

2.4.1.10 ConstantOfShape

功能描述：根据给定的value和shape生成tensor。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量, 决定输出tensor的shape	固定为1D，每个元素都必须>=0	是
value	Attr	tensor	一个单元素的tensor，决定输出tensor的数据类型和值，当没有设置该attr时默认使用float32的0.0		
Y	output	float	输出张量		

2.4.1.11 Conv

功能描述：对输入图像数据做卷积运算，输出特征图，支持分组卷积。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量	NCHW数据格式 输入channel必须被group整除 strides最大为255 kernel_shape 最大为255	否

版权所有 © 上海云集互联有限公司

				pad最大为15.	
W	input	float	权重，[Oc, Ic / group, kh, kw]，Oc为输出通道数，Ic为输入通道数，kh为kernel的height，kw为kernel的width。	Ic能被group整除。	
B	input	float	偏置，一维向量，长度等于卷积输出通道数	可选	
auto_pad	attribute	AutoPadMode	见表 2.4.1.11-1 AutoPadMode取值说明		
dilations	attribute	list of ints	卷积核的膨胀系数。 dilations[0]为height方向系数， dilations[1]为width方向系数。 默认dilations[0]=dilations[1]=1。	卷积核膨胀后，输出Y的形状尺寸不能超过UINT32_MAX(4294967295)值。	
group	attribute	int	分组数量，默认为1		
kernel_shape	attribute	list of ints	卷积核的大小。 kernel_shape[0]为height值， kernel_shape[1]为width值。	支持配置范围：见参数W规格限制。	
pads	attribute	list of ints	边缘像素补位填充的值。 pads[0]为顶部填充 pads[1]为左侧填充 pads[2]为底部填充 pads[3]为右侧填充	根据填充模式不同，pads值不同，参考AutoPadMode取值说明。0<=Pads<=15. Pads<= ((kernel-1) × dilation + 1)	
strides	attribute	list of ints	卷积核移动的步长。 strides[0]为height方向步长， strides[1]为width方向步长。 默认 strides[0]=strides[1]=1。		
Y	output	float	输出张量		

版权所有 © 上海云集互联有限公司

表 2.4.1.11-1 AutoPadMode取值说明

AutoPadMode	说明
NOTSET	默认值。由外部pads给定pad值。
SAME_UPPER	(1) output_shape=input_shape/stride； (2) pad值=(outputshape-1)*stride-input_shape+kernel_shape计算。若pad值为偶数，则顶部(pad[2])、底部(pad[3])的pad值等于padsH / 2，左侧(pad[0])、右侧(pad[1])的pad值等于padsW / 2。若pad值为奇数，多余的pad补到底部和右侧。
SAME_LOWER	若pad值为奇数，多余的pad补到顶部和左侧。
VALID	无效值，不支持推理。

2.4.1.12 ConvTranspose

功能描述：对输入图像数据做反卷积运算

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量	NCHW数据格式 stride最大可配255， kernel_shape最大为255， kernel_shape与配置的padding差值不能超过16	否
W	input	float	权重，[Ic, Oc / group, kh, kw]，Oc为输出通道数，Ic为输入通道数，kh为kernel的height，kw为kernel的width。		
B	input	float	偏置，一维向量，长度等于反卷积输出通道数	可选	
auto_pad	attribute	AutoPadMode	见表 2.4.1.11-1 AutoPadMode取值说明。	Default NOTSET	
dilations	attribute	list of ints	卷积核的膨胀系数。	目前仅支持配置	

版权所有 © 上海云集互联有限公司

			dilations[0]为width方向系数， dilations[1]为height方向系数。 默认dilations[0]=dilations[1]=1。	为[1,1]	
group	attribute	int	分组数量，默认为1	目前仅支持配置为1	
kernel_shape	attribute	list of ints	卷积核的大小。 kernel_shape[0]为width值， kernel_shape[1]为height值。	支持配置范围：见参数W规格限制。	
pads	attribute	list of ints	边缘像素补位填充的值。 pads[0]为左侧填充 pads[1]为右侧填充 pads[2]为顶部填充 pads[3]为底部填充	格式为 [x1_begin, x2_begin...x1_end, x2_end,...]，不可与auto_pad同时配置; 若配置该项，须配置4个数[padUp, padLeft, padDown, padRight]，分别表示配置的上、左、 下、右补边数. 配置范围：[0, 15]， kernel、stride和dilation影响支持范围	
output_padding	attribute	list of ints	添加到输出中坐标索引较高的一侧的补位填充的值 output_padding [0]为右侧填充， output_padding [1]为底部填充。	当前不支持配置	
output_shape	attribute	list of ints	可以显式设置输出的shape output_ shape [0]为h， output_ shape [1]为w		

版权所有 © 上海云集互联有限公司

strides	attribute	list of ints	卷积核移动的步长。strides[0]为width方向步长，strides[1]为height方向步长。默认strides[0]=strides[1]=1。	大小为2，顺序为(height, width)，配置范围为1~255	
Y	output	float	输出张量		

2.4.1.13 Div

功能描述：将两个输入张量的元素逐个相除。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
A	input	float/int32	输入张量	两个输入张量形状不同时，会触发numpy-style的广播机制。4D shape都是在线输入，双向广播时转为CPU算子，4D shape双向广播时，在线输入第一个维度必须为1. 3D shape双向广播，转为CPU算子。不支持除以0。离线输入不允许为多batch。所有在线输入的batch维度需保持一致。在线输入从低维度广播成多维度时，只支持batch为1的时候。例如从2维广播成3维时。	是
B	input	float/int32	输入张量		
C	output	float/int32	输出张量		

版权所有 © 上海云集互联有限公司

2.4.1.14 Dropout

功能描述：根据比例随机丢弃输入张量的元素。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
data	input	float	输入张量		否
ratio	input	float	可选，随机丢弃的比例。如果未设置，则为0.5，输出数据等于输入数据。非0值应用于训练阶段。	仅支持推理阶段，忽略该参数值。	
training_mode	input	bool	true: dropout用于训练阶段。false:忽略ratio，用于推理阶段。推理模式下，输入数据不会丢弃任何内容并直接输出。	仅支持推理阶段。	
seed	attribute	int	可选，随机数生成器的种子值。	推理阶段下该值配置无效。	
output	output	float	输出张量		
mask	output	bool	可选，输出掩码位		

2.4.1.15 Elu

功能描述：激活函数，定义如下：

$$f(x) = alpha * (exp(x) - 1.) \text{ for } x < 0, f(x) = x \text{ for } x >= 0$$

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
x	input	float	输入张量		否
y	output	float	输出张量		
alpha		float		Alpha必须大于0	

2.4.1.16 Exp

功能描述：以自然常数e为底数，输入张量逐个元素作为指数做幂运算。

$$y = e^x$$

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
x	input	float	输入张量		否

版权所有 © 上海云集互联有限公司

y	output	float	输出张量		

2.4.1.17 Erf

功能描述：计算输入的误差

$$\text{out} = \frac{2}{\sqrt{\pi}}\int_0^x e^{-\eta^2} d\eta$$

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
x	input	float	输入张量		否
out	output	float	输出张量		

2.4.1.18 Expand

功能描述：基于给定形状数据按广播规则对输入张量进行延展。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
Input	input	float/int32/int64/uint32/uint64	输入张量		否
shape	input	Int64	给定的形状数据。	与输入input的维度从右往左顺序逐个对齐，且维度值必须相同或为1，否则，不满足延展规则。多batch场景下，指定shape的第1个值要大于1。	
output	output	float/int32/int64/uint32/uint64	输出张量。	输出张量的形状不一定等于输入张量的形状。支持维度个数改变（如3x1 & 2x1x6 = 2x3x6）和不改变（如3x1 & 3x4 = 3x4）的应用场景。	

版权所有 © 上海云集互联有限公司

2.4.1.19 Flatten

功能描述：指定输入张量的某个轴，以该轴为界，两边维度分别展平，数据保持不变。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量		是
axis	attribute	int64	指定展平的分界轴。默认axis=1。axis<0时，表示对输入X维度从后往前展平。		
Y	output	float	输出张量		

2.4.1.20 Gather

功能描述：沿着指定轴方向，根据索引值提取输入张量中的数据。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
data	input	float/int32/int64	输入张量	维度≥1	是
indices	input	int32/int64	索引值	设r为输入data的维度，则$indices \in [0, r-1]$。当输入维度大于1时，不支持indices的维度小于等于1	
axis	attribute	int64	沿着的轴方向。axis=0，按行索引。axis=1，按列索引。axis<0时，表示从后往前开始数data的第几个维度。	设r为输入data的维度，则$axis \in [-r, r-1]$。多batch场景下，axis不能为0。	
output	output	float/int32/int64	输出张量	设q为indices维度，r为data维度，则output维度=q+(r-1)。	

2.4.1.21 Gemm

功能描述：实现两个矩阵相乘（带比例系数），再与偏置矩阵（带系数）相加，定义如下：

$$Y = alpha * A * B + beta * C$$

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
A	input	float	输入矩阵	矩阵相乘维度必须一致。只有当alpha=1、beta=1、transA为false，C存在且不用广播时用图像分析引擎，其它情况用CPU。**当A和B均为Gemm在线输入时，多batch场景下不支持配置transA=1的属性。**	是
B	input	float	输入矩阵		
C	input	float	可选，偏置	仅支持一维数组	
transA	attribute	bool	A是否需要转置。	取值为0	
transB	attribute	bool	B是否需要转置。	取值为1	
alpha	attribute	float	矩阵A*B的系数。	取值为1.0	
beta	attribute	float	矩阵C的系数。	取值为1.0	
Y	output	float	输出矩阵		

2.4.1.22 GlobalAveragePool

功能描述：全局的平均池化，将一个通道内的特征图平均为一个节点。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量	NCHW数据格式，输入维度小于5。 1 <= input_h <=255; 1 <= input_w <= 255	是
Y	output	float	输出张量	维度个数与输入X维度个数保持一致	

云集互联 YUNJI ECO GlobalMaxPool

功能描述：全局的最大池化，将一个通道内的特征图取最大一个节点。

版权所有 © 上海云集互联有限公司

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量	NCHW数据格式，输入维度小于5。 1 <= input_h <=255; 1 <= input_w <= 255	是
Y	output	float	输出张量	维度个数与输入X维度个数保持一致	

2.4.1.24 HardSigmoid

功能描述：将HardSigmoid函数应用于张量元素：

$$y = max\,(0, min\,(1, alpha * x + beta))$$

参数名	参数类型	数据类型	参数说明	规格限制
X	input	float	输入张量	
alpha	attribute	float	HardSigmoid函数系数	默认值0.2
beta	attribute	float	HardSigmoid函数系数	默认值0.5
Y	output	float	输出张量	

2.4.1.25 InstanceNormalization

功能描述：对输入数据做perchannel归一化处理，输出数据在0到1之间，定义如下：

$$y = \frac{x - mean}{\sqrt{var + epsilon}} * scale + B$$

参数名	参数类型	数据类型	参数说明	规格限制
X	input	float	输入张量	仅支持NCHW数据格式
scale	input	float	缩放系数	仅支持离线值，一维向量，默认按通道(C0, C1,...,Cn)取值。
B	input	float	偏置	
epsilon	attribute	float	防止被零除造成溢出，默认值为1e-5f。	支持配置
y	output	float	输出张量	

2.4.1.26 LeakyRelu

功能描述：一种Relu变体激活函数，计算公式如下：

版权所有 © 上海云集互联有限公司

$$y = \begin{cases} \alpha * x, & x < 0 \\ x, & x \geq 0 \end{cases}$$

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量	不支持5-D以上	是
Y	output	float	输出张量		
alpha	attribute	float	系数，默认值为0.01	可选	

2.4.1.27 Log

功能描述：对输入张量逐个元素求对数，底数为自然常数e。

$$y = \ln(x), (x > 0)$$

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
x	input	float	输入张量	必须大于0	是
y	output	float	输出张量		

2.4.1.28 LRN

功能描述：局部响应归一化，按通道局部区域进行归一化。假设通道总数为N，$X_{(i,j,k)}$表示输入张量在（C,H,W）上的数值，$X_{(i,j,k)}$表示输出张量在（C,H,W）上的数值。计算公式如下：

$$Y_{(i,j,k)} = X_{(i,j,k)} \Big/ (bias + alpha * \sum_{j=\max(o, i-\frac{size}{2})}^{\min(N-1, i+\frac{size}{2})} (X_{(i,j,k)})^2)^{beta}$$

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量	仅支持NCHW，4D格式。Channel维度个数必须>配置的size值。	否
Y	output	float	输出张量		
alpha	attribute	float	系数，默认值为0.0001	可选，必须>0	
beta	attribute	float	系数，默认值为0.75	可选，必须>0	
bias	attribute	float	系数，默认值为1.0	可选	
size	attribute	int	局部计算通道数	支持3、5、7	

2.4.1.29 Max

功能描述：对输入的多个张量求最大值。

版权所有 © 上海云集互联有限公司

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	inputs	float	输入张量	支持多输入，不支持在线广播	是
Y	output	float	输出张量		

2.4.1.30 MaxPool

功能描述：将输入特征图按池化窗口不重叠地分割成若干，每一块在该窗口内输出最大值，其余值舍弃。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量	仅支持NCHW数据格式，只支持dilation为1。同时输出最大值索引（即算子有两路输出）时，仅支持接upsample算子。 部分超出图像分析引擎规格的用CPU 图像分析引擎规格:1 <= kernel <255; 1 <= stride <=255, strides <= input_size; 1 <= pad <= 7; pad left + pad right < kernel width; pad up + pad down < kernel height; 当前shape已支持(N,C,H,W)，N>=1	是
auto_pad	attribute	AutoPadMode	pad自动填充模式，详见表 2.4.1.11-1 AutoPadMode取值说明		
ceil_mode	attribute	int	输出形状取整处理。 1:向上取整；0: 向下取整		
dilations	attribute	list of units	池化窗口膨胀系数。dilations[0]	当前版本仅支持dilations配置为{1,1}	

版权所有 © 上海云集互联有限公司

			为height方向系数 dilations[1]为width方向系数 默认dilations[0]=dilations[1]=1		
kernel_shape	attribute	list of units	池化窗口大小。 kernel_shape[0]为窗口height kernel_shape[1]为窗口width		
pads	attribute	list of ints	边缘像素补位填充值，默认补0。 pads[0]为顶部填充值 pads[1]为左侧填充值 pads[2]为底部填充值 pads[3]为右侧填充值		
strides	attribute	list of ints	步长，窗口每次移动的像素数。 默认strides[0]=strides[1]=1 stride[0]为height方向步长 stride[1]为width方向步长		

版权所有 © 上海云集互联有限公司

Y	output	Float	输出张量		
Indices	output	Int64	选取max值的位置索引	当前版本不支持第2个输出	

2.4.1.31 Mean

功能描述：对输入的多个张量求平均值。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	inputs	float	输入张量	支持多输入，不支持在线广播	是
Y	output	float	输出张量		

2.4.1.32 Min

功能描述：对输入的多个张量求最小值。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	inputs	float	输入张量	支持多输入，不支持在线广播	是
Y	output	float	输出张量		

2.4.1.33 MatMul

功能描述：对两个输入张量matmul。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
A	input	float/int32	输入张量	A、B输入同时超过2D时，不支持最后2个维度进行广播计算，如(3,3,1)与(3,3,1,2)矩阵乘形式。	否
B	input	float/int32	输入张量		
C	output	float/int32	输出张量		

版权所有 © 上海云集互联有限公司

2.4.1.34 Mul

功能描述：对两个输入张量逐个元素相乘。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
A	input	float/int32	输入张量	两个输入张量形状不同时，会触发numpy-style的广播机制。4D shape都是在线输入，双向广播时转为CPU算子，4D shape双向广播时，在线输入第一个维度必须为1. 3D shape双向广播，转为CPU算子。不支持除以0。离线输入不允许为多batch。所有在线输入的batch维度需保持一致。在线输入从低维度广播成多维度时，只支持batch为1的时候。例如从2维广播成3维时。	是否
B	input	float/int32	输入张量		
C	output	float/int32	输出张量		

2.4.1.35 Pad

功能描述：对输入张量在指定的轴上的开始和结束填充指定数量的数据，填充的数据根据填充模式指定。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float/int32	输入张量	仅支持NCHW数据格式	否

版权所有 © 上海云集互联有限公司

pads	input/attribute	list of ints	边缘像素补位填充值，默认补0。此处pads需输入八个值，其中： pads[0],pads[4]为N维度填充值 pads[1],pads[5]为C维度填充值 以上四个目前无效但需输入0 pads[2]为顶部填充值 pads[3]为左侧填充值 pads[6]为底部填充值 pads[7]为右侧填充值	仅支持在HW维度上pad； pads[0],pads[1],pads[4],pads[5]设置无效，但需要输入。 Pad 不支持离线输入。	
constant_value	input/attribute	float/int32	可选，指定在constant填充模式下填充的数据	目前不支持非0的指定值	
mode	attribute	string	可选，控制pad填充的模式，默认为constant		
Y	output	float	输出张量		

2.4.1.36 Pow

功能描述：求X的Y次方操作。如果张量维度不一致，则需要对slope张量做双向广播。定义如下：

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
x	input	float/int64	底数	输入元素总数大于64个转CPU设备	
y	input	float/int64	指数	不支持在线输入	是
output	output	float/int64	输出张量		

版权所有 © 上海云集互联有限公司

2.4.1.37 PRelu

功能描述：对输入张量元素，根据给定的slope张量对输入张量中小于0的元素做相乘操作。如果slope张量维度与输入张量维度不一致，则需要对slope张量做双向广播。定义如下：

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
data	input	float/int64	输入张量	维度≥1	否
slope	input	float/int64	当输入张量中元素<0，则与slope张量中对应元素相乘。		
output	output	float/int64	输出张量		

2.4.1.38 ReduceMean

功能描述：对输入张量元素，根据给定的轴信息求平均值。如果keepdims等于1，则输出的张量与输入具有相同的秩。如果keepdims等于0，则输出的张量对应的轴将被删除。定义如下：

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
data	input	float/int64	输入张量	维度≥1	是
keepdims	attribute	Int64	是否在输出张量保留该维度，默认值为1		
axes	attribute	int64	可选，指定进行降维的维度，支持[-rank, rank - 1]，rank为维度数量，默认是对所有维数为1的维度进行降维操作。	设r为输入data的秩，则$axis \in [-r, r-1]$。只支持对H轴&W轴进行该操作。多batch场景下，axis不能为0。	
output	output	float/int64	输出张量		

2.4.1.39 ReduceMax

功能描述：对输入张量元素，根据给定的轴信息求最大值。如果keepdims等于1，则输出的张量与输入具有相同的秩。如果keepdims等于0，则输出的张量对应的轴将被删除。定义如下：

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
data	input	float/int64	输入张量	维度≥1	是

版权所有 © 上海云集互联有限公司

keepdims	attribute	Int64	是否在输出张量保留该维度，默认值为1		
axes	attribute	int64	可选，指定进行降维的维度，支持[-rank, rank - 1]，rank为维度数量，默认是对所有维数为1的维度进行降维操作。	设r为输入data的秩，则$axis \in [-r, r-1]$。只支持对H轴&W轴进行该操作。多batch场景下，axis不能为0。	
output	output	float/int64	输出张量		

2.4.1.40 ReduceMin

功能描述：对输入张量元素，根据给定的轴信息求最小值。如果keepdims等于1，则输出的张量与输入具有相同的秩。如果keepdims等于0，则输出的张量对应的轴将被删除。定义如下：

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
data	input	float/int64	输入张量	维度≥1	是
keepdims	attribute	Int64	是否在输出张量保留该维度，默认值为1		
axes	attribute	int64	可选，指定进行降维的维度，支持[-rank, rank - 1]，rank为维度数量，默认是对所有维数为1的维度进行降维操作。	设r为输入data的秩，则$axis \in [-r, r-1]$。只支持对H轴&W轴进行该操作。多batch场景下，axis不能为0。	
output	output	float/int64	输出张量		

2.4.1.41 ReduceSum

功能描述：对输入张量元素，根据给定的轴信息求和。如果keepdims等于1，则输出的张量与输入具有相同的秩。如果keepdims等于0，则输出的张量对应的轴将被删除。定义如下：

参数名	参数类型	数据类型	参数说明	规格限制

版权所有 © 上海云集互联有限公司

data	input	float/int64	输入张量	维度≥1
axes	input	int64	可选，指定进行降维的维度，支持[-rank, rank - 1]，rank为维度数量，默认是对所有维数为1的维度进行降维操作。	设r为输入data的秩，则$axis \in [-r, r-1]$。当输入Shape为多batch时不可指定axis=0，当指定为0时，可能计算结果数量超出范围或模型转换失败。
keepdims	attribute	Int64	是否在输出张量保留该维度，默认值为1	与data维度必须相同，每个索引值≤data每个维度上的值。
noop_with_empty_axes	attribute	int64	在输入axes为空时，指定进行降维的维度，默认为0“”是对所有维度进行降维操作，“1”不对输入进行降维操作。	取值为0或1
output	output	float/int64	输出张量	

2.4.1.42 Relu

功能描述：激活函数，将输入数据限制在非负数范围内，定义如下：

$$y = max\ (0, x)$$

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
x	input	float	输入张量		是
y	output	float	输出张量		

2.4.1.43 Reshape

功能描述：重塑数据的形状属性，不改变数据。

例：data=[3, 10,1000]，shapeData=[3,2, -1]，则reshaped=[3, 2, 5000]。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
data	input	float	输入形状		是
shapeData	input	int64	形状数据，该存在-1时，表示自动推导长度。	不支持动态shape，必须为Constant	

				张量。 不允许N轴发生改变。例如从[1,192,X,X]转换为[2,96,X,X]。	
reshaped	output	int64	输出形状		

2.4.1.44 Resize

功能描述：以插值计算调整或改变输入张量的大小。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量	仅支持NCHW数据格式	否
roi	input	float	感兴趣区域。在指定维度上归一化处理。仅支持指定h、w轴	当前版本不支持赋值。	
scales	input	float	仅支持离线配置scales或者sizes中的一个。 nearest模式，scales仅支持h、w维度上采样，输入为[1,1,2,2]	1、与sizes定义互斥。 2、当前版本只支持上采样，且取值为2。	
sizes	input	int64		1、与scales定义互斥。 2、维度个数与输入X保持一致。	
coordinate_transform_mode	attribute	string	-	详见表2-5 coordinate_transform_mode取值说明。	
cubic_coeff_a	attribute	float	三次插值系	仅插值模式为cubic时，该	

版权所有 © 上海云集互联有限公司

			数。Pytorch为 -0.75 ，TensorFlow为-0.5。	参数配置有效，参考自定义CPU。	
exclude_outside	attribute	int	不支持配置	采用默认值。	
extrapolation_value	attribute	float	不支持配置	采用默认值。	
mode	attribute	string	-	详见 表2-6 mode取值说明。	
nearest_mode	attribute	string	-	详见 表2-7 nearest_mode源坐标取整方式说明。	
Y	output	float	输出张量		

表 2-4 Resize NPU规格说明

Resize NPU规格说明		
插值模式	**nearest模式coordinate取整模式**	**coordinate转换模式**
nearest	ceil/floor/round_pf_floor/ round_pf_ceil	asymmetric
linear	-	half_pixel
		asymmetric
		pytorch_half_pixel

注：输入scales取值在以下情况会转至CPU执行：

- h和w轴的缩放系数去掉小数后不等于其整数。例：[1, 1, 1.5, 2.5]。**若此时插值模式为linear+half_pixel/pytorch_half_pixel/align_corners/asymmetric，将由NPU执行。其他插值均由CPU执行。**
- h和w轴的缩放系数不相等。例：[1.0, 1.0, 2.0, 4.0]。
- h或w轴的缩放系数不能被2整除。例：[1.0, 1.0, 3.0, 2.0]。
- 高或宽轴是原输入的8倍以上，只有双线性插值模式才会在NPU上执行。

表2-5 coordinate_transform_mode取值说明

coordinate_transform_mode	**说明**
half_pixel	默认模式。半像素坐标转换模式。
pytorch_half_pixel	基于pytorch的half_pixel坐标转换模式。
align_corners	保持对角值坐标转换模式
asymmetric	非对称坐标转换模式
tf_half_pixel_for_nn	基于tensorflow的half_pixel用于神经网络的坐标转换模式
tf_crop_and_resize	基于tensorflow的裁剪和缩放坐标转换模式。仅该模式下roi输入有效，且仅支持h和w轴。

版权所有 © 上海云集互联有限公司

表2- 6 mode取值说明

mode	说明
nearest	最邻近插值。默认模式。
linear	线性插值。默认双线性插值(bilinear)计算。
cubic	立方插值。默认双三次插值(bicubic)计算。

表2- 7 nearest_mode源坐标取整方式说明

nearest_mode	说明
round_perfer_floor	默认最邻近插值下默认坐标取整模式。向下圆整，对轴长索引x向下取整，补误差值0.5，若等于x，则x向下(floor)取整，否则四舍五入(round)取整。
round_prefer_ceil	向上圆整。近似计算等同于四舍五入取整。
floor	向下取整。
ceil	向上取整。

2.4.1.45 RoiAlign

功能描述：输入张量X和兴趣区域（RoI）来在每个RoI上池化输出结果。输入X、rois、batch_indices均不支持离线输入。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线data输入
X	input	float	输入张量	4-D NCHW，不支持多batch的输入。	
rois	input	float	感兴趣区域的坐标	2-D （num_rois, 4）	
batch_indices	input	Int64	每个元素表示批次中对应图像的索引	1-D （num_rois）,元素值需要小于输入张量的Batch数	
mode	attr	string	池化模式	AVG	
output_height	attr	int32	输出张量的高	default为1	
output_width	attr	int32	输出张量的宽	default为1	
sampling_ratio	attr	int32	插值网格中用于计算每个合并输出仓的输出值的采样点数量	default为0	

版权所有 © 上海云集互联有限公司

spatial_scale	attr	float	输入特征图X相对于输入图像的空间比例	default为1.0	
Y	output	float	输出形状	4-D(num_rois,C, output_height, output_width).	

2.4.1.46 Shape

功能描述：获取输入张量的形状数据。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
data	input	float	输入张量	不支持动态shape	是
start	attribute	int32	可选，起始轴。start<0时，表示从后往前开始数data的维度。	设r为data的维度。$start \in (0, r)$，$start < end$。	
end	attribute	int32	可选，结束轴。end<0时，表示后往前开始数data的维度。	$end \in (0, r)$	
shape	output	int64	输出形状		

2.4.1.47 Sigmoid

功能描述：将输入张量映射到（0，1）的区间，定义如下：

$$\mathbf{S(x)} = \frac{\mathbf{1}}{\mathbf{1} + \boldsymbol{e}^{-x}}$$

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量		是
Y	output	float	输出张量		

2.4.1.48 Slice

功能描述：在指定轴上，根据起始及步长将一个张量切片。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
input	input	float/int32/int8/uint8	输入数据		是。starts、

版权所有 © 上海云集互联有限公司

starts	input	list of int64	每个轴的起始		ends、axes、steps必须为离线数据。
ends	input	list of int64	每个轴的终止（不包含该位置）		
axes	input	list of int64	可选，需要切片的轴，没指定的轴不需要切片。 [-r, r-1]的范围。	多batch场景下，axes不能为0。当输入大于4维时，只支持在最后两维度（h轴和w轴）上切片。	
steps	input	list of int64	可选，每个轴切片的步长。没有指定的话默认为1。不支持为0。		
output	output	float/int32/int8/uint8	输出数据		

2.4.1.49 Softmax

功能描述：计算给定输入z的归一化指数值，输出的张量和输入具有相同的形状。计算公式如下：

$$softmax_{(z_i)} = e^{z_i - \max(z)} \Big/ \sum_{j=1}^{n} e^{z_j - \max(z)}$$

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量	仅支持3D~5D。	是
Y	output	float	输出张量		
axis	attribute	Int32	描述执行softmax运算的轴，负数表示倒着计算维度	设r为输入data的秩，则$axis \in [-r, r-1]$。只支持对H或W轴进行该运算。 多batch场景下，axis不能为0。	

2.4.1.50 Split

功能描述：在指定切分轴上，根据切分数量或输出数量将一个张量拆分为多个张量。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持

版权所有 © 上海云集互联有限公司

					离线输入
input	input	float/int32/int8/uint8	数据		否
splits	input	list of int32	可选，每个输出数据的length，且length≥0。该值总和一定等于指定axis上的长度。	与num_outputs值互斥。	
axis	attribute	int32	指定的切分轴	设r为input的维度个数，$axis < r$。多batch场景下，axes不能为0。	
num_outputs	attribute	int32	可选，输出张量的数量。若axis不能被num_output整除，则最后一个输入维度会比其他输出维度要小。	与splits值互斥。	
outputs	list of output	float/int32/int8/uint8	数据	Output个数最大为64	

2.4.1.51 Squeeze

功能描述：对输入张量进行降维操作，如果指定了降维的维度，则去掉维数为1的维度，若未指定维度，则去掉维度中所有维数为1的维度。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量		是
Axes	attribute	int64	可选，指定进行降维的维度，支持[-rank, rank - 1]，rank为维度数量，默认是对所有维数为1的维度进行降维操作。	多batch场景下，axis不能为0。	
Y	output	float	输出张量		

2.4.1.52 Sub

功能描述：将两个输入张量的元素逐个相减。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线

版权所有 © 上海云集互联有限公司

					输入
A	input	float/int32	输入张量	两个输入张量形状不同时，会触发 numpy-style 的广播机制。4D shape都是在线输入，双向广播时转为CPU算子，4D shape 双向广播时，在线输入第一个维度必须为1. 3D shape双向广播，转为CPU算子。不支持除以0。离线输入不允许为多batch。所有在线输入的batch维度需保持一致。在线输入从低维度广播成多维度时，只支持batch为1的时候。例如从2维广播成3维时。	是
B	input	float/int32	输入张量		
C	output	float/int32	输出张量		

2.4.1.53 Sum

功能描述：对输入的多个张量逐元素相加。

参数名	**参数类型**	**数据类型**	**参数说明**	**规格限制**	**是否支持离线输入**
X	inputs	float	输入张量	输入张量数量：[2, 64] 如果是全在线数据最多支持32个在线张量，两个输入张量形状不同时，会	是

版权所有 © 上海云集互联有限公司

				触发numpy-style的广播机制。4D shape都是在线输入，双向广播时转为CPU算子，4D shape双向广播时，在线输入第一个维度必须为1. 3D shape双向广播，转为CPU算子。不支持除以0。离线输入不允许为多batch。所有在线输入的batch维度需保持一致。在线输入从低维度广播成多维度时，只支持batch为1的时候。例如从2维广播成3维时。	
Y	output	float	输出张量		

2.4.1.54 Tanh

功能描述：双曲正弦函数，将输入映射到(-1, 1)，定义如下：

$$y = \frac{e^{x} - e^{-x}}{e^{x} + e^{-x}}$$

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量		是
Y	output	float	输出张量		

2.4.1.55 Transpose

功能描述：对输入张量根据转置参数进行转置操作。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输

版权所有 © 上海云集互联有限公司

					入
X	input	float	输入张量		是
perm	attribute	int32	可选，指定转置操作轴的顺序，默认为全部转置操作。	当输入维度为4维时,如果转置W或者H轴到N轴上,输入维度为5维时，如果转置n轴，或者channel数大于1时，输入维度大于5维时，会转成CPU算子。当多batch的情况下，不允许转置第一个batch轴至其他位置。	
Y	output	float	输出张量		

2.4.1.56 Unsqueeze

功能描述：对输入张量增加维度。输入指定轴维度，将1插入到输入维度上。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量		是
axes	attribute/input	int64	指定要插入维度的列表，支持[-r, r - 1]，r为输入X的维度个数。	多batch场景下，axis不能为0。	
Y	output	float	输出张量		

2.4.1.57 Upsample

功能描述：对输入张量进行上采样。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量	仅支持NCHW数据排布格式	否
scales	input	float	h、w维度的上采样比例系数。	不支持batch、channel维度上采样，建议值为1.0。h和w维度上的值应≥1.0。scales维度个数应与输入X维度个数保持一致。	

版权所有 © 上海云集互联有限公司

mode	attribute	string	上采样插值模式	模式可配nearest/linear	
Y	output	float	输出张量		

注：Resize功能涵盖Upsample，因此非特殊情况下通常会转换为Resize进行处理。

补充说明：

1.ConstantOfShape、Dropout、Shape 算子当前仅支持 onnx 解析后进行常量折叠，不进行在线推理。

2.Add、 Sub、 Mul、 Div、Sum 算子当前仅支持单向广播，及离线输入的双向广播， 不支持在线输入的双向广播。支持 W/HW 轴双向广播，不支持不同纬度的广播。

2.4.1.58 Mish

功能描述：对输入张量进行元素线性激活计算，公式如下：

$$f(x) = x * \tanh(\ln(1 + e^{x}))$$

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量		否
Y	output	float	输出张量		

2.4.2 内置CPU算子规格

2.4.2.1 ArgMin

功能描述：计算输入张量的指定维度axis上最小值的索引。

参数名	参数类型	数据类型	参数说明	规格限制
X	input	float	输入张量	
axis	attribute	int32	计算最小值的轴方向，默认值为0。	设r为输入inputs的维度个数，$axis \in [-r, r-1]$。
keepdims	attribute	int32	是否保持获取最小值维度。当指定值为1时，表示为保留。	
select_last_index	attribute	int32	当最小值有多个索引时，选择第一个索引还是最后一个索引，当指定值为0时，表示为选择第一个索引。	默认为0，不可配置。
Y	output	int32	输出张量	

云集互联 YUNJI ECO ArgMax

功能描述：计算输入张量的指定维度axis上最大值的索引。

参数名	参数类型	数据类型	参数说明	规格限制
x	input	float	输入张量	
y	output	float	输出张量	
axis	attribute	int	计算最大值的维度	设r为输入inputs的维度个数，$axis \in [-r, r-1]$。
keepdims	attribute	int32	是否保持获取最大值维度。当指定值为1时，表示为保留。	
select_last_index	attribute	int32	当最大值有多个索引时，选择第一个索引还是最后一个索引，当指定值为0时，表示为选择第一个索引。	默认为0，不可配置。

2.4.2.3 AveragePool

功能描述：对输入张量在kernel size指定的空间维度进行下采样，采样方法就是取区域中的平均值。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线data输入
X	input	float	输入张量	当前shape暂时仅已支持4维形状输入	是
auto_pad	attribute	AutoPad Mode	pad自动填充模式，详见表 2.4.1.11-1 AutoPadMode取值说明。		
ceil_mode	attribute	int	输出形状取整处理。 1:向上取整； 0: 向下取整		
dilations	attribute	list of units	可选，池化窗口膨胀系数。 dilations[0]为height方向系数 dilations[1]为width方向系数 默认dilations[0]=dilations[1]=1		

版权所有 © 上海云集互联有限公司

kernel_shape	attribute	list of units	池化窗口大小。kernel_shape[0]为窗口height kernel_shape[1]为窗口width		
pads	attribute	list of ints	边缘像素补位填充值，默认补0 pads[0]为顶部填充值 pads[1]为左侧填充值 pads[2]为底部填充值 pads[3]为右侧填充值		
strides	attribute	list of ints	步长，窗口每次移动的像素数。默认 strides[0]=strides[1]=1 stride[0]为height方向步长 stride[1]为width方向步长		
count_include_pad	attribute	int	可选，控制计算均值时是否包含padding的数，默认为0		
Y	output	float	输出张量		

2.4.2.4 Cast

功能描述：将输入张量，转为to指定的数据类型输出张量。

参数名	参数类型	数据类型	参数说明	规格限制
A	input	float	输入张量	目前进支持float输入的转换

版权所有 © 上海云集互联有限公司

saturate	attribute	int32	可选，该参数定义了如果输入值超出目标类型的范围，转换的行为，适用于float8的转换。	当前场景不涉及该参数配置，默认为1.
to	attribute	int32	需要转换的类型，与 oritekgraph ::DataType 一致。	目前支持 uint8/int8/int16 类型转换
C	output	uint8/int8/int16	输出张量	目前支持 uint8/int8/int16 类型

2.4.2.5 Ceil

功能描述：将输入张量向上取整

参数名	参数类型	数据类型	参数说明	规格限制
X	input	float	输入张量	
Y	output	float	输出张量	

2.4.2.6 Conv

功能描述：对输入图像数据做卷积运算，输出特征图，支持分组卷积。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量		否
W	input	float	权重，[Oc, Ic / group, kh, kw]，Oc为输出通道数，Ic为输入通道数，kh为kernel的height，kw为kernel的width。		
B	input	float	偏置，一维向量，长度等于卷积输出通道数		
auto_pad	attribute	AutoPadMode	见表 2.4.1.11-1 AutoPadMode 取值说明		
dilations	attribute	list of ints	卷积核的膨胀系数。 dilations[0]为height方向系数， dilations[1]为width方向系数。 默认dilations[0]=dilations[1]=1。		
group	attribute	int	分组数量，默认为1		

版权所有 © 上海云集互联有限公司

kernel_shape	attribute	list of ints	卷积核的大小。 kernel_shape[0]为height值， kernel_shape[1]为width值。		
pads	attribute	list of ints	边缘像素补位填充的值。 pads[0]为顶部填充 pads[1]为左侧填充 pads[2]为底部填充 pads[3]为右侧填充		
strides	attribute	list of ints	卷积核移动的步长。 strides[0]为height方向步长， strides[1]为width方向步长。 默认strides[0]=strides[1]=1。		
Y	output	float	输出张量		

2.4.2.7 ConvTranspose

功能描述：对输入图像数据做反卷积运算

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量		否
W	input	float	权重，[Ic, Oc / group, kh, kw]，Oc为输出通道数，Ic为输入通道数，kh为kernel的height，kw为kernel的width。		
B	input	float	偏置，一维向量，长度等于反卷积输出通道数		
auto_pad	attribute	AutoPadMode	见表 2.4.1.11-1 AutoPadMode取值说明。		
dilations	attribute	list of ints	卷积核的膨胀系数。 dilations[0]为width方向系数， dilations[1]为height方向系数。 默认dilations[0]=	目前仅支持配置为[1,1]	

版权所有 © 上海云集互联有限公司

			dilations[1]=1。		
group	attribute	int	分组数量，默认为1	目前仅支持配置为1	
kernel_shape	attribute	list of ints	卷积核的大小。 kernel_shape[0]为width值， kernel_shape[1]为height值。	支持配置范围：见参数W规格限制。	
pads	attribute	list of ints	边缘像素补位填充的值。 pads[0]为左侧填充 pads[1]为右侧填充 pads[2]为顶部填充 pads[3]为底部填充	格式为 [x1_begin, x2_begin...x1_end, x2_end,...]，不可与auto_pad同时配置; 若配置该项，须配置4个数[padUp, padLeft, padDown, padRight]，分别表示配置的上、左、 下、右补边数. 配置范围：[0, 15]， kernel、stride和dilation影响支持范围	
output_padding	attribute	list of ints	添加到输出中坐标索引较高的一侧的补位填充的值 output_padding [0]为右侧填充， output_padding [1]为底部填充。	当前不支持配置	
output_shape	attribute	list of ints	可以显式设置输出的shape output_ shape [0]为h， output_ shape [1]为w		
strides	attribute	list of ints	卷积核移动的步长。 strides[0]为width方向步长， strides[1]为height方向步长。		

版权所有 © 上海云集互联有限公司

			默认 strides[0]=strides[1]=1 。		
Y	output	float	输出张量		

2.4.2.8 DepthToSpace

功能描述：将描述深度的数据重新排列为描述空间的数据块，是SpaceToDepth的逆变换。

参数名	参数类型	数据类型	参数说明	规格限制
input	input	float	输入张量	数据格式为NCHW
mode	attribute	string	默认为DCR模式，该模式下输入张量沿着depth维度元素按照深度、列、行次序重新排列。	
blocksize	attribute	int		
output	output	float	输出张量，形式为[N, C/(blocksize*blocksize), H*blocksize, W*blocksize]	

2.4.2.9 Expand

功能描述：基于给定形状数据按广播规则对输入张量进行延展。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
Input	input	float	输入张量		否
shape	input	Int64	给定的形状数据。	与输入input的维度从右往左顺序逐个对齐，且维度值必须相同或为1，否则，不满足延展规则。	
output	output	float	输出张量。	输出张量的形状不一定等于输入张量的形状。支持维度个数改变（如3x1 & 2x1x6	

版权所有 © 上海云集互联有限公司

				= 2x3x6）和不改变（如3x1 & 3x4 = 3x4）的应用场景。	

2.4.2.10 Floor

功能描述：将输入张量向下取整

参数名	参数类型	数据类型	参数说明	规格限制
X	input	float	输入张量	
Y	output	float	输出张量	

2.4.2.11 Gemm

功能描述：实现两个矩阵相乘（带比例系数），再与偏置矩阵（带系数）相加，定义如下：

$$Y = alpha * A * B + beta * C$$

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
A	input	float	输入矩阵	矩阵相乘维度必须一致。只有当alpha=1、beta=1、transA为false，C存在且不用广播时用图像分析引擎，其它情况用CPU	是
B	input	float	输入矩阵		
C	input	float	可选，偏置	仅支持一维数组	
transA	attribute	bool	A是否需要转置。	取值为0	
transB	attribute	bool	B是否需要转置。	取值为1	
alpha	attribute	float	矩阵A*B的系数。	取值为1.0	
beta	attribute	float	矩阵C的系数。	取值为1.0	
Y	output	float	输出矩阵		

2.4.2.12 Gather

功能描述：沿着指定轴方向，根据索引值提取输入张量中的数据。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
data	input	float	输入张量	维度≥1	是

版权所有 © 上海云集互联有限公司

indices	input	int32/int64	索引值	设r为输入data的维度，则$indices \in [0, r-1]$。当输入维度大于1时，不支持indices的维度小于等于1	
axis	attribute	int64	沿着的轴方向。axis=0，按行索引。axis=1，按列索引。axis<0时，表示从后往前开始数data的第几个维度。	设r为输入data的维度，则$axis \in [-r, r-1]$。	
output	output	float	输出张量	设q为indices维度，r为data维度，则output维度=q+(r-1)。	

2.4.2.13 GlobalAveragePool

功能描述：全局的平均池化，将一个通道内的特征图平均为一个节点。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量	NCHW数据格式，输入维度小于5。	是
Y	output	float	输出张量	维度个数与输入X维度个数保持一致	

2.4.2.14 GlobalMaxPool

功能描述：全局的最大池化，将一个通道内的特征图取最大一个节点。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量	NCHW数据格式 输入维度小于5。	是
Y	output	float	输出张量	维度个数与输入X维度个数保持一致	

版权所有 © 上海云集互联有限公司

2.4.2.15 NonMaxSuppression

功能描述：CPU算子，输出值为输入张量中非极大值抑制后的选择坐标。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线data输入
boxes	input	float	输入张量		
scores	input	float	输入张量		
max_output_boxes_per_class	input	int64	每个batch每个class的最大boxes数量（可选）		
iou_threshold	input	float	交并比阈值（可选）		
score_threshold	input	float	Boxes分数阈值（可选）		
center_point_box	attr	int	Box数据的格式		
selected_indices	outputs	int64	输出张量		

2.4.2.16 MatMul

功能描述：对两个输入张量matmul。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
A	input	float	输入张量	两个输入张量形状不同时，会触发numpy-style的广播机制。	否
B	input	float	输入张量		
C	output	float	输出张量		

2.4.2.17 MaxPool

功能描述：将输入特征图按池化窗口不重叠地分割成若干，每一块在该窗口内输出最大值，其余值舍弃。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量		是
auto_pad	attribute	AutoPadM	pad自动填充		

版权所有 © 上海云集互联有限公司

		ode	模式，详见表 2.4.1.11-1 AutoPadMode取值说明		
ceil_mode	attribute	int	输出形状取整处理。 1:向上取整；0: 向下取整		
dilations	attribute	list of units	池化窗口膨胀系数。 dilations[0]为height方向系数 dilations[1]为width方向系数 默认dilations[0]=dilations[1]=1		
kernel_shape	attribute	list of units	池化窗口大小。 kernel_shape[0]为窗口height kernel_shape[1]为窗口width		
pads	attribute	list of ints	边缘像素补位填充值，默认补0。 pads[0]为顶部填充值 pads[1]为左侧填充值 pads[2]为底部填充值 pads[3]为右侧填充值		

版权所有 © 上海云集互联有限公司

strides	attribute	list of ints	步长，窗口每次移动的像素数。 默认strides[0]=strides[1]=1 stride[0]为height方向步长 stride[1]为width方向步长		
Y	output	Float	输出张量		
Indices	output	Int64	选取max值的位置索引		

2.4.2.18 Mean

功能描述：对输入的多个张量求平均值。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	inputs	float	输入张量		是
Y	output	float	输出张量		

2.4.2.19 Mul

功能描述：对两个输入张量逐个元素相乘。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
A	input	float	输入张量		
B	input	float	输入张量		
C	output	float/int32	输出张量		

2.4.2.20 NonZero

功能描述：CPU算子，输出值为输入张量中非0元素的位置坐标。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线data输入

版权所有 © 上海云集互联有限公司

x	input	float	输入张量		否
y	output	float	输出张量		

2.4.2.21 Pad

功能描述：对输入张量在指定的轴上的开始和结束填充指定数量的数据，填充的数据根据填充模式指定。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float/int32	输入张量		是
pads	input/attribute	list of ints	1D张量，格式为[x1_begin,x2_begin,…,x1_end,x2_end,…]指定要填充或删除（值为负）的元素的数量		
constant_value	input/attribute	float/int32	可选，指定在constant填充模式下填充的数据		
mode	attribute	string	可选，控制pad填充的模式，默认为constant，可选的模式有constant,reflect,edge		
Y	output	float	输出张量		

2.4.2.22 Resize

功能描述：以插值计算调整或改变输入张量的大小。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量	支持4-D NCHW数据格式	否
roi	input	float	感兴趣区域。在指定维度上归一化处理。仅支持指定h、w轴	roi维度数必须是X的2倍。	

版权所有 © 上海云集互联有限公司

scales	input	float	离线配置。沿着各维度缩放系数	1、与sizes配置互斥。 2、当前版本只支持上采样，且取值为2。 3、维度个数与输入X保持一致。	
sizes	input	int64	离线配置。指定输出张量大小	1、与scales配置互斥。 2、维度个数与输入X保持一致。	
coordinate_transform_mode	attribute	string	-	详见表2.4-1 coordinate_transform_mode取值说明。	
cubic_coeff_a	attribute	float	Pytorch为-0.75，TensorFlow为-0.5	仅缩放模式为cubic时，该参数有效，其他模式下不参与计算。	
exclude_outside	attribute	int64	默认值：0。仅支持配置为1，源张量外的采样点所在位置计算的权重将被置为0，且该权重会被归一化处理，使得总和为1.0	仅cubic模式下有效。	
extrapolation_value	attribute	float	默认值：0.0。源张量轴上值不在0到该轴长减1的范围时，直接输出源坐标像素值	仅cubic模式下有效。	
mode	attribute	string	-	详见表2.4-2 mode取值说明。	
nearest_mode	attribute	string	-	详见表2.4-3 nearest_mode源坐标取整方式说明。	
Y	output	float	输出张量		

2.4.2.23 Pow

功能描述：求X的Y次方操作。如果张量维度不一致，则需要对slope张量做双向广播。定义如下：

版权所有 © 上海云集互联有限公司

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
x	input	float	底数		
y	input	float	指数	不支持在线输入	是
output	output	float	输出张量		

2.4.2.24 PRelu

功能描述：对输入张量元素，根据给定的slope张量对输入张量中小于0的元素做相乘操作。如果slope张量维度与输入张量维度不一致，则需要对slope张量做双向广播。定义如下：

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
data	input	float	输入张量	维度≥1	否
slope	input	float	当输入张量中元素<0，则与slope张量中对应元素相乘。		
output	output	float	输出张量		

2.4.2.25 Range

功能描述：生成一维张量数据，该张量数据是一序列的数字，该生成过程是通过起始的start，然后每次增加delta，最大限制的数字为limit。定义如下：

参数名	参数类型	数据类型	参数说明	规格限制
start	input	float/int32	输入标量	1个数字
limit	input	float/int32	输入标量	1个数字
delta	input	float/int32	输入标量	1个数字
output	output	float/int32	输出张量	

2.4.2.26 ReduceMean

功能描述：对输入张量元素，根据给定的轴信息求平均值。如果keepdims等于1，则输出的张量与输入具有相同的秩。如果keepdims等于0，则输出的张量对应的轴将被删除。定义如下：

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
data	input	float/int64	输入张量	维度≥1	是
keepdims	attribute	Int64	是否在输出张量保留该维度，默认值为1		
axes	attribute	int64	可选，指定进行	设r为输入data的秩，	

版权所有 © 上海云集互联有限公司

			降维的维度，支持[-rank, rank - 1]，rank为维度数量，默认是对所有维数为1的维度进行降维操作。	则$axis \in [-r, r-1]$。只支持对H轴&W轴进行该操作。	
output	output	float/int64	输出张量		

2.4.2.27 ReduceMax

功能描述：对输入张量元素，根据给定的轴信息求最大值。如果keepdims等于1，则输出的张量与输入具有相同的秩。如果keepdims等于0，则输出的张量对应的轴将被删除。定义如下：

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
data	input	float/int64	输入张量	维度≥1	是
keepdims	attribute	Int64	是否在输出张量保留该维度，默认值为1		
axes	attribute	int64	可选，指定进行降维的维度，支持[-rank, rank - 1]，rank为维度数量，默认是对所有维数为1的维度进行降维操作。	设r为输入data的秩，则$axis \in [-r, r-1]$。只支持对H轴&W轴进行该操作。	
output	output	float/int64	输出张量		

2.4.2.28 ReduceMin

功能描述：对输入张量元素，根据给定的轴信息求最小值。如果keepdims等于1，则输出的张量与输入具有相同的秩。如果keepdims等于0，则输出的张量对应的轴将被删除。定义如下：

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
data	input	float/int64	输入张量	维度≥1	是
keepdims	attribute	Int64	是否在输出张量保留该维度，默认值为1		

版权所有 © 上海云集互联有限公司

axes	attribute	int64	可选，指定进行降维的维度，支持[-rank, rank - 1]，rank为维度数量，默认是对所有维数为1的维度进行降维操作。	设r为输入data的秩，则$axis \in [-r, r-1]$。只支持对H轴&W轴进行该操作。	
output	output	float/int64	输出张量		

2.4.2.29 Relu

功能描述：激活函数，将输入数据限制在非负数范围内，定义如下：

$$y = max\ (0, x)$$

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
x	input	float	输入张量		是
y	output	float	输出张量		

2.4.2.30 Resize

功能描述：以插值计算调整或改变输入张量的大小。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量	支持4-D NCHW数据格式	否
roi	input	float	感兴趣区域。在指定维度上归一化处理。仅支持指定h、w轴	roi维度数必须是X的2倍。	
scales	input	float	离线配置。沿着各维度缩放系数	1、与sizes配置互斥。 2、当前版本只支持上采样，且取值为2。 3、维度个数与输入X保持一致。	
sizes	input	int64	离线配置。指	1、与scales配置互斥。	

			定输出张量大小	2、维度个数与输入X保持一致。	
coordinate_transform_mode	attribute	string	-	详见表2-5 coordinate_transform_mode取值说明。	
cubic_coeff_a	attribute	float	Pytorch为-0.75，TensorFlow为-0.5	仅缩放模式为cubic时，该参数有效，其他模式下不参与计算。	
exclude_outside	attribute	int64	默认值：0。仅支持配置为1，源张量外的采样点所在位置计算的权重将被置为0，且该权重会被归一化处理，使得总和为1.0	仅cubic模式下有效。	
extrapolation_value	attribute	float	默认值：0.0。源张量轴上值不在0到该轴长减1的范围时，直接输出源坐标像素值	仅cubic模式下有效。	
mode	attribute	string	-	详见表2-6 mode取值说明。	
nearest_mode	attribute	string	-	详见表2-7 nearest_mode源坐标取整方式说明。	
Y	output	float	输出张量		

2.4.2.31 Slice

功能描述：在指定轴上，根据起始及步长将一个张量切片。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
input	input	float	输入数据		
starts	input	list of int64	每个轴的起始		
ends	input	list of int64	每个轴的终止（不包含该位置）		

版权所有 © 上海云集互联有限公司

axes	input	list of int64	可选，需要切片的轴，没指定的轴不需要切片。 [-r, r-1]的范围。		
steps	input	list of int64	可选，每个轴切片的步长。没有指定的话默认为1。不支持为0。		
output	output	float	输出数据		

2.4.2.32 Softmax

功能描述：计算给定输入z的归一化指数值，输出的张量和输入具有相同的形状。计算公式如下：

$$softmax_{(z_i)} = e^{z_i - \max(z)} \Big/ \sum_{j=1}^{n} e^{z_j - \max(z)}$$

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	input	float	输入张量		是
Y	output	float	输出张量		
axis	attribute	Int32	描述执行softmax运算的轴，负数表示倒着计算维度	设r为输入data的秩，则$axis \in [-r, r-1]$。只支持对H或W轴进行该运算	

2.4.2.33 Sqrt

功能描述：对输入张量的逐个元素计算平方根。y = x^0.5

参数名	参数类型	数据类型	参数说明	规格限制
X	input	float	输入张量	
Y	output	float	输出张量	

2.4.2.34 Sum

功能描述：对输入的多个张量逐元素相加。

参数名	参数类型	数据类型	参数说明	规格限制	是否支持离线输入
X	inputs	float	输入张量	输入张量数量>=1	是

版权所有 © 上海云集互联有限公司

Y	output	float	输出张量		

2.4.2.35 TopK

功能描述：计算输入张量的指定维度axis上，排序前K个的值与索引。

参数名	参数类型	数据类型	参数说明	规格限制
X	input	float/int32	输入张量	
K	input	int32	按规则排序后，前K数据与索引	
axis	attribute	int32	选择输入张量的需要排序的维度，默认为-1。	
largest	attribute	int32	选择最大排序还是最小排序，当指定的largest为1时，选择最大排序。当指定的largest为0时，选择最小排序。	
sorted	attribute	int32	选择是否按原本最值顺序输出。当指定sorted为1时表示原本顺序输出。当指定sorted为0时输出的顺序将未定义。	
Values	output	float/int32	输出张量。该输出张量为输入张量的指定维度axis上，排序前K个的值。	
Indices	output	int32	输出张量。该输出张量为输入张量的指定维度axis上，排序前K个的索引。	

版权所有 © 上海云集互联有限公司

版权所有 © 上海云集互联有限公司

3 仿真工具使用

3.1 环境准备

工具链提供了Linux和Windows系统下的仿真示例(samples)、运行时库(simulator/bin)和相关头文件(simulator/include)。同时提供了Windows系统下基于IDE Visual Studio 2022(x64)的工程文件，建议版本号在17.x以上，.Net Framework在4.8.x以上。目前只支持Intel和AMD系列的CPU。

依赖环境	版本
操作系统	Ubuntu 20.04
CPU	只支持 Inter 和 AMD 系列
GPU	只支持 nvidia 系列 最低驱动版本：Driver Version: 525.85.12 (查看方式：nvidia-smi) 最低 CUDA 版本：CUDA Version: 12.0 (查看方式：nvcc – version)
.Net Framework	最低版本：4.8.x
Windows 系统下 IDE Visual Studio 2022(x64)	最低版本：17.x

3.2 准备 demo 工程

在npu_toolchain/common/samples目录下，包含ortm_run_model，resnet50_binary，mobilenetv2_rgbplanar和tiny-yolov3_yuv420sp的demo工程。离线模型生成可参考samples/README.md，使用oritek_model_gen.sh生成sample对应的ortm模型。

```
./oritek_model_gen.sh mobilenetv2_rgbplanar simulator
```

其中，第一个参数是sample的目录，第二个参数是选择生成板端模型还是仿真模型。上面命令执行后，会在samples/mobilenetv2_rgbplanar/目录下生成mobilenetv2_rgbplanar_s.ortm仿真模型。

下面以ortm_run_model, mobilenetv2_rgbplanar和tiny-yolov3_yuv420sp为例介绍工程。

3.2.1 ortm_run_model工程

ortm_run_model支持命令行输入，进行模型评测，功能如下：

- 支持批量执行多组数据。
- 支持统计模型推理时间。
- 支持设置执行次数，统计平均推理时间（仅板端支持）。

版权所有 © 上海云集互联有限公司

- 支持精度dump，导出逐层结果。
- 支持导出性能数据。

命令行参数如下：

参数	输入类型	
-m	string	模型路径
-i	string	输入文件或文件夹路径
-o	string	输出文件夹路径
-d	无	逐层精度dump（默认关闭）
-p	无	导出性能结果（默认关闭）
-r	int	执行次数（仿真不支持设置）
-f	无	输入文件夹是否为二级目录

首先进入ortm_run_model，编译工程：

```
./build.sh
```

编译后，生成的可执行文件在./build/ortm_run_sim_model

设置环境变量：

```
export LD_LIBRARY_PATH=${NPU_TOOLCHAIN_ROOT}/linux/simulator/lib/:$LD_LIBRARY_PATH
```

使用实例：

（1）单输入模型的场景

当执行单个数据时，-i可以输入文件路径：

```
./ortm_run_sim_model -m xxx.ortm -i abc.bin -o output
```

模型输出会保存在output

```
output
├── abc_0.float.bin
├── abc_1.float.bin
```

当需要执行多组数据时，-i可以输入文件夹路径：

```
./ortm_run_sim_model -m xxx.ortm -i input -o output
```

输入输出文件夹目录为

```
input
├── abc.bin
└── efg.bin
output
├── abc_0.float.bin
├── abc_1..float.bin
```


版权所有 © 上海云集互联有限公司

```
├── efg_0.float.bin
└── efg_1.float.bin
```

（2）多输入模型的场景

多输入场景只支持文件夹输入。当执行单个数据时，可以输入：

```
./ortm_run_sim_model -m xxx.ortm -i input -o output
```

输入文件夹内的输入文件，需要按照模型的输入顺序，依次命名为0.bin, 1.bin, 2.bin…

```
input
├── 0.bin
└── 1.bin
output
├── 0_0.float.bin
├── 0_1..float.bin
```

（3）开启二级目录

当需要执行多组数据的多输入模型时，需要开启二级目录-f，输入：

```
./ortm_run_sim_model -m xxx.ortm -i input -o output -f
```

输入输出文件夹目录如下：

```
input
├── abc
│   ├── 0.bin
│   └── 1.bin
└── efg
    ├── 0.bin
└── 1.bin
output
├── abc
│   ├── 0_0.float.bin
│   └── 0_1.float.bin
└── efg
    ├── 0_0.float.bin
    └── 0_1.float.bin
```

（4）开启精度dump

指定参数-d，开启精度dump，导出精度数据

```
./ortm_run_sim_model -m xxx.ortm -i input -o output -d
```

（5）开启性能模式

指定参数-p，开启性能模式，导出性能数据

```
./ortm_run_sim_model -m xxx.ortm -p
```

（6）性能评估（仅支持板端）

版权所有 © 上海云集互联有限公司

当需要评估模型的性能时，可以指定执行次数-r，统计模型的在多次执行的平均时间。

```
./ortm_run_model -m xxx.ortm -r 1000
```

执行结束后会打印模型的最大执行时间，最小执行时间，平均时间。

3.2.2 mobilenetv2_rgbplanar工程

首先进入mobilenetv2_rgbplanar，目录下mobilenetv2_rgbplanar_s.ortm为根据omg工具生成的仿真模型文件，其输入格式为rgbplanar格式。ILSVRC2012_val_00024327.bin为经过预处理后的浮点输入数据文件（用于精度比对时，作为onnx模型的输入），ILSVRC2012_val_00024327.rgb为rgbplanar格式的输入文件，作为mobilenetv2_rgbplanar模型。执行run.sh脚本，编译工程并执行。模型会以ILSVRC2012_val_00024327.rgb文件作为输入，进行模型推理。

```
./run.sh
```

3.2.3 tiny-yolov3_yuv420sp工程

COCO_val2014_000000568213.jpg为测试图片，COCO_val2014_000000568213.yuv420sp为输入模型的yuv图像数据，draw_image.py为模型输出后处理示例脚本，根据区域坐标作目标框。示例工程编译并执行如下：

```
./run.sh
```

3.3 配置说明

在simulator/include/中，包括仿真接口需要使用的头文件。配置参数通过ot_avp_npu_common.h的ot_avp_npu_config结构体进行配置。目前extra_configs支持配置选项有"DUMP_PATH"，"QUANT_DUMP_PATH"

```
typedef struct {
    ot_u32 core_ids;     // 设备id
    ot_bool dump_layer;   //  仿真精度dump与量化精度dump，ture为开启
    ot_bool perf_mode;          // 性能模式，与sim_dump_layer和quant_dump_layer互斥。
    ot_u8 log_level;     // 日志级别，目前支持输入 1: debug、2: info、3: warn、4: error。
        ot_u32 thread_num;  // 执行的线程数，目前仿真阶段暂不支持配置
        ot_u32 extra_config_num; // 额外的参数配置的数量
        extra_config* extra_configs; //额外的参数配置
} ot_avp_npu_config;
```


版权所有 © 上海云集互联有限公司

图 3- 1 ot_avp_npu_config相关变量

3.4 精度 Dump

要开启精度Dump，需要关闭性能模型per_mode=false，设置sim_dump_layer=true开启仿真精度dump。

以mobilenetv2的demo工程为例，修改工程下main.cpp的ot_avp_npu_config结构体，开启量化或者仿真的dump_layer，同时perf_mode需要设置成false。

```
ot_avp_npu_config config = {
        . core_ids = 0,
        .dump_layer = true,
        .perf_mode = false,
        .log_level = 2,
    };
```

然后执行脚本。

```
./run.sh
```

执行结束后，仿真每层精度dump保存在LayerDump文件夹内。

3.5 导出性能数据

开启性能模式，perf_mode=true，执行脚本会打印出模型性能数据。以mobilenetv2为例，开启后，执行run.sh结果如下。同时，性能数据会保存到“oritek_perf_sim.csv”文件。

```
==== Oritek Perf result ====
  UID        CYCLE  HARDWARE         READBW        WRITEBW  NODE
    0          189       NPU              0              0  preprocess
    1        98688       NPU         615136              0  Conv_0
    2       101563       NPU              0              0  Conv_2
    3       100773       NPU              0              0  Conv_4
    4       101746       NPU              0              0  Conv_5
    5       104541       NPU              0              0  Conv_7
    6       104013       NPU              0          75264  Conv_9
    7       103994       NPU              0              0  Conv_10
    8        37021       NPU           1872              0  Conv_12
```

图 3- 2 模型每层性能数据

```
Profiler Stats Info
1 graphs
56 nodes
604118 NN clock cycles
4222080 NN read band width
80544 NN write band width
993.18345 fps in LQ560 single core
```

图 3-3 模型总的性能数据

4 量化损失评估

4.1 环境准备

在解压后的发布包中的npu_toolchain/linux/simulator/bin目录中，提供了一个伪量化模型推理工具oritek_graph_runner。该工具执行环境需求如下：

依赖环境	版本
操作系统	Ubuntu 20.04
CPU	只支持 Inter 和 AMD 系列
GPU	只支持 nvidia 系列 最低驱动版本：Driver Version: 545.23.08

4.2 oritek_graph_runner 工具参数说明

参数	输入类型	是否必选	说明
--model	string	必选	模型路径
-input	string	必选	输入文件路径（txt或者binary文件）
--output	string	可选	输出文件路径（文件名为模型中保存的输出tensor名字）
--dump_layer	bool	可选	是否保存中间层数据。当设置为true的时候，会在执行路径下创建QuantDump路径，并保存模型中所有算子的输出。默认为false
--gpu_id	int32	可选	使用GPU推理的GPU编号（可以使用nvidia-smi来查看编号）。如果设置为-1，则不适用GPU。该选项默认为-1.
--thread_num	int32	可选	使用CPU推理时，并行执行的CPU数量，默认为8.
--log_info	string	可选	日志级别（error/warn/info/debug）。默认为info。
--dump_analysis	string	可选	模型精度分析的结果保存路径，默认为./result.json；只有指定onnx_model之后，该选项才生效。

4.3 伪量化精度评估

在执行OMG进行模型转换的时候，如果是转换仿真（simulator）模型，在仿真模型保存的路径下，会生成一个_fake_quant后缀结尾的伪量化模型，该模型专门用来评估本次模型转换中的量化损失。

当发生精度问题的时候，可以使用上述fake_quant模型来评估量化损失。大致步骤如下：

版权所有 © 上海云集互联有限公司

4.3.1 Dump所有中 间层数据

```
npu_toolchain/linux/simulator/bin/oritek_graph_runner --model xxx_fake_quant.ortm --input xxx --dump_layer
```

执行上述命令，会在当前目录生成QuantDump目录，保存着量化后模型的所有中间层结果。

4.3.2 对比原始onnx结果

经过上面的命令，伪量化结果已经全部保存在了QuantDump目录中，这里可以继续使用精度对比工具来比对精度（具体介绍可以参考第7章）。

```
./compare_result.py --quant_result QuantDump \
--model xxx.onnx \
--input xxx.txt
```

经过上述命令，会把每层的精度比对结果打印到终端界面，结果如下：

```
Compare Results:
|   id | layer              | tensor             |    onnx vs quant |
|------|--------------------|--------------------|------------------|
|    3 | Pooling66          | Pooling66_Output_0 | 0.99956610241943 |
|    5 | ReLU114            | ReLU114_Output_0   | 0.99924956808128 |
|    6 | Pooling160         | Pooling160_Output_0| 0.99932809920870 |
|    8 | op_default_Gemm_13 | Plus214_Output_0   | 0.99975222726738 |
```

图4-1 精度对比结果

可以从图中查看每一层的余弦相似度，从而分析从哪一层开始精度下降较多，针对精度下降较多的层，可以使用高bit量化来提高模型精度。

4.4 量化精度分析

量化损失跟当前层的数据分布强相关，当前oritek_graph_runner也支持保存每层数据的精度比对结果和每层数据的直方图。大致使用流程如下：

4.4.1 导出精度数据

ortm模型和onnx模型精度对比dump精度结果

```
./ oritek_graph_runner --model xxx_fake_quant.ortm --input input.txt --log_level info --dump_analysis xxx/result.json
```

该命令，会删除量化模型中的量化信息并保存未量化模型中每层数据的分布直方图；并且会执行伪量化模型，来和未量化数据进行对比，并且保存对比结果。精度对比结果和每层数据分布会保存在dump_analysis指定的文件中。

4.4.2 精度数据可视化

使用NPU Studio工具可以将上去数据进行可视化，具体使用可以参考《SD3589CV100 NPUStudio VSIX使用指南》中的4.4章 模型量化功能。可视化效果如下图所示：

版权所有 © 上海云集互联有限公司

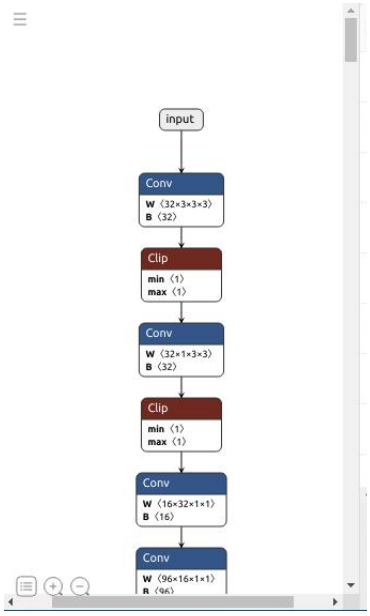


图4-2 量化数据分布可视化

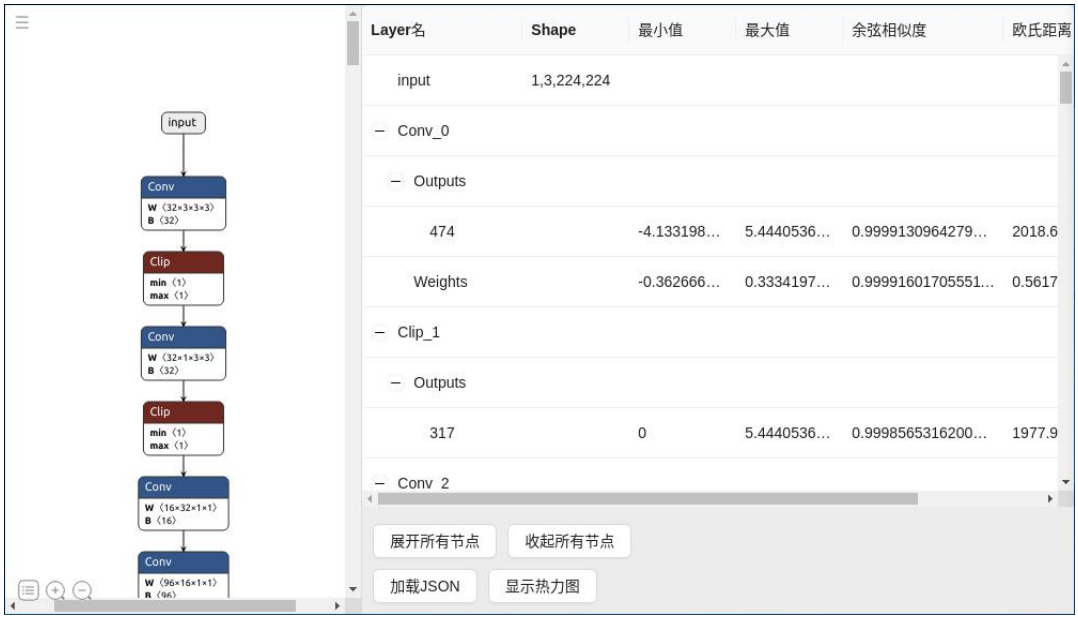


图4-3 量化损失可视化

如上图4-2所示，右侧的热力图展示的是当前层的分布直方图，从图上可以看出，绝大多数数据分布在零点附近，但是最大值附近也有不少数据分布（这里颜色越深数据越多）。

图4-3为当前层的最大、最小值展示，还有余弦相似度、欧式距离、均方误差等评估指标

5 板端 SDK 使用

5.1 兼容版本

OMG生成的离线模型，兼容板端SDK最低版本V1.2.3

5.2 使用说明

参考《SD3589CV100 NPU API开发参考》。

5.3 Sample 示例

5.3.1 通用sample工程

在sdk/main/src/component/npu/samples目录下，包含ortm_run_model，sample_shared_lib两个demo工程。ortm_run_model使用静态库链接, sample_shared_lib使用动态库链接。区别在于执行sample_shared_lib之前需要设置环境变量LD_LIBRARY_PATH, SDK_ROOT是SDK发布包的根目录。

```
export LD_LIBRARY_PATH=${SDK_ROOT}/main/out/lib:$LD_LIBRARY_PATH
```

下面以ortm_run_model为例，进行说明

ortm_run_model支持命令行输入，命令行参数如下：

参数	输入类型	
-m	string	模型路径
-i	string	输入文件路径
-o	string	输出文件夹路径
-d	无	逐层精度dump（默认关闭）（V100不支持）
-p	无	导出性能结果（默认关闭）
-r	int	执行次数
-f	无	输入文件夹是否为二级目录

（1）sample编译：首先进入sdk/main/src/component/npu/samples，进行make。

（2）设置环境变量

```
export LD_LIBRARY_PATH=${SDK_ROOT}/main/out/lib:$LD_LIBRARY_PATH
```

（3）使用实例：请参考3.2.1 中仿真的使用实例，用法一致。

（4）开启性能模式

指定参数-p，开启性能模式，导出性能数据

```
./ortm_run_model -m xxx.ortm -p
```

（5）性能评估

当需要评估模型的性能时，可以指定执行次数-r，统计模型的在多次执行的平均时间。

```
./ortm_run_model -m xxx.ortm -r 1000
```

执行结束后会打印模型的最大执行时间，最小执行时间，平均时间。

版权所有 © 上海云集互联有限公司

5.3.2 sample_api_user_guide工程

该sample主要是指导客户如何使用一些特定场景下的功能。

（1）sample编译：首先进入sdk/main/src/component/npu/samples，进行make。

（2）用法：进入sample_api_user_guide目录，按照Usage，选择对应的功能执行。

```
Usage : ./sample_api_user_guide <index>
index :
    1) async inference. [single_npu_graph_model + single_npu_graph_model]
    2) async inference. [single_graph_model + multi_graph_model ]
```

（3）功能说明

异步推理：

1. 支持model 0 trigger/model 0 wait + … + mode n trigger/model n wait的方式。
2. 多个单NPU图，也支持model 0 trigger + … + model n trigger + model n wait的方式，以及 model 0。

5.4 配置说明

在sdk/main/out/include/中，包括板端接口需要使用的头文件。配置参数通过ot_avp_npu_common.h的ot_avp_npu_config结构体进行配置。

```
typedef struct {
    ot_u32 core_ids;     // 设备id
    ot_bool dump_layer;
    ot_bool perf_mode;   // 性能模式，与dump_layer互斥。
    ot_u8 log_level;         // 日志级别，目前支持输入，1: debug、2: info、3: warn、4: error。
} ot_avp_npu_config;
```

图 4- 1 ot_avp_npu_config相关变量

5.5 导出性能数据

开启性能模式，perf_mode=true，执行脚本会打印出模型性能数据。以mobilenetv2为例，开启后，执行run.sh结果如下。

版权所有 © 上海云集互联有限公司

```
====== Oritek Perf Res
  UID   HARDWARE    DUR
    0        NPU
    1        NPU
    2        NPU
    3        NPU
    4        NPU
    5        NPU
    6        NPU
    7        NPU
    8        NPU
    9        NPU
   10        NPU
   11        NPU
   12        NPU
   13        NPU
   14        NPU
   15        NPU
   16        NPU
```

图 4-2 模型每层性能数据

```
Profiling Status Info
  graphs : 1
  nodes  : 48
  Single Core fps : 1079.91361
  NN Duration     : 926 us
```

图 4-3 模型总的性能数据

6 图像预处理工具使用

6.1 使用场景

当需要生成模型执行所需的输入文件时，可参考npu_toolchain/linux/script/convert_data.py脚本，编写图像预处理功能，生成模型所需的输入文件。

6.2 使用说明

convert_data.py具有以下功能：

- 根据jpg图像，生成binary，rgbplanar，yuv420sp格式的文件。
- 将rgbplanar, yuv420sp进行预处理，生成binary文件。
- 将binary, rgbplanar, yuv420sp文件转成txt文本文件，查看文件内容。
- 指定预处理crop, resize, dtc的参数。

（1）参数说明

参数	说明
--input	输入文件
--output_type	输出类型（binary, rgbplanar, yuv420sp, bin, txt）

版权所有 © 上海云集互联有限公司

	(输入输出类型对应关系：[jpg, jpeg] -> [binary, rgbplanar, yuv420sp], [rgb, yuv420sp] -> [bin, txt], [bin] -> [txt])
--img_centercrop	先缩放，再中心裁剪，需要输入4个参数（[resize_height, resize_width, crop_height, crop_width]）
--img_resize	缩放（[resize_height, resize_width]）
--img_dtc	对图像进行data = (img / 255 - mean) / std操作，需要传入6个参数 （[r_mean, g_mean, b_mean, r_scale, g_scale, b_scale]）
--img_size	rgb和yuv420sp转bin需要指定图像的宽和高。（[height, width]）
--use_default	使用默认的预处理参数（resize:[256, 256], center_crop:[224, 224], dtc:[0.485, 0.456, 0.406, 0.229, 0.224, 0.225]）

（2）使用说明
使用示例可参考 npu_toolchain/linux/script 下的 README

7 精度对比工具使用

7.1 使用场景

精度对比工具面向的问题场景是：

1、量化后模型和原始浮点模型精度差异大；

2、仿真模型和原始浮点模型精度差异大；

版权所有 © 上海云集互联有限公司

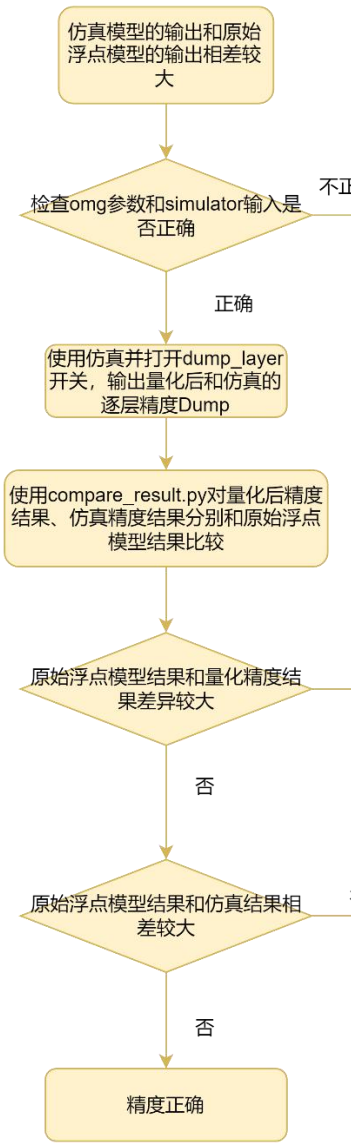


图 - 6- 1 精度调试流程

7.2 环境准备

在发布包的tools目录，提供了精度比对的脚本compare_result.py，依赖的相关python库，可参考同目录的requirements.txt，使用命令pip install -r requirements.txt完成相关依赖的安装。

7.3 精度分析

当需要ONNX模型输出对比逐层精度时，由于ONNX仅支持浮点数据格式输入，需要使用经过预处理后的浮点数据作为ONNX模型的输入（Binary格式）。以mobilenetv2为例，使用convert_data.py，指定参数--output_type为Binary，选择默认的预处理参数图像进行预处理：

```
./convert_data.py --input ./xxx.jpeg --output_type Binary --use_default
```

执行命令后，生成xxx.bin文件，作为onnx模型的输入。

参考以下工具使用，将 仿真模型推理结果 QuantDump，板端仿真推理结果 LayerDump 和原始 onnx 模型推理结果逐层比对。使用示例可参考 npu_toolchain/linux/script 下的 README

```
./compare_result.py --quant_result QuantDump \
--simulate_result LayerDump \
--model mobilenetv2-12.onnx \
--input input.bin
```

表 6-1 精度比对参数QuantDump和LayerDump说明

成果物	说明
QuantDump	通过仿真执行后生成的量化之后的模型执行结果。
LayerDump	通过仿真执行后生成的板端仿真结果，该结果和最终上板执行二进制一致。

当指定--model参数、--input参数为原始模型和输入的数据时，会生成原生模型以浮点数据推理的结果。执行结果比对示例如下：

Compare Results:

id	layer	tensor	onnx vs quant	onnx vs board
3	Clip_1	317	0.99993133853338	0.99993133591112
5	Clip_3	320	0.99887846678396	0.99887845934382
6	Conv_4	480	0.99355125251286	0.99336076385015
8	Clip_6	325	0.99585169062225	0.99585176026934
10	Clip_8	328	0.99475938298851	0.99475977353605
11	Conv_9	489	0.98903517704239	0.98889436730169
13	Clip_11	333	0.99392779006886	0.99392911878951

图 6-2 模型的onnx与量化后、onnx与板端仿真的每一层精度对比

图中各列分别为layerId，layerName，tensorName, onnx和量化后结果的余弦相似度，onnx和仿真结果的余弦相似度。可基于该结果，转换后的模型做进一步的精度分析。

不指定--model参数，--input参数时，仅比对量化后的模型和板端仿真的精度差异。

id	layer	tensor	quant vs board
1	op_Preprocess0	preprocess_out_1113	0.99998574278907
3	Clip_1	317	0.99999999497455
5	Clip_3	320	0.99999997728946
6	Conv_4	480	0.99980147913934
8	Clip_6	325	0.99999935278490
10	Clip_8	328	0.99999832952925
11	Conv_9	489	0.99985167028795

图 6-3 模型量化后与板端仿真的精度对比

版权所有 © 上海云集互联有限公司

7.4 解决方案

7.4.1 onnx vs quant余弦相似度较低

7.4.1.1 增加量化数据数量

量化数据集数量对结果有一定影响，若一张数据集效果较差，可考虑增加数据数量，一般设置50~200条数据。若包含ptp剪枝，剪枝所用数据集数量一般设置一千条。

7.4.1.2 改变量化算法

其次，考虑量化算法是否合适。权重使用per-channel量化，量化效果较per-tensor更高，例如densenet模型使用per-channel量化精度更高。当数据分布呈现两端数据较少且分布范围较大，可考虑kld算法、mse或者pencetile算法，以截取集中范围数据避免误差。以上均在原本设置的量化比特上计算实数域到整数域的映射关系，具体配置方式请参考表 2.3-1。例如图6-4中，hazy模型中有部分中间层onnx vs quant精度低于0.9，算子relu的输出 _layer3_layer3_0_layer3_0_4_act2_Relu_output_0的热力图显示数据呈现两端分散（这里数据统计用的绝对值），那么kld算法能更好的应对由于分散阈值带来的精度损失。

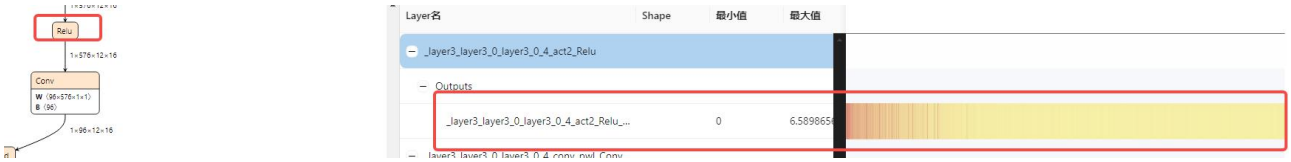


图 6-4 hazy模型中间层精度结果

7.4.1.3 特定算子组合设置配置

针对特定算子或者算子组合精度较差的情况，如add算子、concat算子等，可利用发布包可视化工具查看其数据分布，若该算子或者组合不适合量化（conv算子等矩阵运算算子必须量化，可配置16比特量化），可以参考表 2.3-1设置该算子或者算子区间的数据类型为S16或fp16以提高精度。由8bit量化改为16比特量化或是不量化，也会引发性能降低，用户需要平衡性能和精度的需求。如图6-5中，concat算子的三个输入数据的范围差异较大，而concat算子需要输出输入统一量化系数，导致量化误差。

版权所有 © 上海云集互联有限公司

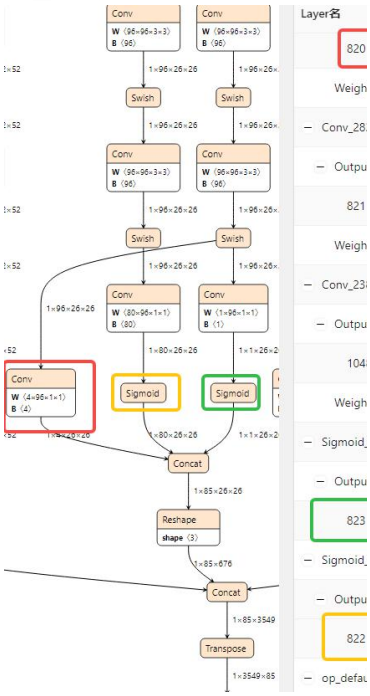


图 6-5 hazy模型中间层精度结果

7.4.1.4 配置混合比特量化

当前版本支持混合精度量化功能，与章节7.4.1.4不同，混合比特量化会改变tensor的量化比特数。。混合精度量化包括activation混合精度量化和weight混合精度量化两种做法。用户通过配置量化配置文件中activation字段或weight字段中auto_bits的属性，来实现混合精度量化功能的配置。具体配置方式请参考表2.3-1。

1）activation混合精度量化

activation混合精度量化是将部分的8比特量化升级为16比特，从而提升网络的精度。可以根据需求配置不同的升级比例，配置范围为9-15。配置参数越大，则升级比例越高，量化的比特数越多，精度提升的效果也会更好。另外，当前版本对activation混合精度量化功能提供了auto配置，使用auto配置时，会根据量化敏感度阈值对所有的activation进行筛选，然后将筛选得到的activation升级为16比特量化。

2）weight混合精度量化

weight混合精度量化是将部分的8比特降低为4比特，从而提升网络的性能。可以根据需求配置不同的降低比例，配置范围为5-7。参数配置越小，则降低比例越高，量化的比特数越少，网络性能提升的效果也会更好。weight混合精度量化的auto配置是根据每个权重的量化敏感度与内置的量化敏感度阈值进行比较筛选，然后将筛选得到的weight降低为4比特量化。

另外，activation和weight的混合精度量化只支持单独配置其中一个，需要根据具体的需求和网络结构选择适合的混合精度量化方式，从而达到更好的效果

版权所有 © 上海云集互联有限公司

7.4.2 onnx vs board余弦相似度较低

7.4.2.1 检查层名匹配

onnx与quant余弦相似度超过0.9而onnx与board余弦相似度很低，查看LayerDump数据，考虑是否是图融合导致onnx和board的层名匹配失败。是否onnx模型该层结果匹配到了board模型的其它层结果，导致计算有误。

7.4.2.2 输入为极小值

swish、Sigmoid等算子的输入若为极小值，可能造成精度丢失。对于检测模型，数据集最好含有检测物体，否则背景检测层的概率值趋近于零，导致余弦相似度较差。

版权所有 © 上海云集互联有限公司

8 高性能算子配置

8.1 Conv 类算子

8.1.1 Conv/Pool/DepthwiseConv

output_w: output_w 16对齐

output_c: output_c 16对齐

input_c: input_c 整除 (64 / data_bit_num)，data_bit_num 表示计算数据位宽

kernel: 建议配置1*1; 2*2; 3*3，当Conv输入通道数小于32时，不推荐设置kernel为1*1

dilation: 建议配置1*1

stride: 建议配置1*1或2*2

pad: pad_up < kernel_h pad_down < kernel_h，在可以选择上补边或者下补边时，建议配置上补边

group: 针对Conv，每个group都可以视作一个Conv层，每个group的参数都满足上述建议配置时，性能最优。

当Conv在网络中是单输出节点，Conv后接了Pool，并且Pool的kernel为2*2，stride为2*2，pad为0时，此时Conv级联Pool的性能最优。

8.1.2 ConvTranspose

output_w: output_w 16对齐

output_c: output_c 16对齐

input_c: input_c 整除 (64 / data_bit_num)

kernel: 建议配置1*1; 2*2; 3*3，针对ConvTranspose，当（input_c < 32）时，不建议配置kernel为1*1

dilation: 建议配置1*1

stride: 建议配置1*1或 2*2

pad: pad_up > (kernel_h - stride_h - 1) pad_down > (kernel_h - stride_h - 1)，在可以选择上补边或者下补边时，建议配置上补边

8.2 数据排布

建议使用NCHW描述算子数据排布格式。

Concat、Slice输入输出均为NCHW格式，并且在C轴拼接或者分割时，效率最高

Reshape　output_w = input_w时，效率最高

9 自定义 CPU 算子使用

版权所有 © 上海云集互联有限公司

9.1 使用场景

当用户遇到内置算子不满足需求时，可以按照步骤手动添加自定义CPU算子，以满足需求。

9.2 环境准备

自定义CPU算子相关头文件和库在custom_ops目录下。

9.3 使用说明

custom_ops/sample/extern_custom_opsets目录为自定义CPU算子的demo工程。在该工程中，包含一个自定义Abs算子的实现实例。下面以Abs算子为例，介绍自定义算子的添加流程。添加一个自定义CPU算子，需要三个步骤：1）算子原语定义；2）算子相关函数实现；3）算子注册。

9.3.1 算子原语定义

算子原语定义，需要定义算子的名称，输入输出信息，属性信息等。在extern_custom_opsets/def/目录下，新建算子定义xxx_def.cpp文件，定义算子的基本信息。以Abs为例，其原语定义如下：

```
namespace oritekgraph {
EXTERN_CUSTOM_OPERATOR_SET_SCHEMA(
   Abs,                                    // 算子名称
   1,                                      // 版本号
   OpSchema()
   .Input(0, "X", "N-D tensor", "T")                  // 输入信息
   .Output(0, "Y", "N-D tensor", "T")                 //输出信息
   .TypeConstraint("T", {"float", "int32"}, "only fp32 int32 supported")  // 限制信息
   .SetDoc("Y=abs(X)")                                //描述文档
   );
}
```

9.3.2 算子函数实现

要支持CPU算子运行，需要编写算子的三个函数实现：

- infershape：输出shape, dtype, format的推理方法；
- check_supported：算子规格限制的检查方法；
- compute：算子计算的实现方法；

版权所有 © 上海云集互联有限公司

算子函数的实现放在extern_custom_opsets/impl/ 目录下。新建xxx_impl.c和xxx_impl.h文件，定义infershape, checksupported, compute这三个函数实现，在impl/opsets.h文件中，加入定义好的头文件。定义的函数需要遵循定义好的格式形式：

```
ot_s32 op_impl_function(ot_avp_custom_handle custom_op)
{
  …
}
```

在执行过程中，CPU算子的输入输出信息，属性信息，会保存在ot_avp_custom_handle类型中。在编写算子的实现函数时，通过调用ot_avp_custom_utils.h头文件提供的接口，获取和设置算子的信息。

以Abs算子为例。在infershape函数中，通过接口获取算子的输入shape、dtype和format信息，并设置到输出中，从而推导输出的shape, dtype和format。

```
ot_s32 abs_check_supported_float (ot_avp_custom_handle custom_op)
{
  ot_avp_npu_shape in0_shape;
  ot_avp_data_type in0_dtype;
  ot_avp_npu_dformat in0_format;
  // get inputs info
  ot_avp_custom_get_input_shape_by_index(custom_op, 0, &in0_shape); // 获取输入0的shape
  ot_avp_custom_get_input_dtype_by_index(custom_op, 0, &in0_dtype); // 获取输入0的dtype
  ot_avp_custom_get_input_format_by_index(custom_op, 0, &in0_format); // 获取输入0的format

  // update outputs info
  ot_avp_custom_set_output_shape_by_index(custom_op, 0, in0_shape); // 设置输出0的shape
  ot_avp_custom_set_output_dtype_by_index(custom_op, 0, in0_dtype); // 设置输出0的dtype
  ot_avp_custom_set_output_format_by_index(custom_op, 0, in0_format); // 设置输出0的format
  return 0;
}
```

check_supported函数会对算子信息进行检查，判断该算子的规格和数据信息是否符合自定义函数实现的条件。在自定义Abs算子的compute函数中，只定义了float类型的计算，该函数只支持float类型的计算。因此在check_supported中，判断dtype是否为OT_AVP_DTYPE_F32。

```
ot_bool abs_check_supported_float(ot_avp_custom_handle custom_op)
{
  printf("call extern cpu abs check supported\n");
  ot_avp_data_type in0_dtype;
  ot_s32 ret = ot_avp_custom_get_input_dtype_by_index(custom_op, 0, &in0_dtype);
  if (in0_dtype != OT_AVP_DTYPE_F32 || ret != 0) {
    return false;
  }
  return true;
```


版权所有 © 上海云集互联有限公司

```
}
```

在算子compute函数中，定义了CPU算子的计算过程。

```
ot_s32 abs_compute_float(ot_avp_custom_handle custom_op)
{
   // get inputs tensor info
   ot_u64 in0_buf_len = 0;
   ot_avp_custom_get_input_buf_len_by_index(custom_op, 0, &in0_buf_len);
   ot_u64 in0_elem_len = in0_buf_len / sizeof(ot_float);
   ot_float* in0_buf = (ot_float*)ot_avp_custom_get_input_buf_by_index(custom_op, 0);
   if (in0_buf == NULL) {
      return -1;
   }
   // get outputs tensor info
   ot_float* out0_buf = (ot_float*)ot_avp_custom_get_output_buf_by_index(custom_op, 0);
   if (out0_buf == NULL) {
      return -1;
   }
   // compute
   for (ot_u32 i = 0; i < in0_elem_len; i++) {
      out0_buf[i] = fabs(in0_buf[i]);
   }
   return 0;
}
```

9.3.3 算子注册

在完成CPU算子的定义和实现后，需要将定义好算子原语和实现，注册到算子库中。在extern_schema_sets.h加入CPU算子的OpSchema注册信息。

```
class ORITEK_OPERATOR_SET_SCHEMA_CLASS_NAME(extern_cpu, 1, Abs);
…
fn(GetOpSchema<ORITEK_OPERATOR_SET_SCHEMA_CLASS_NAME(extern_cpu, 1, Abs)>());
…
```

在extern_impl_sets.h文件中，加入算子实现函数的注册。

```
REG_EXTERN_CUSTOM_OP_IMPL(Abs, abs_infershape, abs_check_supported_float, abs_compute_float);
```

在宏定义中，传入参数依次为算子类型，实现名称，infershape函数，check_suipported函数，compute函数。

版权所有 © 上海云集互联有限公司

9.3.4 算子库编译和加载

在将实现一个CPU算子的相关代码编写好后，在extern_custom_opsets目录下，执行./run.sh，进行编译，在生成的build文件夹下，可以找到CPU算子库libcustom_opsets_extern.so。将该库放到omg/lib和simulator/lib下，即可在生成离线模型和仿真中，使用自定义的CPU算子。

```
./run.sh
```

9.4 算子定义限制

在自定义CPU算子时，需要注意以下限制条件：

（1） 自定义算子的属性个数 <= 16

（2） 自定义算子的属性名称 <= 64

（3） 编写自定义函数实现时，需要保证定义函数名不能重复，且函数名<=64。

9.5 准备 demo 工程

在npu_toolchain/linux/samples/custom_abs 目录下，提供了转换和执行自定义Abs算子的demo。首先，**确保将libcustom_opsets_extern.so放在omg/lib和simulator/lib文件夹下**。

（1）Abs算子的ortm仿真模型生成

进入samples/custom_abs/convert_model，执行脚本，生成custom_abs.ortm模型。

```
./oritek_model_gen.sh
```

（2）仿真执行

进入samples/custom_abs/simulator目录，将上一步生成的custom_abs仿真模型拷贝到当前目录，执行run.sh脚本，编译工程并执行，在仿真执行中，则会调度到CPU算子库中执行。

```
./run.sh
```

9.6 板端加载 CPU 算子库执行

在板端npu sample中，提供了CPU算子的执行sample(custom_abs)。

Step1：编译板端sample和用户自定义CPU算子库 libot_avp_npu_custom_opsets_extern.so。

进入sdk/main/src/component/npu/samples，编译板端sample和用户自定义算子库

```
make
```

编译得到的板端CPU算子库在sdk/main/out/lib/ libot_avp_npu_custom_opsets_extern.so

Step2：将CPU算子库所在目录加入LD_LIBRARY_PATH环境变量

```
export LD_LIBRARY_PATH= (CPU算子库所在路径) :$LD_LIBRARY_PATH
```

同时，要确保内部custom_opsets_oritek的算子库所在目录也设置在LD_LIBRARY_PATH环境，板端才能加载CPU算子库。

版权所有 © 上海云集互联有限公司

Step3：执行 sample_custom_abs

进入板端samples/custom_abs。该工程是板端执行自定义Abs算子的sample工程。该文件夹下有工程执行所需的Abs单算子板端模型custom_abs_b.ortm，以及执行所需的输入input_abs.bin。

直接执行即可得到自定义Abs算子的执行结果。

版权所有 © 上海云集互联有限公司